Analysez les données de systèmes éducatifs

Projet 1 du parcours **Data Scientist Machine Learning**

Projet d'extension de l'entreprise

Academy

Objectif : Identifier les pays pertinents pour une expansion à l'international

Analyse pré-exploratoire de données issues de la Banque Mondiale

07/08/2026

Index

1.Présentation

1. L'entreprise.
2. La mission.

2. Explorer des données

1. Visualisation des valeurs manquantes pour chaque fichiers avec la bibliothèque missingo de python.

2. Calcul du % de données manquantes pour chaque DataFrame avec la bibliothèque matplotlib (langage Python)

3. Tests DataFrames et nettoyages des données

1. Résumé synthétique des tests de cohérence.

4. Créer les variables

1.Etude des valeurs pertinentes.

2.Liste des indicateurs sélectionnées.

3.Consolider un nouveau DataFrame

5. L'étude des variables

1.J'analyse du taux de remplissage de mes variables sélectionnées

2 Bilan global du remplissage des variables

3 Analyse de l'indicateur temps

4 Détecter des outliers

6. Analyse des corrélations et calcul du score

6.1 Exemple de corrélation entre le taux d'inscription en secondaire et tertiaire VS population

6.2 Explication du besoin de pondération

6.3 Calcul du score et liste de 15 pays sélectionnés

7. Conclusion

7.1-Les limites de l'étude et les recommandations

1.1-L’entreprise

Academy est une start-up de la EdTech qui propose des contenus de formation en ligne pour un public de niveau lycée et université.

1.2-La mission

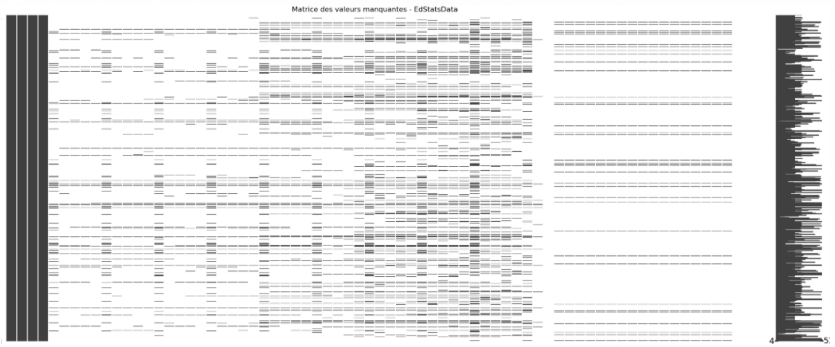
La mission consiste à une première d'analyse exploratoire des jeux de données par le data scientist et consiste a déterminer si les données collectés peuvent fournir des insights guidant academy à décider dans quels pays s’implanter.

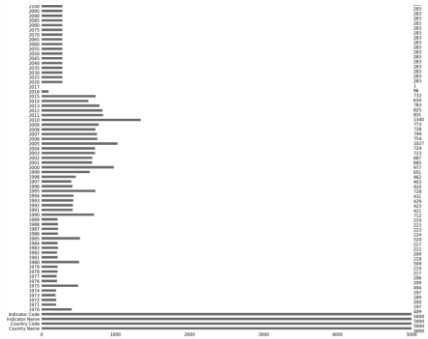
2. Exploration des données

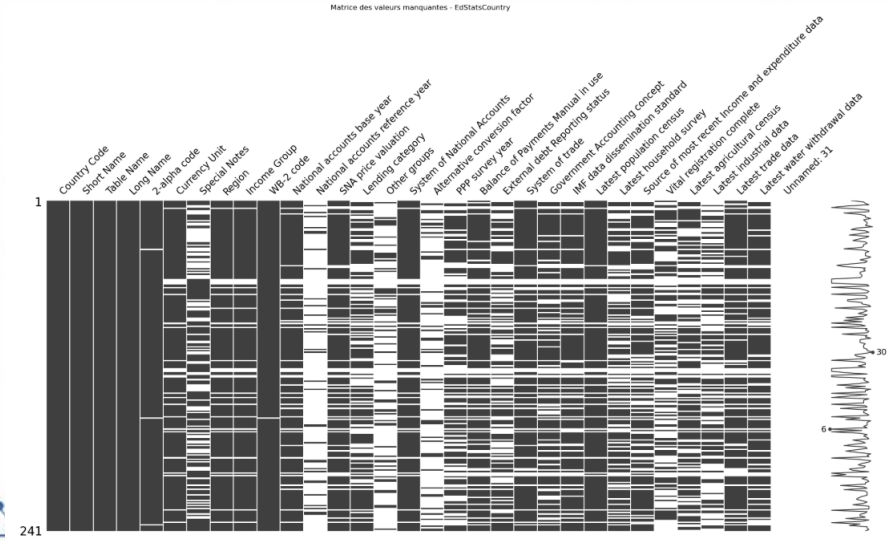
- 5 jeux de données ont été fourni, il s'agit de 4 index et d'un fichier principal.

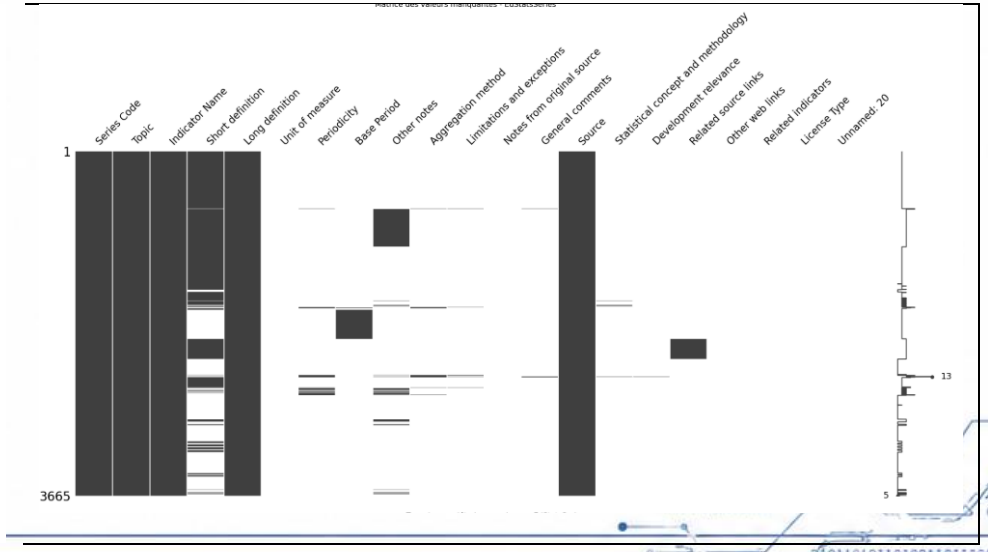
2.1 Visualisation des valeurs manquantes pour chaque fichier avec la bibliothèque missingo de python.

La première analyse exploratoire consiste à visualiser pour chaque fichier la globalité des valeurs manquantes et à les représenter sous la forme d'un graphique à l'aide de la bibliothèque missingo (langage Python). Nous pouvons ainsi d'un coup d'œil visualiser le taux de remplissage des colonnes et des lignes pour chaque fichier.

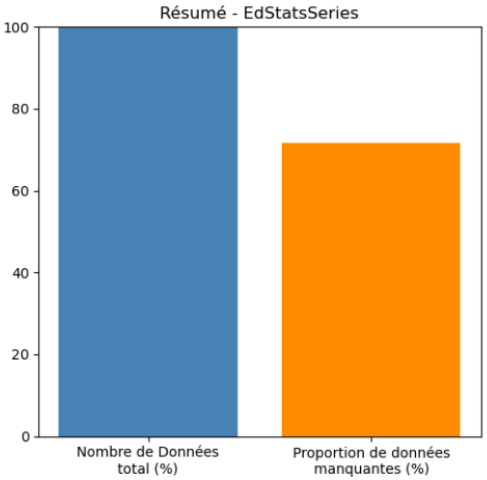




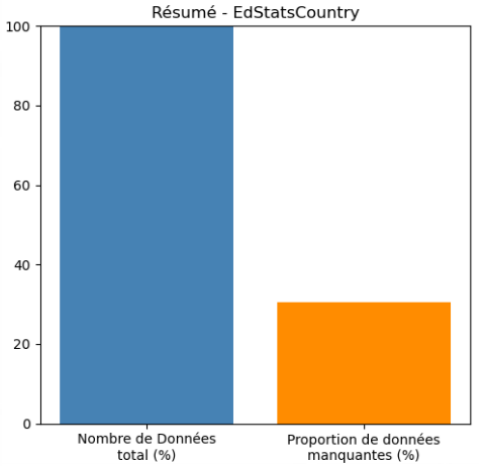




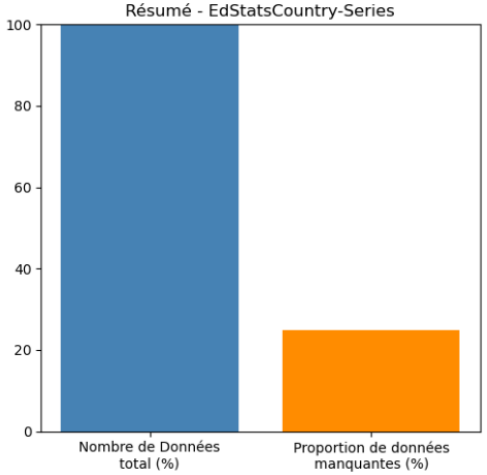
2.2 Calcul du % de données manquantes pour chaque DataFrame avec la bibliothèque matplotlib (langage Python).



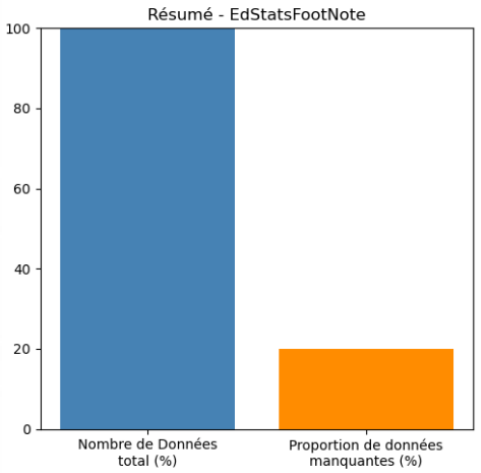
EdStatsSeries' : data frame de **3665 lignes et 21 colonnes**, comprenant 76965 éléments dont **71.72%** de données manquantes.
Ce fichier sert de dictionnaire pour les indicateurs (nom, définition, source)



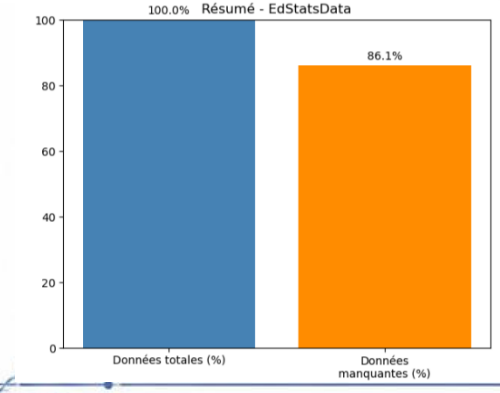
'EdStatsCountry' : data frame de **241 lignes et 32 colonnes**, comprenant 7712 éléments dont **30.52%** de données manquantes.
Ce fichier donne les métadonnées des pays (région, revenu, devise...).



'EdStatsCountry-Series' : data frame de **613 lignes et 4 colonnes**, comprenant 2452 éléments dont **25.00%** de données manquantes.
Ce fichier donne des notes/annotations sur la source ou la méthode de collecte
des données, pour certains couples (pays, indicateur).



'EdStatsFootNote' : data frame de **643638 lignes et 5 colonnes**, comprenant 3218190 éléments dont **20.00%** de données manquantes.
Ce fichier donne des précisions (ex: estimation par le pays) pour un couple (pays, indicateur) à une année précise.



'EdStatsData' : Contient **886930 lignes et 70 colonnes**, soit 62085100 éléments dont **86.10%** de données manquantes.

Ce fichier correspond au dataset principal de l'analyse.

3. Tests DataFrames et nettoyages des données

3.1 Résumé synthétique des tests de cohérence

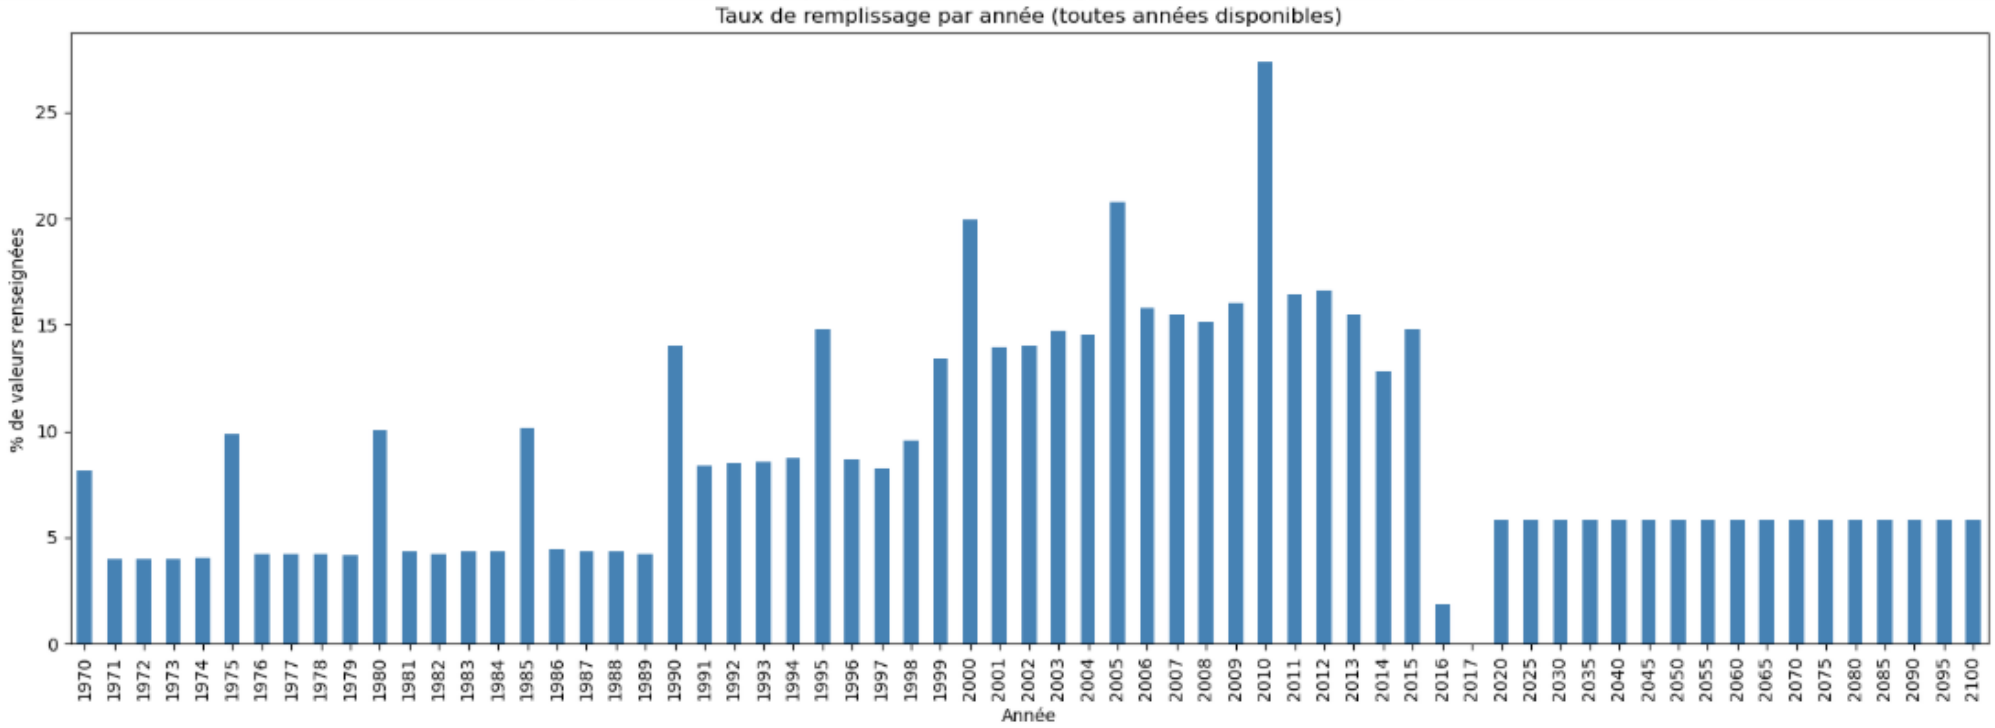
Plusieurs contrôles croisés ont été réalisés entre les 5 fichiers du projet (EdStatsData, EdStatsSeries, EdStatsCountry, EdStatsFootNote et EdStatsCountry-Series) entre les index et le fichier principal.

Test	Résultat principal
1. Indicateurs	53 écarts apparents → uniquement des différences de casse/espaces. Après normalisation : 0 écart.
2. Pays par nom	29/30 écarts dus à des différences d'écriture. 1 seul cas réel : British Virgin Islands (erreur de nom + mauvaise classification).
3. Pays par code ISO	1 seul vrai écart : VGB (British Virgin Islands).
4. Contrôle croisé global	4 codes problématiques : GRL, MAF, SXM (sans note) et VGB (sans fiche pays). Correspondance correcte sur 3 fichiers / 4. Point de vigilance : format des années différent (YR2004 vs 2004).
5. Validation aléatoire	Plusieurs tests de lecture donnée aléatoire ont été effectués (≈ 30 tests) avec succès.

4. Créer les variables

4.1-Etude des valeurs pertinentes.

4.1.1-J'ai besoin d'un **échantillon de temps** : je choisi alors 10 années que je sélectionne dans le fichier de données principal selon leur pourcentage de remplissage (données de recensement).



Je sélectionne les années : 2000, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013

-Je crée la variable : **annees_selectionnees**

4.1.2-Depuis le fichier df_country.

-Je crée la variable : **zones_geographiques**
-Je crée la variable : **pays**

4.1.3 -Je cherche de **indicateurs à conserver** pour cela je recherche par mots clé dans le nom des indicateurs ou dans leurs définitions.

Exemple :

```
Nombre d'indicateurs avec nom trouvé : 489
--- Indicateurs contenant 'enrolment' : 106 résultats ---
--- Indicateurs contenant 'secondary' : 131 résultats ---
--- Indicateurs contenant 'tertiary' : 32 résultats ---
--- Indicateurs contenant 'internet' : 1 résultats ---
--- Indicateurs contenant 'teachers' : 10 résultats ---
--- Indicateurs contenant 'web' : 0 résultats ---
--- Indicateurs contenant 'connectivity' : 0 résultats ---
--- Indicateurs contenant 'computers' : 0 résultats ---
```

(Voir le notebook pour la méthode de recherche par mots clés).

Les variables vont être nommées selon la convention nom_indicateur_**unite**
(ex. : _pct pour les pourcentages, _usd pour les dollars), afin d'indiquer clairement l'unité de chaque valeur.

4.2-Liste des indicateurs sélectionnées

Series Code	Indicator Name	Topic	Variable
IT.NET.USER.P2	Internet users (per 100 people)	Infrastructure: Communications	**Utilisateurs internet (%)**
SE.SEC.ENRL	Enrolment in secondary education, both sexes (number)	Secondary	**Inscription secondaire (%)**
SE.TER.ENRL	Tertiary	Tertiary	**Inscription tertiaire (%)**
SE.SEC.ENRL.TC.ZS	Pupil-teacher ratio in secondary education (headcount basis)	Secondary	**Ratio élèves/professeur secondaire**
UIS.PTRHC.56	Pupil-teacher ratio in tertiary education (headcount basis)	Teachers	**Ratio élèves/professeur tertiaire**
NY.GDP.PCAP.CD	GDP per capita (current US$)	Economic Policy	**PIB par habitant ($)**
NY.GDP.MKTP.CD		Economic Policy	**PIB total ($)**
SE.XPD.TOTL.GD.ZS	Government expenditure on education as % of GDP (%)	Expenditures	**Dépenses éducation (% PIB)**
UIS.XSPENDP.2.FDPUB.FNCUR	Current expenditure as % of total expenditure in lower secondary public institutions (%)	Expenditures	**Dépenses courantes secondaire (%)**
UIS.XSPENDP.56.FDPUB.FNCUR	Current expenditure as % of total expenditure in tertiary public institutions (%)	Expenditures	**Dépenses courantes tertiaire (%)**
SP.POP.TOTL	Population, total	Health: Population: Structure	**Population totale**
SP.POP.1564.TO.ZS	Population ages 15-64 (% of total)	Health: Population: Structure	**Population 15-64 ans (%)**
SP.POP.GROW	Population growth (annual %)	Health: Population: Dynamics	**Croissance population (%)**

+ Une variable zones à risques

5.L’étude des variables Séléctionnées

5.1-Information complémentaire sur la variable zone a risque.

Il ressort de l’étude de la base de données principale que 242 pays sont présent dans l’analyse sur les 10 années sélectionné et que 75 d’entre eux ne figure pas dans les études de projection de recensement effectué après 2026 dont une étude est entièrement consacrée dans le fichier index **df-notes.**

Après appondissent **ces pays** ont des caractéristiques particulières : micro-États, territoires dépendants (non-souverains), ou pays en forte instabilité politique, pour lesquels des projections démographiques fiables sont plus difficiles à établir.

Ces données regroupées ne périmètre doivent être valide, c’est-à-dire avoir un volume de donnée au dessus des 75% et couvrir un secteur temps qui est une représentation objective en rapport au développent d’une **start up dans le Ed tech**.

Ces variables vont alors **s’intégrées dans la vision métier de l’entreprise**.

5.2-J'analyse du taux de remplissage des variables sélectionnées et leur pertinence pour une **start up de Ed tech**.

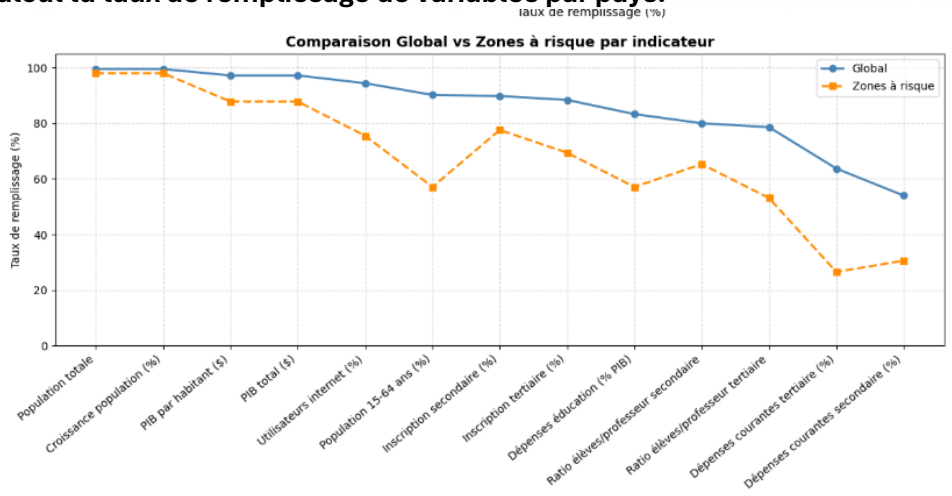
5.2.1 les indicateurs

Observation : Je vais prendre en considération le taux de remplissage des variables

Calcul du taux de remplissage des variables

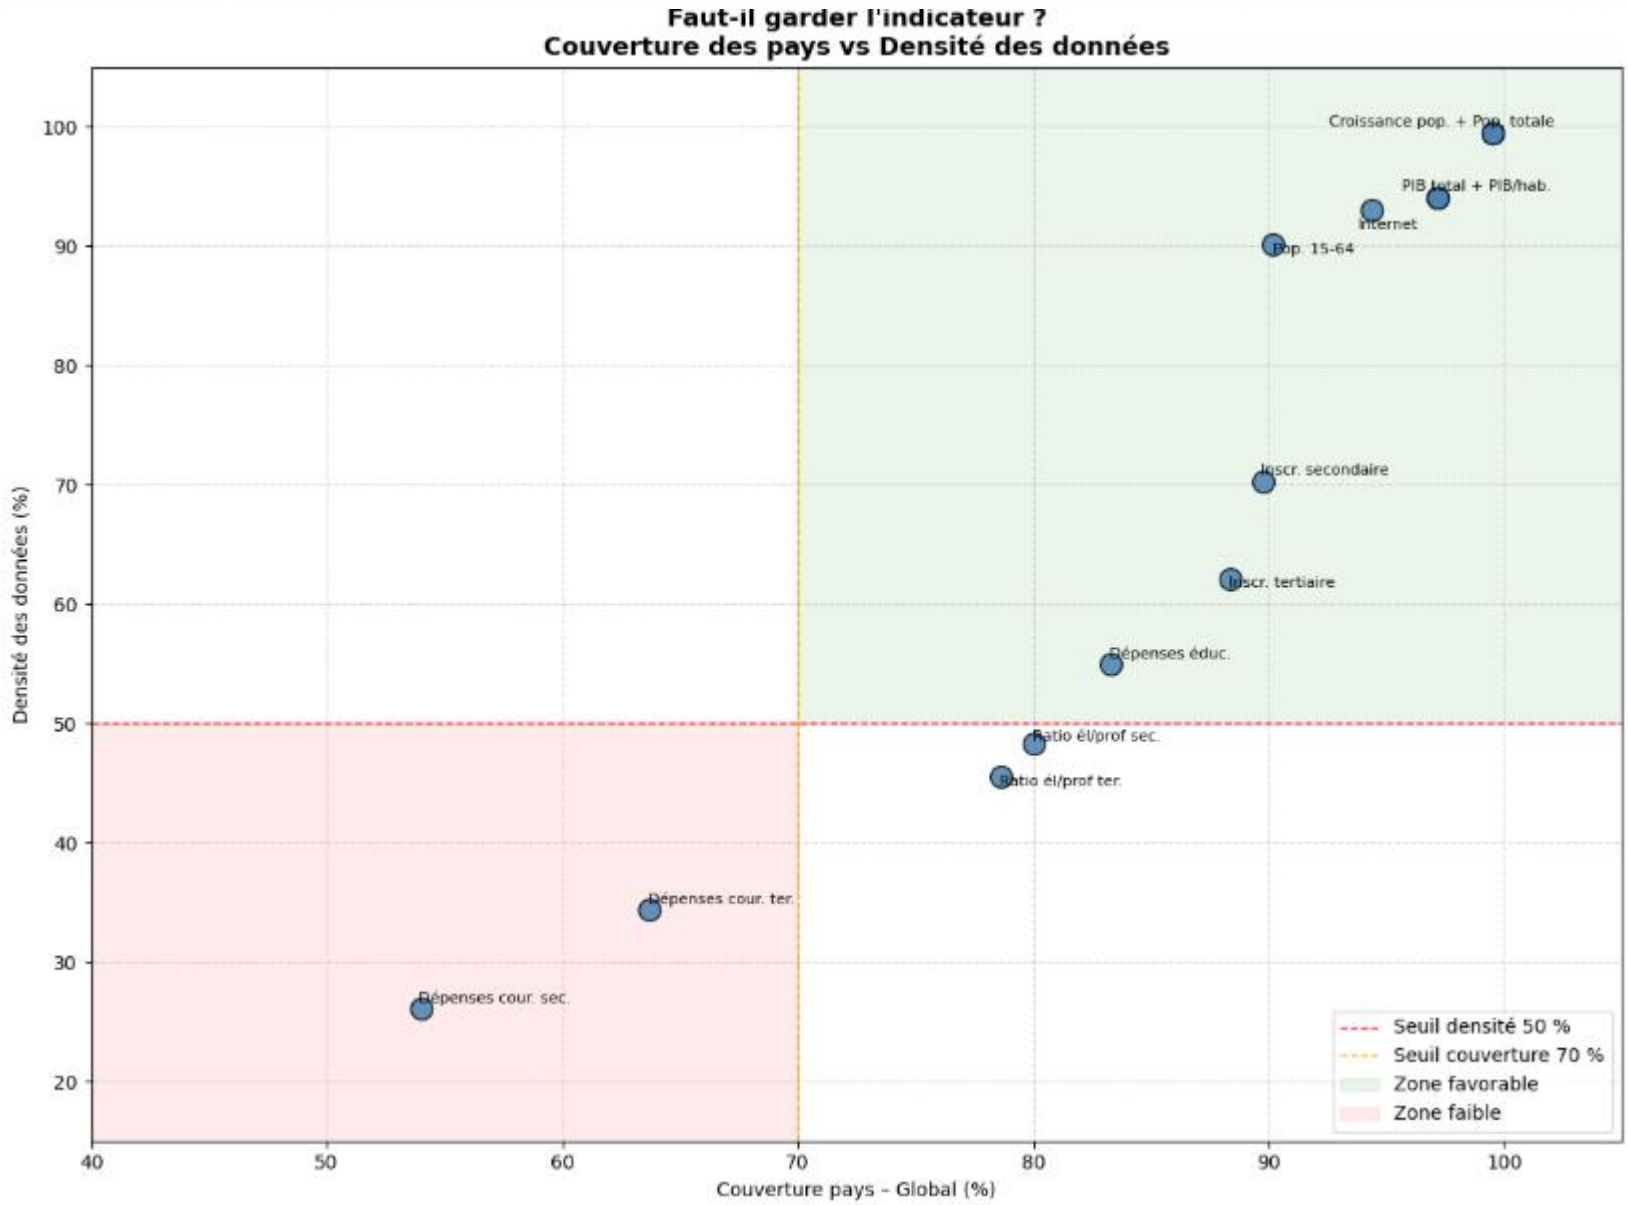
	Variable	Densité cellules (%)	Taux global (%)	Taux zones à risque (%)
1	Croissance population (%)	99.4	99.5	98.0
2	Population totale	99.4	99.5	98.0
3	PIB total ($)	94.1	97.2	87.8
4	PIB par habitant ($)	94.1	97.2	87.8
5	Utilisateurs internet (%)	93.0	94.4	75.5
6	Population 15-64 ans (%)	90.1	90.2	57.1
7	Inscription secondaire (%)	70.2	89.8	77.6
8	Inscription tertiaire (%)	62.1	88.4	69.4
9	Dépenses éducation (% PIB)	55.0	83.3	57.1
10	Ratio élèves/professeur secondaire	48.3	80.0	65.3
11	Ratio élèves/professeur tertiaire	45.5	78.6	53.1
12	Dépenses courantes tertiaire (%)	34.4	63.7	26.5
13	Dépenses courantes secondaire (%)	26.1	54.0	30.6

Calcul tu taux de remplissage de variables par pays.



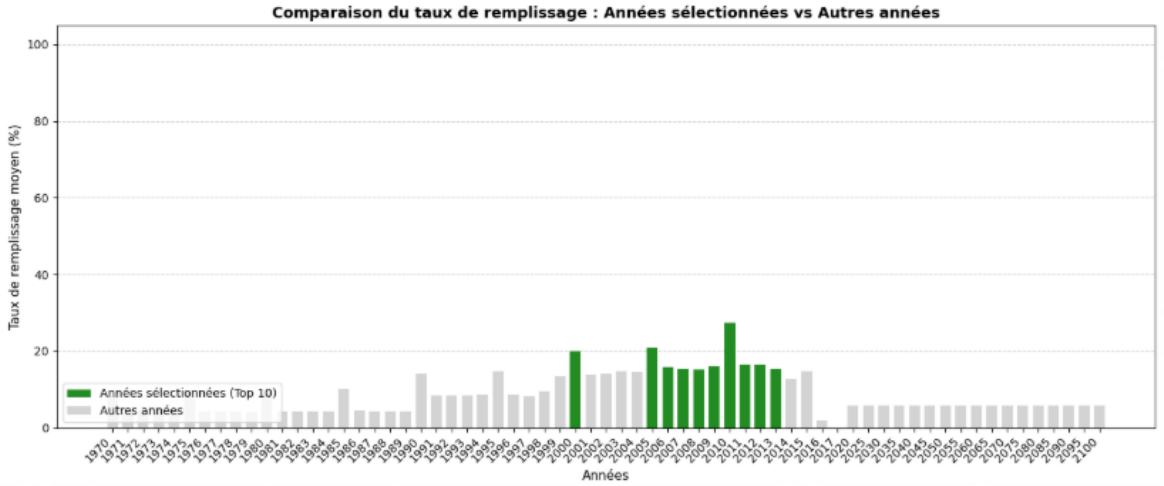
ays.

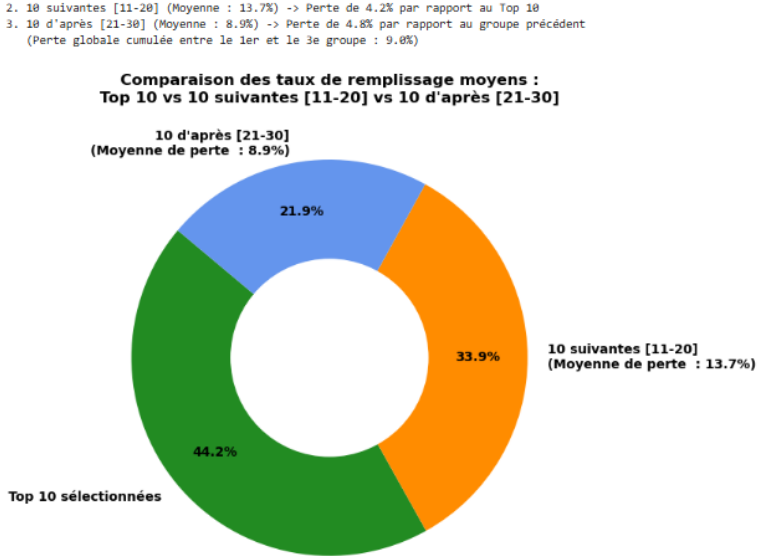
Bilan global du remplissage des indicateurs :



5.2.2 La variable temps

L'analyse de l'indicateur temps pour une stat up dans a Ed Tech révèle que **les années les plus productives** en termes de recensement sont: ['2000', '2005', '2006', '2007', '2008', '2009', '2010', '2011', '2012', '2013']



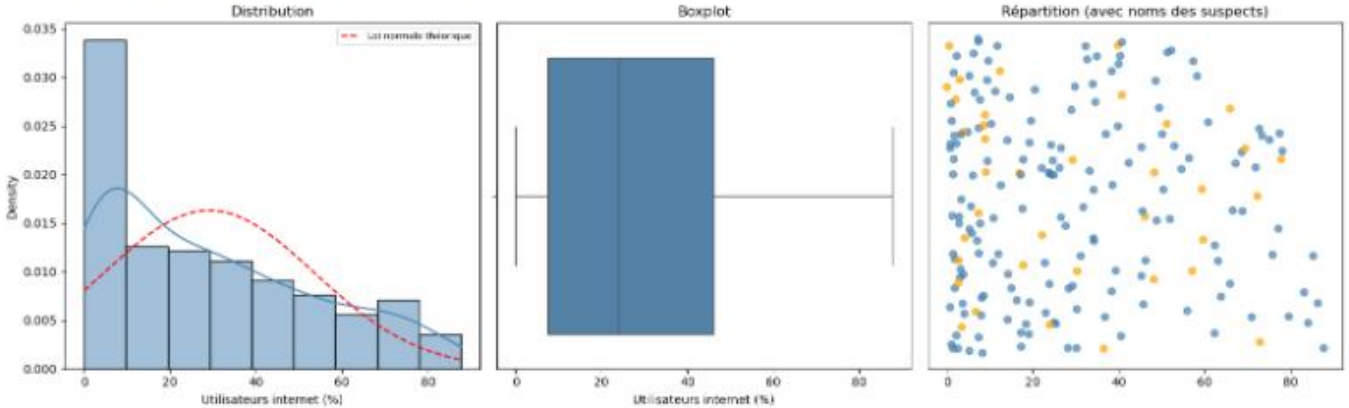


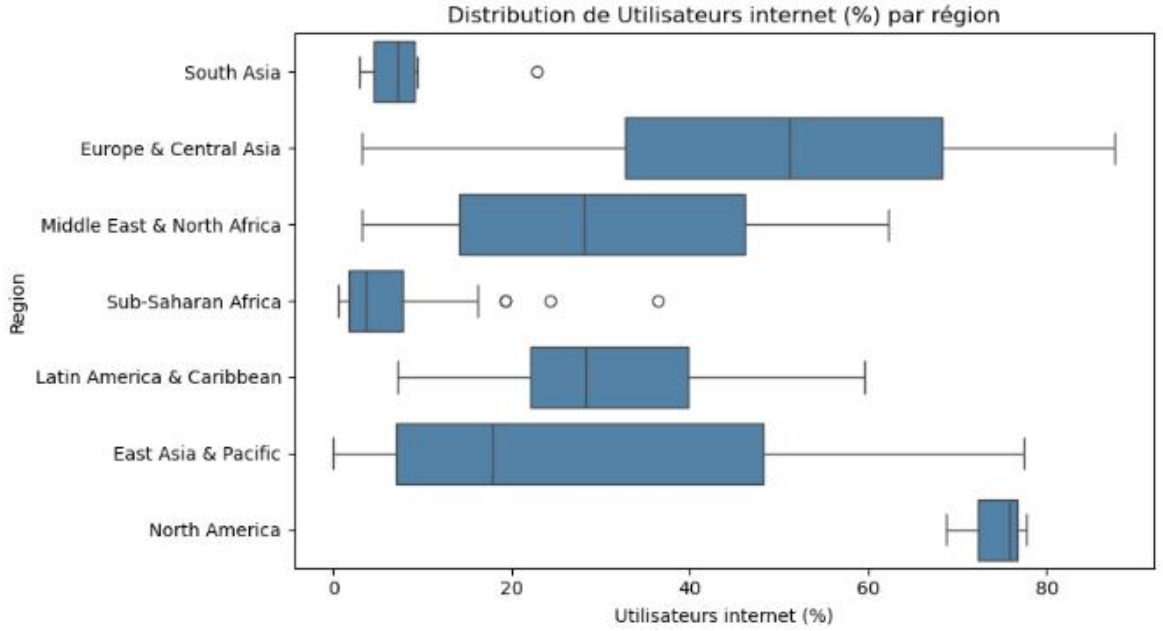
5.3-Detecter des outliers

Je vérifie pour chaque variable que les pays qui se démarquent largement de la tendance globale correspondent à des mesures réelles ne soient pas des erreurs de notations.

L'exemple ci-dessous illustre l'analyse de la variable « Utilisateurs d'Internet pour 100 habitants » 0 suspects sont à vérifier manuellement (moyenne sur la période)

```
--- Utilisateurs internet (%) — Moyenne sur la période ---
203 pays | bornes IQR : [0.0 ; 100.0] | 0 suspects détectés
L'écart interquartile de cette variable est de 38.78.
```

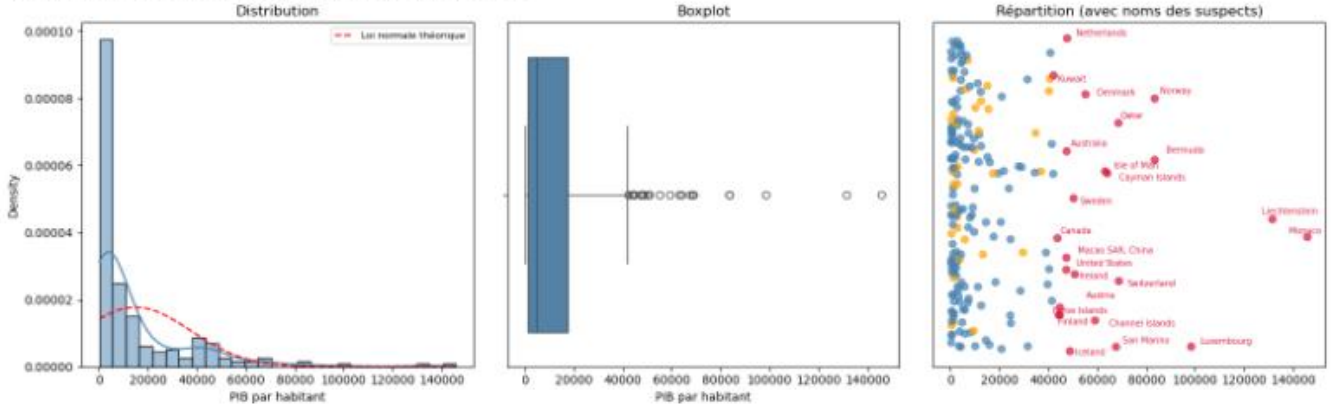


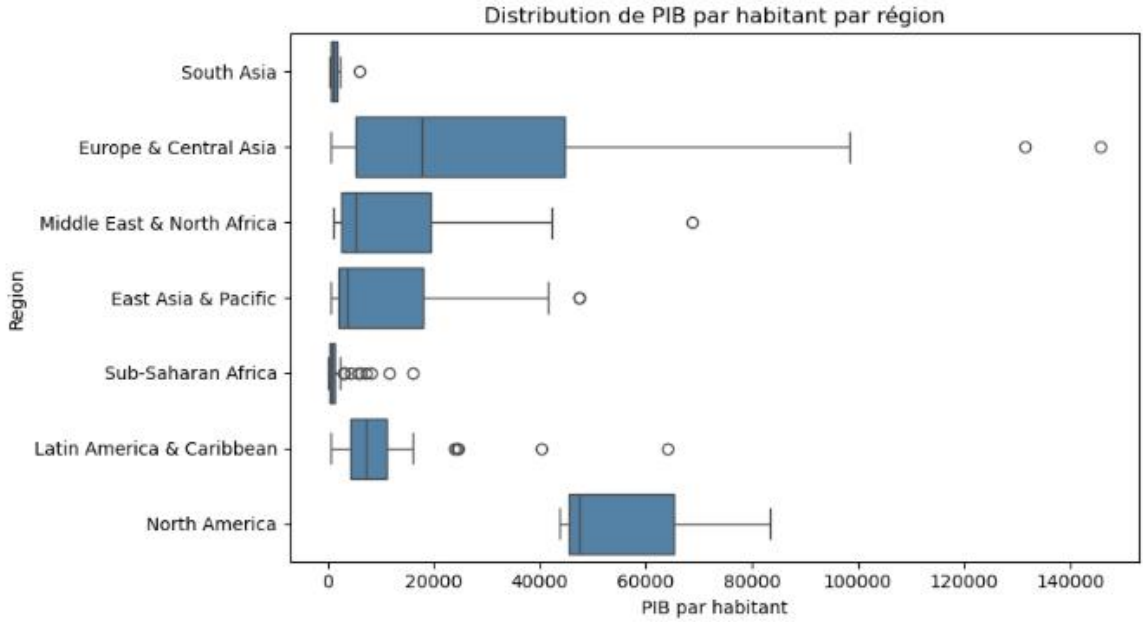



```
Aucun outlier détecté.
```

Concernant le **PIB par habitant**, l'analyse montre que les pays identifiés comme des valeurs atypiques (ou *outliers* statistiques) par la méthode des quartiles correspondent en réalité à des **réalités économiques fondées** (telles que de très riches micro-états ou des économies pétrolières), et non à des erreurs de saisie ou à des anomalies de données, je peux donc les conserver.

```
--- PIB par habitant — Moyenne sur la période ---
209 pays | bornes IQR : [0.0 ; 42,046.0] | 24 suspects détectés
L'écart interquartile de cette variable est de 16262.19.
```



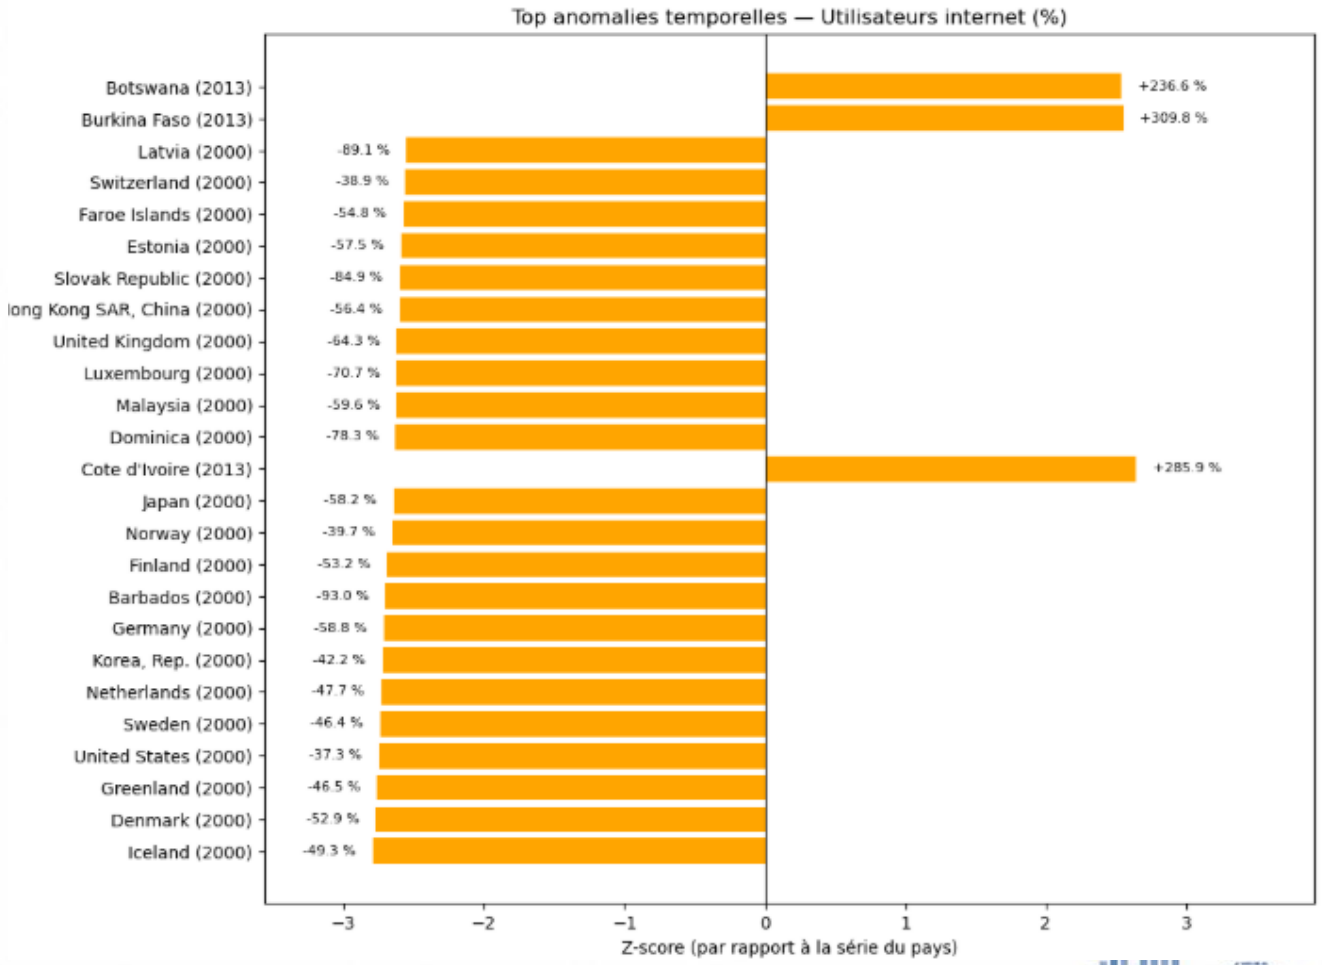



```
--- 24 pays à vérifier ---
```

5.4 -Détecter les oublier, autre approche.

Une autre approche consiste à calculer le z-score de chaque valeur par rapport à la série historique du pays, puis à analyser les observations qui présentent un z-score particulièrement élevé. Ainsi, chaque valeur d'indicateur est comparée à l'ensemble des valeurs historiques du pays. (/ ! \ a la vue du graphique ci-dessous il est pertinent que En 2013 le Botswana est fait un bon de % d'utilisation de la technologie de +236 % pour l'exemple.

Il convient alors d'analyser la cohérence des données à la vue de chaque indicateur et si une incohérence est détecté d'analysé en plus en détails.



6.Consolider un nouveau DataFrame

Après avoir rassembler tous nos indicateurs dans plusieurs variables symbolisées et testé les outliers nous créons un nouveau fichier d'étude afin de pouvoir travailler en se libérant du le fichier data set principal.

Cela permet de :

-Alléger le dataset principal

-Travailler plus facilement et plus rapidement

-Garder le fichier original intact

-Avoir un fichier prêt pour l'analyse.

7.Analyse des corrélations et calcul du score

7.1 Explication de la matrix de corrélation.

Maintenant que nous disposons d'un fichier contenant uniquement les variables qui nous intéressent, nous pouvons les croiser afin de les étudier.

Ces croisements d'informations permettent de vérifier si une variable en influence une autre, et ainsi d'alléger le poids de certaines variables dans le calcul global du score.

En effet, dans les exemples graphiques de la page suivante, on observe clairement à quel point la population totale influence les taux d'inscription dans le secondaire et le tertiaire au fil des années.

Noter un pays à la fois sur ces deux taux d'inscription et sur sa population lui donnerait donc un poids excessif et augmenterait artificiellement ses chances d'arriver en tête du classement.

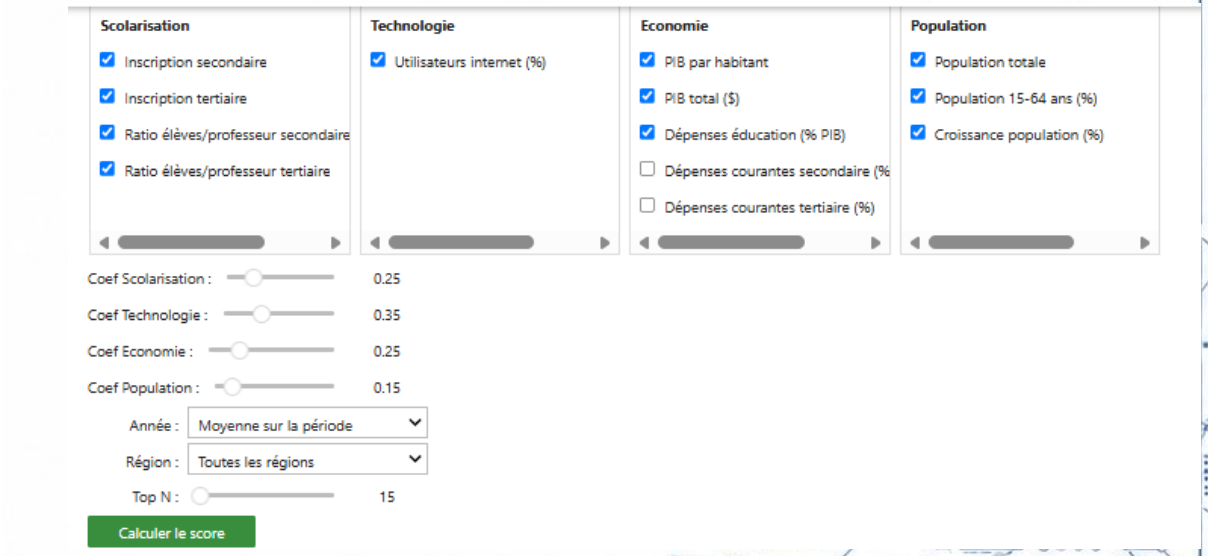
7.2 Explication du besoin de pondération.

Pour Éviter le biais de taille (redondance statistique) : La matrice montre une corrélation quasi parfaite (r = 0,98) entre la *Population totale* et les *Inscriptions secondaire et tertiaire*. Si l'on ne pondère pas le calcul du score, les pays les plus peuplés se retrouvent surreprésentés et avantagés mécaniquement, car la taille démographique pèse trois fois (une fois dans la catégorie Population et deux fois à travers les volumes scolaires).

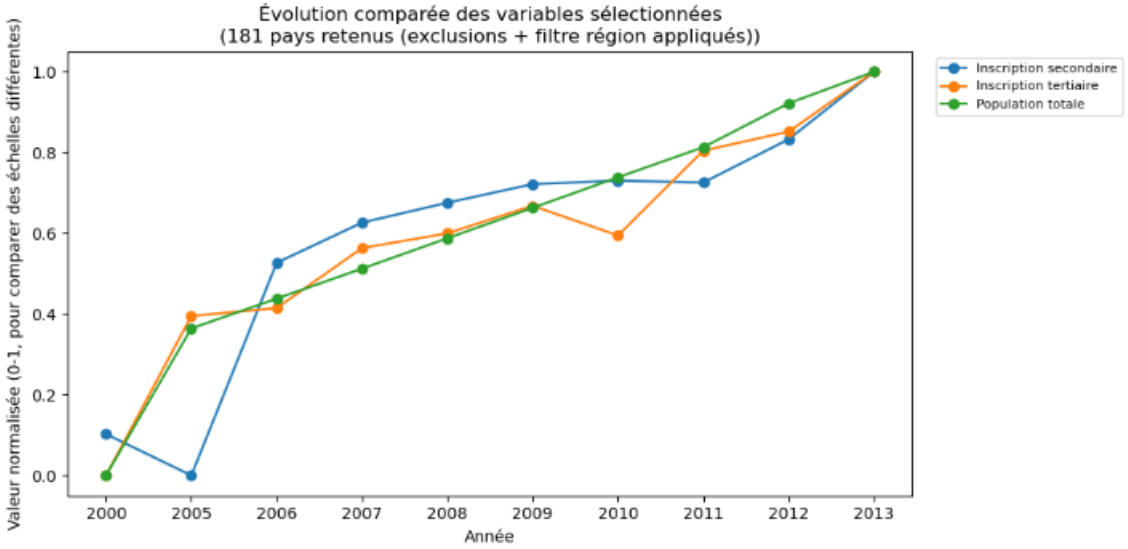
Nous devons donc mettre en place un système de **coefficients de pondération** attribués à chaque variable, regroupées par secteur (Scolarisation, Technologie, Économie, Population)

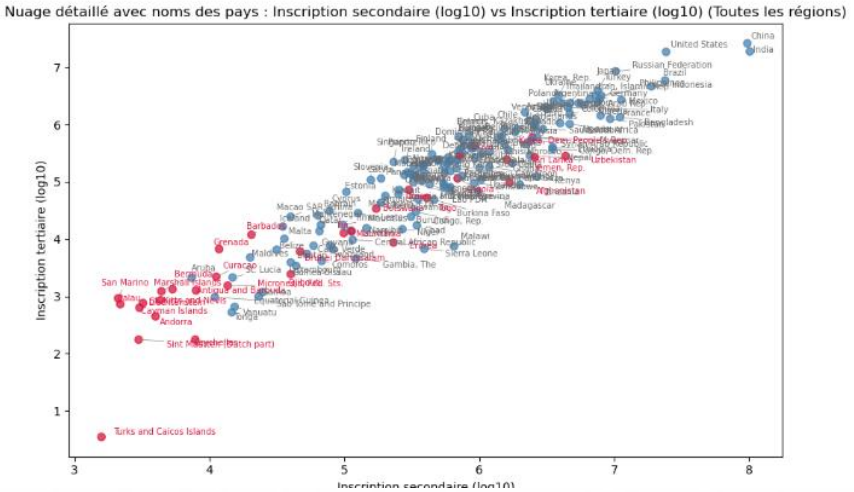
Equilibrer le poids des catégories : Les catégories ne contiennent pas toutes le même nombre d'indicateurs (par exemple, la technologie ne compte qu'un seul indicateur contre plusieurs pour l'économie ou la population). Sans pondération manuelle, l'algorithme accorderait un poids artificiellement trop lourd aux blocs les plus fournis.

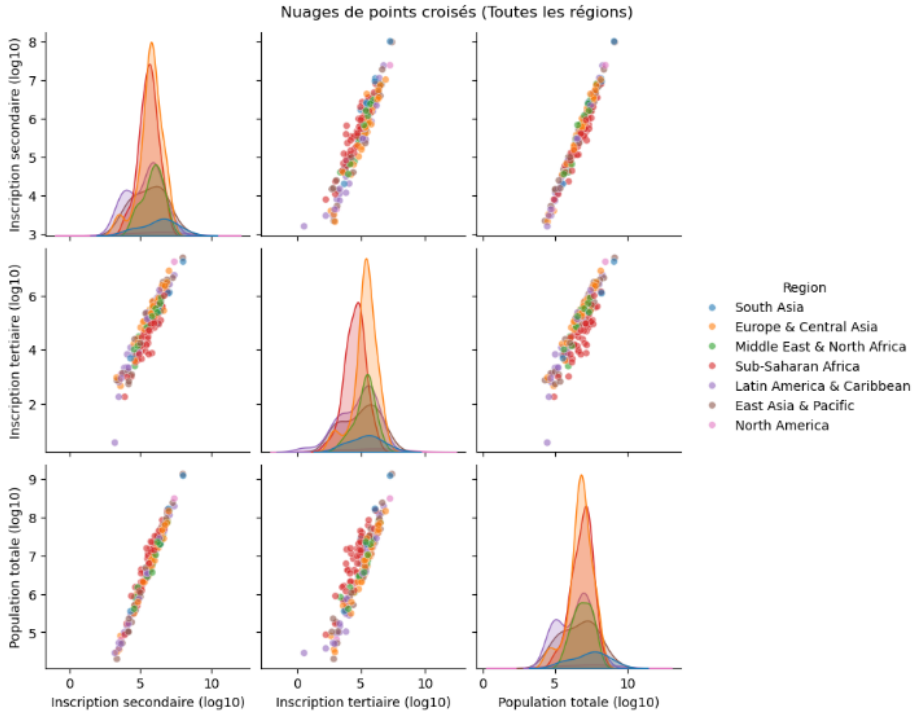
Neutraliser la multicolinéarité : Par exemple, le fait que des variables comme le PIB par habitant et le taux d'utilisateurs internet soient très fortement corrélées (r = 0.89) signifie qu'elles mesurent en grande partie la même réalité de développement. La pondération permet de modérer l'impact de ce "bloc" pour qu'il n'écrase pas les autres dimensions du score.



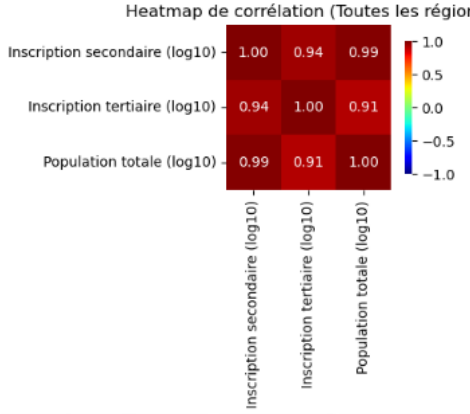
7.2 Exemple analyse de corrélation statistique.







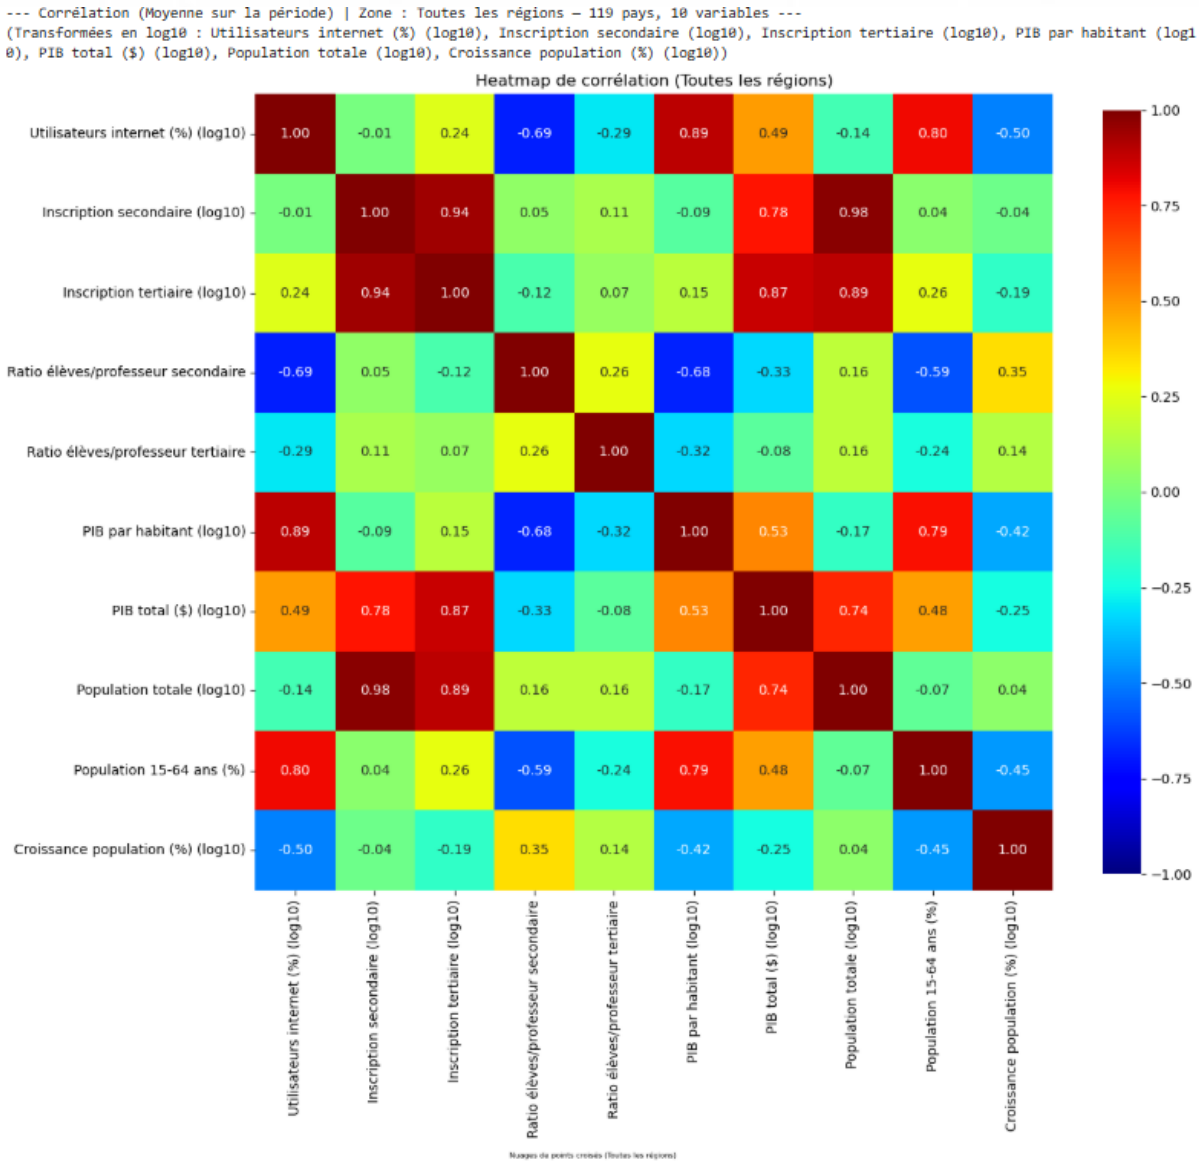

```
--- Corrélation (Moyenne sur la période) | Zone : Toutes les régions — 181 pays, 3 variables ---
(Transformées en log10 : Inscription secondaire (log10), Inscription tertiaire (log10), Population totale (log10))
```



Matrice de corrélation de l'ensemble des variables:

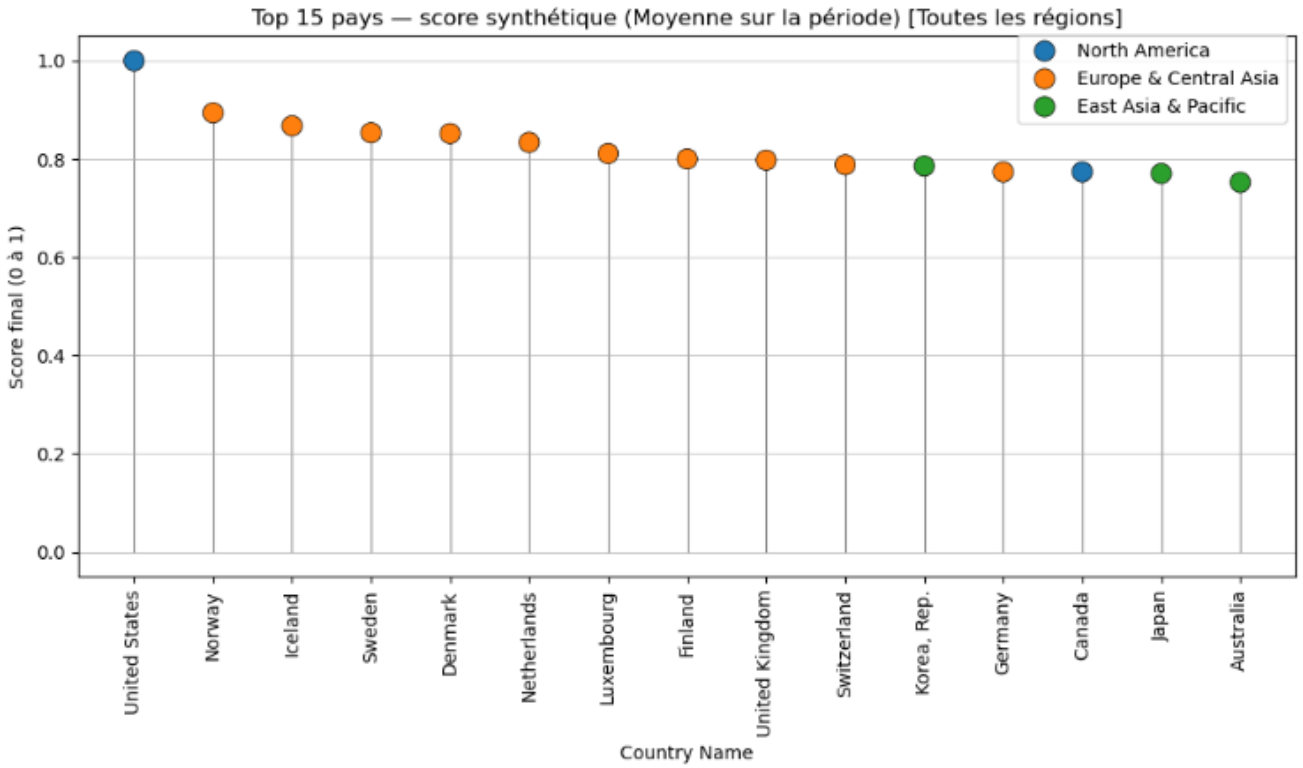
Lien Education → Démographie : On observe une corrélation quasi parfaite entre l'*Inscription secondaire* et la *Population totale* (0.89), ainsi qu'avec l'*Inscription tertiaire* (0.89).
Interprétation *:* Les pays les plus peuplés ont mécaniquement les plus grands volumes bruts d'inscrits à l'école. C'est un effet de taille structurel.
Lien Technologie→ Démographie : (r = -0.69) : Plus le taux d'utilisateurs internet est élevé, plus le ratio élèves/professeur dans le secondaire est bas.
Interprétation : Les pays développés disposent de meilleures infrastructures technologiques et de classes moins surchargées, contrairement aux pays en développement.
Lien Economie → Technologie : La croissance de la population est négativement corrélée au taux d'utilisateurs internet (r = -0.50) et au PIB par habitant (r = -0.42)
Interprétation *:* Les pays ayant une forte croissance démographique (souvent en développement) peinent à afficher des niveaux de PIB par habitant et d'équipement numérique élevés.

Conclusion : La matrice de corrélation met en évidence une forte colinéarité entre la taille de la population et les volumes d'inscription (r = 0.98), confirmant la nécessité de pondérer ces variables pour éviter un biais de taille. Par ailleurs, elle valide un bloc de développement homogène liant fortement le PIB par habitant et la connectivité numérique (r = 0.89), confirmant la pertinence de nos grands axes d'analyse.



8 .Liste des 15 pays retenus

United States, Norway, Iceland, Sweden, Denmark, Netherlands, Luxembourg, Finland, United Kingdom, Switzerland, Korea (Rep.), Germany, Canada, Japan et Australia.



--- Score synthétique (Moyenne sur la période) | Zone : Toutes les régions — pondération : SCOLARISATION=0.25, TECHNOLOGIE=0.35, ECONOMIE=0.25, POPULATION=0.15 (normalisée sur 1.00) ---

NB : Mécaniquement aucun pays à risque ne fait partie de la liste car le score de pondération empêche le trop fort poids d'une valeur au grès d'une autre.

Pourquoi la liste de ces pays et un calcul fait sur l'ensemble des indicateur retenus ?

« Une nuance analytique importante : L'absence de données vs l'absence de réalité mesurée »

Dans les bases de données internationales comme celle de la Banque Mondiale, une valeur manquante (NaN) ne traduit pas toujours une défaillance dans la collecte ou un oubli de transmission. Elle peut refléter une **réalité structurelle** propre au pays :

Par exemple, un petit État insulaire ou un territoire spécifique peut ne pas posséder d'enseignement supérieur de type *tertiaire* sur son sol, rendant les indicateurs associés (comme les dépenses courantes tertiaires) inapplicables.

Voici un exemple de liste de pays non sélectionné qui apparaissent en retirant les valeur dépense éducatives et en ajustant le calcul de coefficient en réponse.

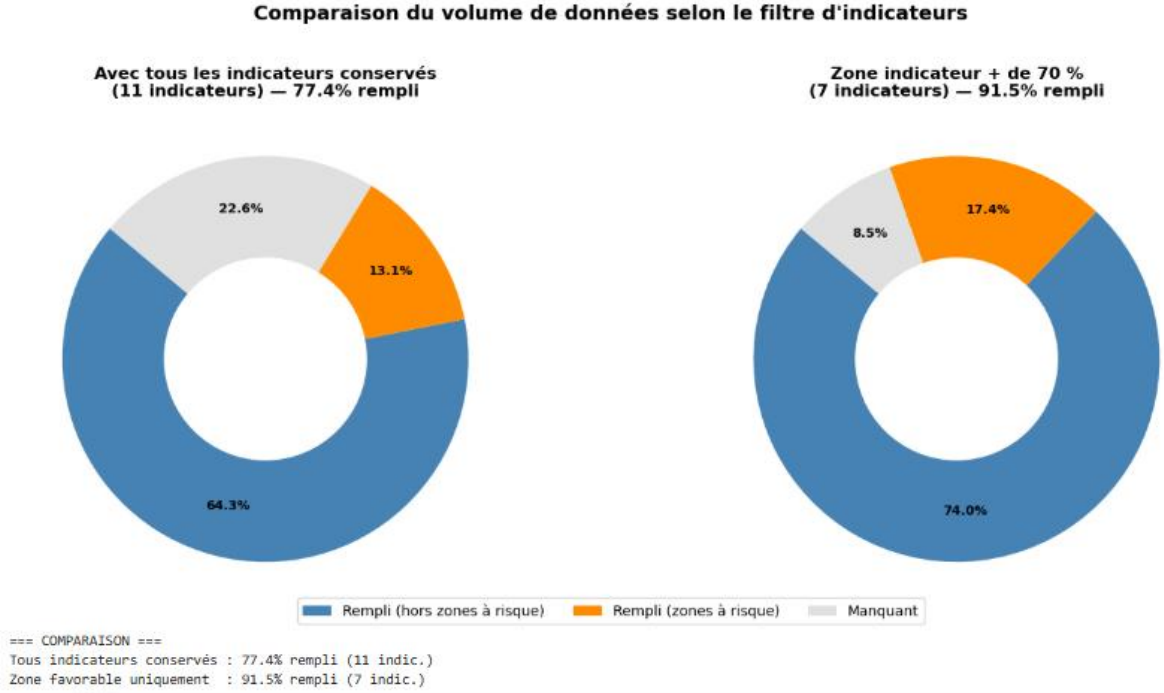
--- Score synthétique (moyenne des années 2000, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013) | Zone : Toutes les régions — pondération : SCOLARISATION=0.20, TECHNOLOGIE=0.35, ECONOMIE=0.25, POPULATION=0.20 (normalisée sur 1.00) ---

	Country Name	SCORE_SYNT	Region
1	United States	1.000000	North America
2	Norway	0.783563	Europe & Central Asia
3	China	0.782001	East Asia & Pacific
4	Luxembourg	0.755529	Europe & Central Asia
5	Iceland	0.738054	Europe & Central Asia
6	Japan	0.729376	East Asia & Pacific
7	Netherlands	0.726312	Europe & Central Asia
8	Sweden	0.725731	Europe & Central Asia
9	Denmark	0.714122	Europe & Central Asia
10	**Monaco (zone à risque)**	**0.711594**	**Europe & Central Asia**
11	Switzerland	0.709313	Europe & Central Asia
12	United Kingdom	0.702599	Europe & Central Asia
13	Germany	0.702335	Europe & Central Asia
14	**Liechtenstein (zone à risque)**	**0.701999**	**Europe & Central Asia**
15	Canada	0.694066	North America

9.Conclusion

9.1 Les données

1- **Le fichier de variables consolidées** comporte **taux de remplissage global de variables de 77,4 %**, en partant d'un fichier de base **df-data** avec 86% de données manquantes, je décide alors de conserver tous les indicateurs ayant ainsi 77.4% de données exploitables dont 13,1% sont des pays faisant partie d'une zone sensible et tagguer comme à risque.



2- **L'indicateur technologique** disponible pour évaluer le potentiel de la EdTech est le **« taux d'utilisateurs Internet (% de la population) »,** issu des données de l'Union internationale des télécommunications (UIT). Cependant, cet indicateur est pertinent car il définit l'usage d'internet toute technologies confondues mais présente des limites temporelles, les données s'arrêtent généralement en 2013, et ne reflète pas l'accélération fulgurante des nouvelles technologies

9.2 Recommandation

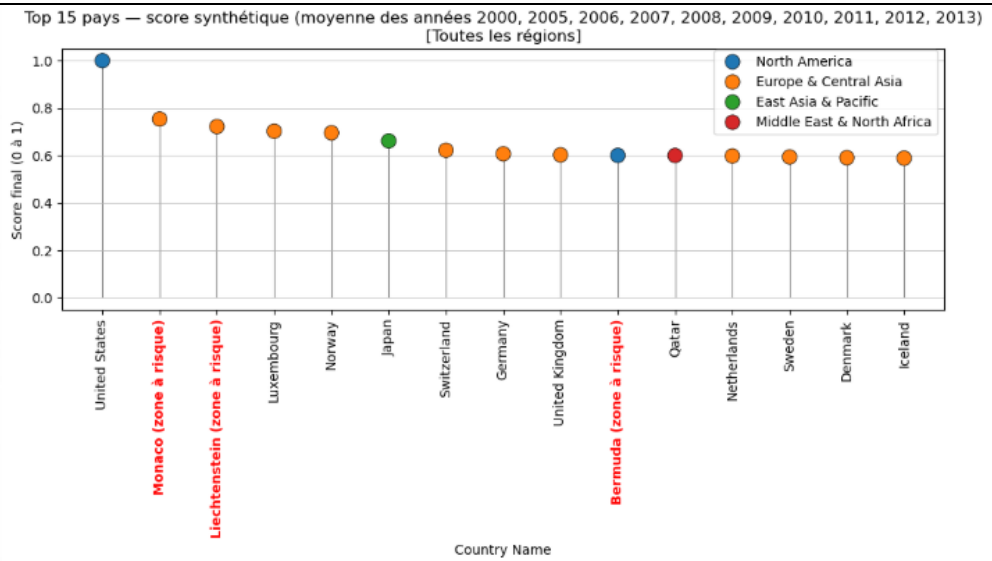
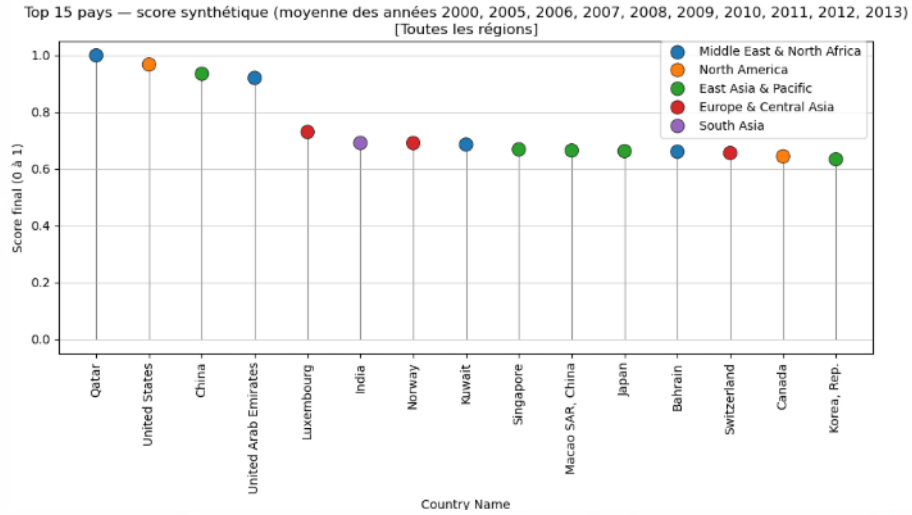
9.2.1-**Traitement des zones à risque :**

Lors du calcul du score, une couleur rouge apparaît sur les pays présentant des risques élevés et qui ne figurent pas dans le Top 15.

Par exemple, certains sont des micro-États très riches, mais moins développés sur d'autres aspects tels que la scolarité.

Réajuster mécaniquement les coefficients utilisés dans le calcul ferait apparaître certains de ces pays. Il convient alors soit d'établir une phase 2 d'exploration des données, en combinant cette analyse quantitative (phase 1) avec une analyse qualitative (en allant chercher d'autres indicateurs auprès d'autres sources), soit de déterminer si les données actuelles sont suffisantes.

Voici les résultats si nous survalorisons le coefficient **économique** ou celui de la **population**.

Economique --- Score synthétique (moyenne des années 2000, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013) | Zone : Toutes les régions — pondération : SCOLARISATION=0.10, TECHNOLOGIE=0.20, ECONOMIE=0.45, POPULATION=0.15 (normalisée sur 0.90) ---	**Population** --- Score synthétique (moyenne des années 2000, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013) | Zone : Toutes les régions — pondération : SCOLARISATION=0.10, TECHNOLOGIE=0.20, ECONOMIE=0.45, POPULATION=0.85 (normalisée sur 1.60) ---
	
United States, Monaco (zone à risque), Liechtenstein (zone à risque), Luxembourg, Norway, Japan, Switzerland, Germany, United Kingdom, Bermuda (zone à risque), Qatar, Netherlands, Sweden, Denmark, Iceland	Qatar, United States, China, United Arab Emirates, Luxembourg, India, Norway, Kuwait, Singapore, Macao SAR (China), Japan, Bahrain, Switzerland, Canada, Korea (Rep.)

9.2.2-**Traitement des pays ayant des données de projections après 2026**

Puisque certains pays disposent de données de projection enregistrées après 2026, nous pouvons, afin d'améliorer notre étude, ajouter une variable qui regroupe ces pays, afin d'identifier ceux qui sont les plus prometteurs.

Dans tous les cas, nous basons le calcul du score sur une approche mécanique des différentes variables, à travers des coefficients de pondération par secteur.

Dans ce cas soit nous ajoutons un nouveau secteur afin de temporiser le score final de pondération exemple : Technologique, Population, Scolarité, Economique et **Projeter** soit nous ajouton un bonus ou non aux pays concernés.

. **Recommandations stratégiques :**

Approche itérative (Phase 1) : Il est recommandé de considérer cette analyse quantitative comme une première étape exploratoire (Phase 1).

Une modification des pondérations ou des indicateurs permettrait d'intégrer des marchés plus risqués mais potentiellement à fort rendement.

Affinement qualitatif : Pour aller plus loin, il convient de cibler un pays à fort potentiel identifié par le modèle, puis de collecter des indicateurs de terrain (auprès de sources locales ou sectorielles) afin d'affiner l'évaluation du risque et de valider l'opportunité d'investissement

En conclusion : Le nettoyage des données et les pondérations mathématiques offrent une rigueur statistique indéniable pour une première étude quantitative. Bien que l'analyse métier s'avère perfectible en l'état les indicateurs macro-économiques et technologiques globaux parviennent a dégager une première approche statistique quantitative. Cette approche constitue une base solide (Phase 1) pour un niveau de risque minimisé.

Mais selon le niveau de risque voulu elle rend indispensable un complément d'analyse qualitative, notamment en raison de l’absence de données contextuelles granulaires, de la complexité des écosystèmes locaux.

C'est cette combinaison entre rigueur quantitative et finesse qualitative qui permettra de sécuriser les décisions d'investissement futurs sur des pays plus discret aux extensions de recensement.

Y compris sur des marchés présentant des limites de recensement, afin de capturer au mieux la réalité de terrain des marchés émergents et de la EdTech.