Classifiez automatiquement des informations

Projet : Le département RH de l'entreprise **TechNova** veut identifier les causes racines potentielles derrière les démissions de ces employés.

Objectif : Prédire le taux d'attrition du personnel de l'entreprise.

Index

1.Présentations

1.1 1 L'entreprise

1.2 La mission

2. Exploration

2.1 Vue tabulaire des DataFrames

2.2 Vues graphiques des DataFrames

2.3 Analyse du remplissage des DataFrames

3. Nettoyage de la donnée et consolidation d'un nouveau Dataframe

3.1 Traitement des colonnes constante, Nan, cellule vide ou avec des erreurs de saisies

4. L'hypothèse

4.1 Analyse des corrélations avec Y dans le but de créer de nouvelles features

4.2 Analyse des formes et mouvements de la distribution des variables vers Y

5. Liste de nouvelles features

5.1 Création et classification de nouvelles features

5.2 Analyse des nouvelles features

6. Sélection des features pertinentes

6.1 Panneau de sélection des features

7. Découpage Train/Test et stratification

7.1 Cross Validation et Train/Test

7.2 Stratification du jeu de données

8. Préprocesseur

8.1 5 portes, zéro fuite

9. Modélisation et interprétation

9.1 Comparer le ROC-AUC : plis d'apprentissage vs plis de validation (CV)

9.2 Comparer les résultats CV/Train/Test

10. Fine-tunning

10.1 Choix d'un modèle et optimisations

10.2 Optimisation du seuil

11. Analyse Shap

11.1 globale

11.1 Locale

11. Conclusion

1. Présentations

1. 1 L’entreprise

L’entreprise ESN TechNova Partners est spécialisée dans le conseil en transformation digitale et la vente d’applications en SaaS.

1.2 La mission

Consultant Data Scientist par le département RH de votre client, il s’agit de l'ESN TechNova Partners, spécialisée dans le conseil en transformation digitale et la vente d’applications en SaaS.
Ils font face à un turnover plus élevé que d'habitude et ils souhaitent identifier les causes racines potentielles derrière ces démissions.

2.Exploration

2.1 Vues tabulaires des DataFrames

```
--- ANALYSE DE SIRH ---
Lignes : 1470 | Colonnes : 12
Répartition des types de colonnes :
int64     8
object    4
Name: count, dtype: int64
------------------------------
```

	id_employee	age	genre	revenu_mensuel	statut_marital	departement	poste	nombre_experiences_precedentes	nombre_heures_travailless	annee_experience_totale	annees_dans_l_entreprise	annees_dans_le_poste_actuel
0	1	41	F	5993	Célibataire	Commercial	Cadre Commercial	8	80	8	6	4
1	2	49	M	5130	Marié(e)	Consulting	Assistant de Direction	1	80	10	10	7
2	4	37	M	2090	Célibataire	Consulting	Consultant	6	80	7	0	0
3	5	33	F	2909	Marié(e)	Consulting	Assistant de Direction	1	80	8	8	7
4	7	27	M	3468	Marié(e)	Consulting	Consultant	9	80	6	2	2

	id_employee	age	genre	revenu_mensuel	statut_marital	departement	poste	nombre_experiences_precedentes	nombre_heures_travailless	annee_experience_totale	annees_dans_l_entreprise	annees_dans_le_poste_actuel
count	1470.000000	1470.000000	1470	1470.000000	1470	1470	1470	1470.000000	1470.0	1470.000000	1470.000000	1470.000000
unique	NaN	NaN	2	NaN	3	3	9	NaN	NaN	NaN	NaN	NaN
top	NaN	NaN	M	NaN	Marié(e)	Consulting	Cadre Commercial	NaN	NaN	NaN	NaN	NaN
freq	NaN	NaN	882	NaN	673	961	326	NaN	NaN	NaN	NaN	NaN
mean	1024.865306	36.923810	NaN	6502.931293	NaN	NaN	NaN	2.693197	80.0	11.279592	7.008163	4.229252
std	602.024335	9.135373	NaN	4707.956783	NaN	NaN	NaN	2.498009	0.0	7.780782	6.126525	3.623137
min	1.000000	18.000000	NaN	1009.000000	NaN	NaN	NaN	0.000000	80.0	0.000000	0.000000	0.000000
25%	491.250000	30.000000	NaN	2911.000000	NaN	NaN	NaN	1.000000	80.0	6.000000	3.000000	2.000000
50%	1020.500000	36.000000	NaN	4919.000000	NaN	NaN	NaN	2.000000	80.0	10.000000	5.000000	3.000000
75%	1555.750000	43.000000	NaN	8379.000000	NaN	NaN	NaN	4.000000	80.0	15.000000	9.000000	7.000000
max	2068.000000	60.000000	NaN	19999.000000	NaN	NaN	NaN	9.000000	80.0	40.000000	40.000000	18.000000

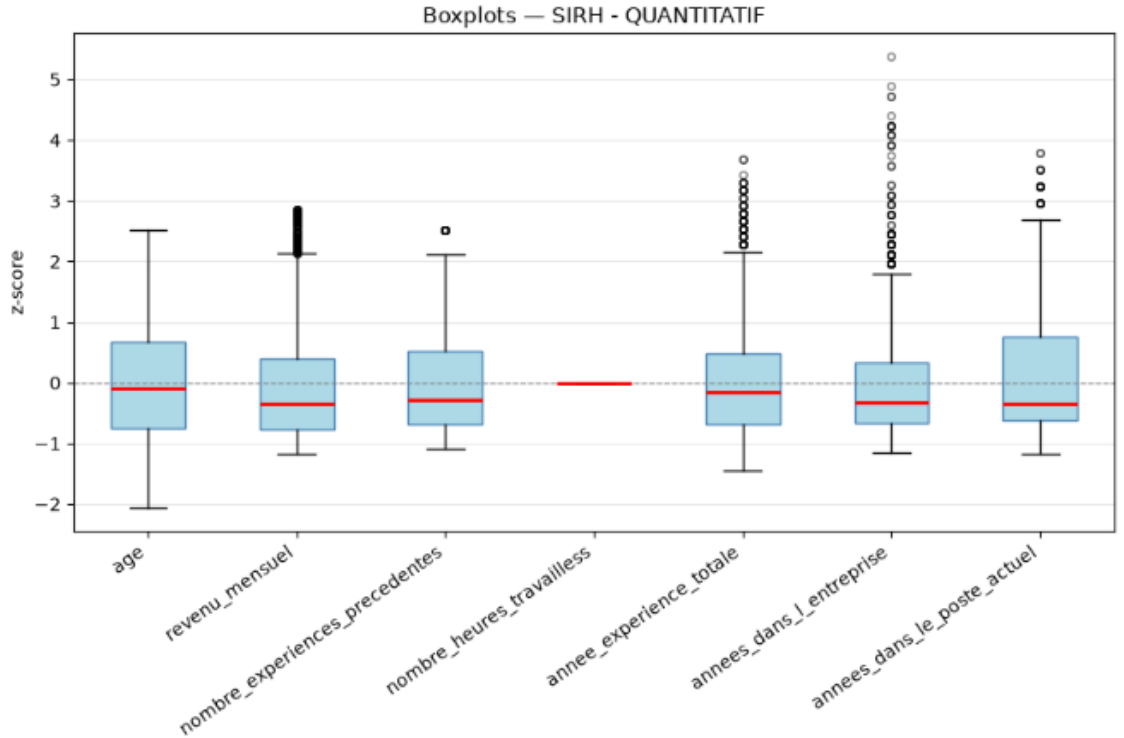
```
Nombre total de lignes dans SIRH : 1470

--- MATRICE DE CORRÉLATION : SIRH ---
• Colonnes numériques utilisées : ['age', 'revenu_mensuel', 'nombre_experiences_precedentes', 'annee_experience_totale', 'annees_dans_l_entreprise', 'annees_dans_le_poste_actuel']
```

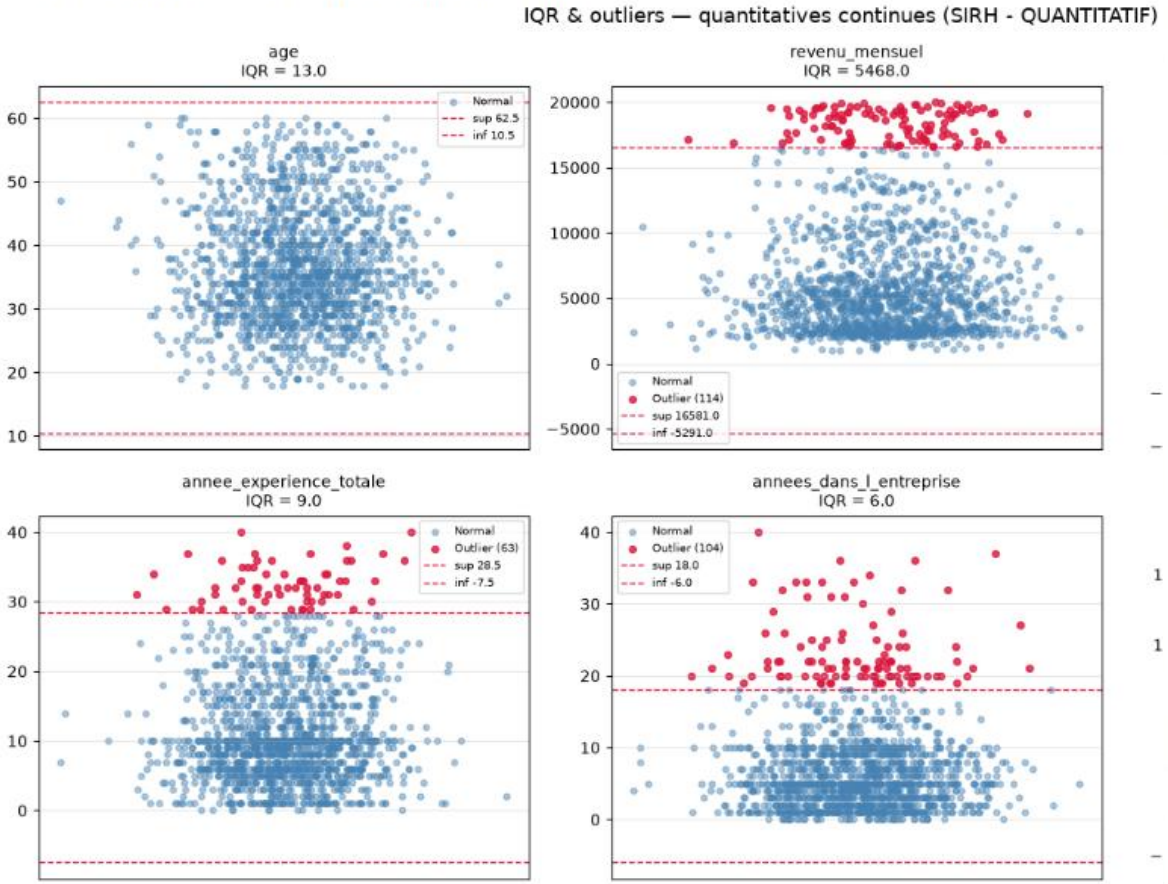
	age	revenu_mensuel	nombre_experiences_precedentes	annee_experience_totale	annees_dans_l_entreprise	annees_dans_le_poste_actuel
age	1.00	0.50	0.30	0.68	0.31	0.21
revenu_mensuel	0.50	1.00	0.15	0.77	0.51	0.36
nombre_experiences_precedentes	0.30	0.15	1.00	0.24	-0.12	-0.09
annee_experience_totale	0.68	0.77	0.24	1.00	0.63	0.46
annees_dans_l_entreprise	0.31	0.51	-0.12	0.63	1.00	0.76
annees_dans_le_poste_actuel	0.21	0.36	-0.09	0.46	0.76	1.00

2.2 Vues graphiques des DataFrames

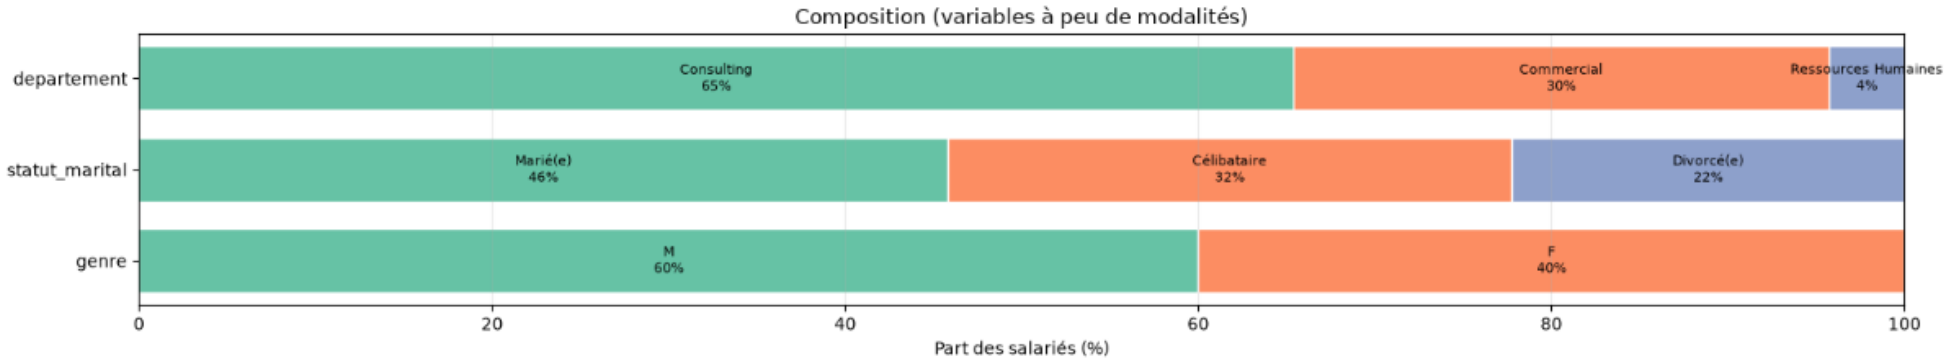
--- Boxplots regroupés : SIRH - QUANTITATIF ---

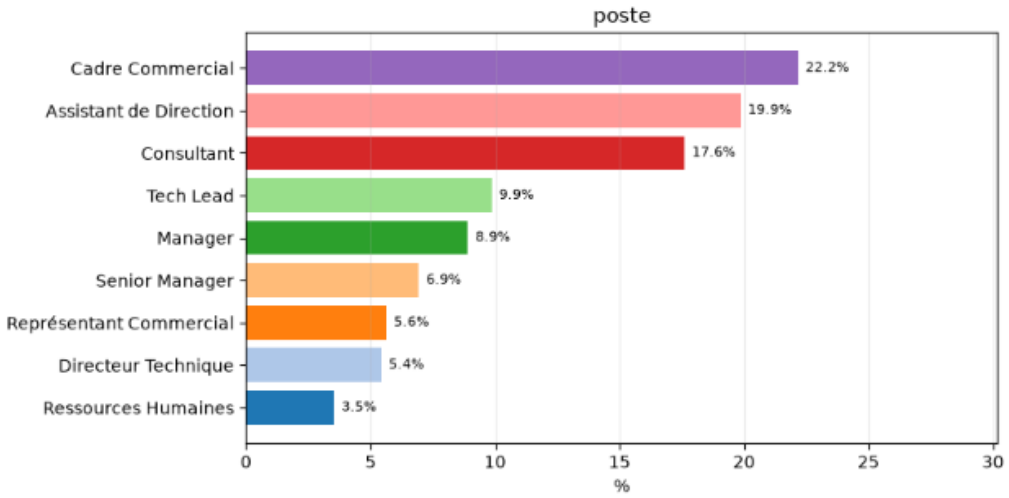


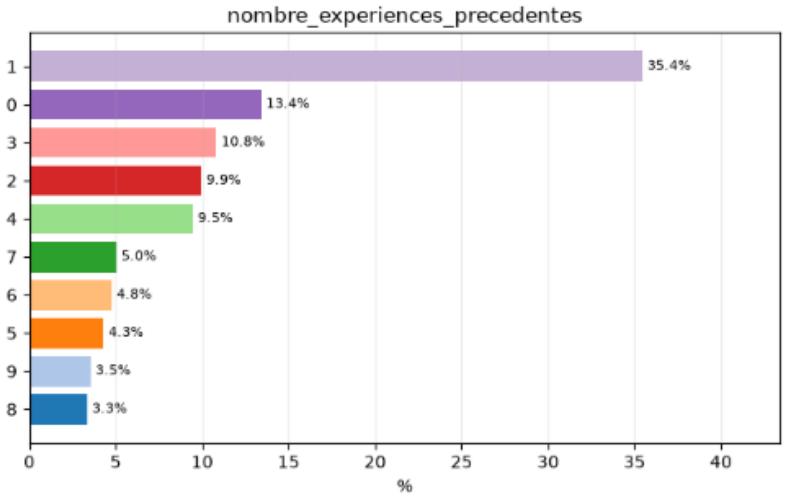
--- IQR / outliers (quantitatives continues seulement) : SIRH - QUANTITATIF ---



Qualitatives — SIRH - QUALITATIF

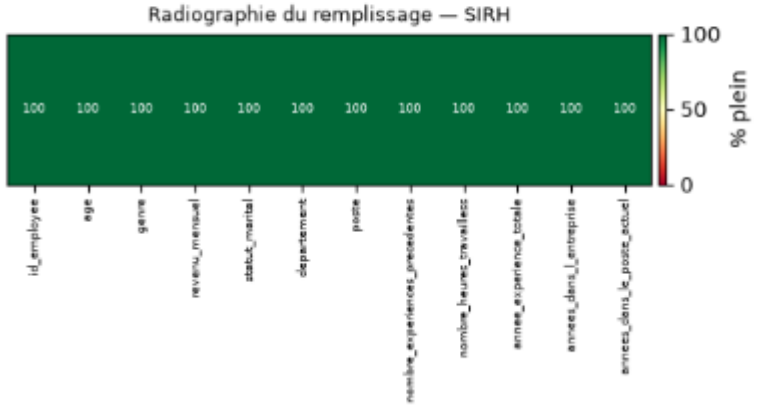




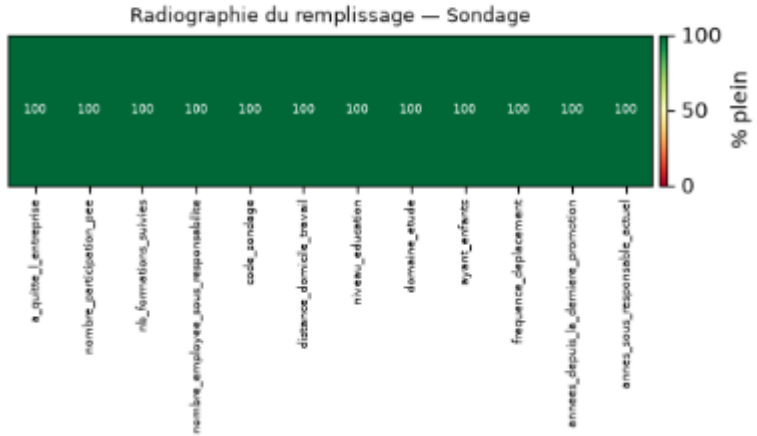


2.3 Analyse du remplissage des DataFrames

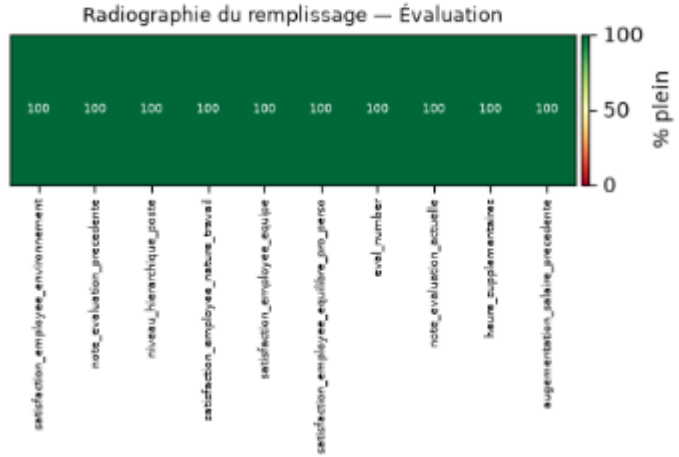
=== TEST DE REMPLISSAGE : SIRH ===
- Lignes : 1470 | Colonnes : 12
- NaN au total : 0 / 17640
- Chaines vides ('') au total : 0 / 17640
- Manquant total (NaN + vides) : 0 / 17640 (0.00%)
- Taux de remplissage global : 100.0%
- Aucune colonne incomplète : toutes les colonnes sont remplies à 100%.



=== TEST DE REMPLISSAGE : Sondage ===
- Lignes : 1470 | Colonnes : 12
- NaN au total : 0 / 17640
- Chaines vides ('') au total : 0 / 17640
- Manquant total (NaN + vides) : 0 / 17640 (0.00%)
- Taux de remplissage global : 100.0%
- Aucune colonne incomplète : toutes les colonnes sont remplies à 100%.



=== TEST DE REMPLISSAGE : Évaluation ===
- Lignes : 1470 | Colonnes : 10
- NaN au total : 0 / 14700
- Chaines vides ('') au total : 0 / 14700
- Manquant total (NaN + vides) : 0 / 14700 (0.00%)
- Taux de remplissage global : 100.0%
- Aucune colonne incomplète : toutes les colonnes sont remplies à 100%.



3. Nettoyage de la donnée et consolidation d'un nouveau Dataframe

3.1 Traitement des colonnes constante, Nan, cellules vides ou avec des erreurs de saisies

```
=== 0. IDENTIFICATION DES COLONNES IDs ===
## Identification des colonnes IDs
On extrait les identifiants de chaque source, on mesure les IDs communs (ceux qu'on pourra fusionner) et les colonnes partagées (hors clés de jointure).

Nombre d'IDs uniques dans df_sirh : 1470
Nombre d'IDs uniques dans df_sondage : 1470
Nombre d'IDs uniques dans df_eval : 1470
--------------------------------------------------
IDs communs entre SIRH et Sondage : 1470
IDs communs entre SIRH et Eval : 1470
IDs communs aux 3 DataFrames : 1470
Taux de recouvrement vs SIRH — Sondage : 100.0% | Éval : 100.0% | les 3 : 100.0%

Communes entre sirh et sondage : {}
Communes entre sirh et eval : {}
Communes entre sondage et eval : {}

=== 1. DIMENSIONS AVANT NETTOYAGE ===
• df_sirh    : 1470 lignes | 12 colonnes
• df_sondage : 1470 lignes | 12 colonnes
• df_eval    : 1470 lignes | 10 colonnes

=== DÉTAIL DES IDENTIFIANTS AVANT FUSION ===
• df_sirh    : 1470 IDs uniques
• df_sondage : 1470 IDs uniques
• df_eval    : 1470 IDs uniques

=== ANALYSE DES EXCLUSIONS (IDs absents d'au moins une source) ===
• IDs exclus de df_sirh    : 0
• IDs exclus de df_sondage : 0
• IDs exclus de df_eval    : 0
• IDs communs aux 3 sources : 1470

=== COLONNES CONSTANTES RETIRÉES (variance nulle, hors clés) ===
• nombre_employee_sous_responsabilite (toujours 1)
• nombre_heures_travailless (toujours 80)

=== 2. DIMENSIONS APRÈS NETTOYAGE (AVANT FUSION) ===
• df_sirh    : 1470 lignes | 11 colonnes
• df_sondage : 1470 lignes | 12 colonnes
• df_eval    : 1470 lignes | 11 colonnes
  → df_sirh  ajoutées : aucune  |  retirées : ['nombre_heures_travailless']
  → df_sondage  ajoutées : ['id_employee']  |  retirées : ['nombre_employee_sous_responsabilite']
  → df_eval  ajoutées : ['id_employee']  |  retirées : aucune

=== 3. DIMENSIONS FINALES (APRÈS FUSION & NETTOYAGE FINAL) ===
• Lignes finales : 1470
• Colonnes finales : 28
• Colonnes redondantes retirées : ['note_evaluation_precedente_num', 'note_evaluation_actuelle_num']
• Colonnes constantes retirées  : ['nombre_heures_travailless', 'nombre_employee_sous_responsabilite', 'ayant_enfants']
• id_employee retiré du df final (identifiant technique)
• Fichier sauvegardé localement : df_clean.csv
• Copies locales SIRH / Sondage / Éval effacées — il reste df_clean
```

```
=== TYPES DE TOUTES LES COLONNES DANS DF_CLEAN ===
age                                    int64
genre                                    str
revenu_mensuel                         int64
statut_marital                           str
departement                              str
poste                                    str
nombre_experiences_precedentes         int64
annee_experience_totale                int64
annees_dans_l_entreprise               int64
annees_dans_le_poste_actuel            int64
a_quitte_l_entreprise                    str
nombre_participation_pee               int64
nb_formations_suivies                  int64
distance_domicile_travail              int64
niveau_education                       int64
domaine_etude                            str
frequence_deplacement                    str
annees_depuis_la_derniere_promotion    int64
annes_sous_responsable_actuel          int64
satisfaction_employee_environnement    int64
note_evaluation_precedente             int64
niveau_hierarchique_poste              int64
satisfaction_employee_nature_travail   int64
satisfaction_employee_equipe           int64
satisfaction_employee_equilibre_pro_perso  int64
note_evaluation_actuelle               int64
heure_supplementaires                    str
augementation_salaire_precedente         str
dtype: object
```

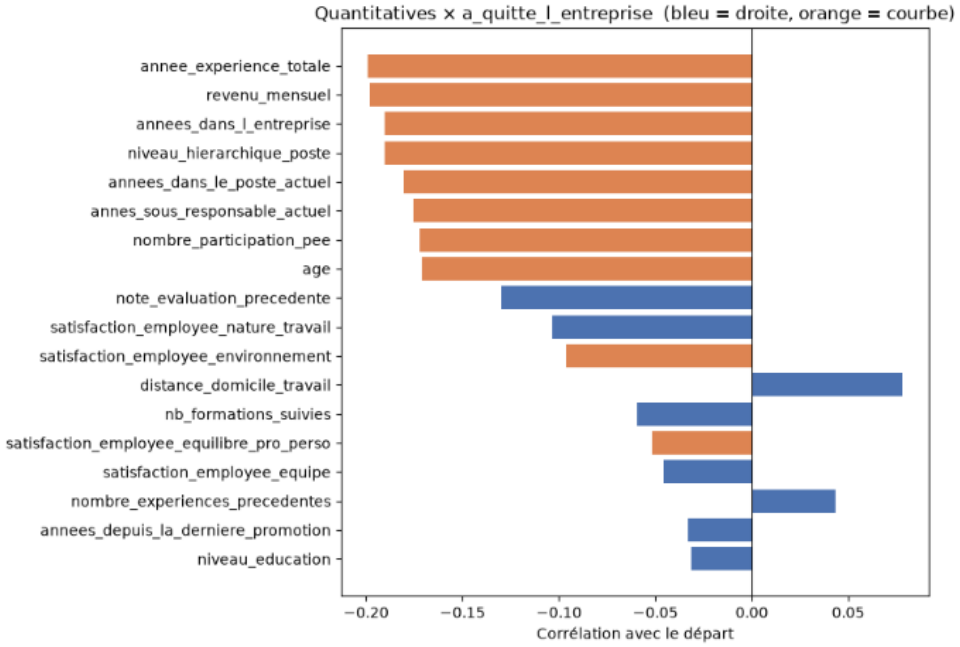
- Fichier sauvegardé localement : df_clean.csv
- Copies locales SIRH / Sondage / Éval effacées — il reste df_clean

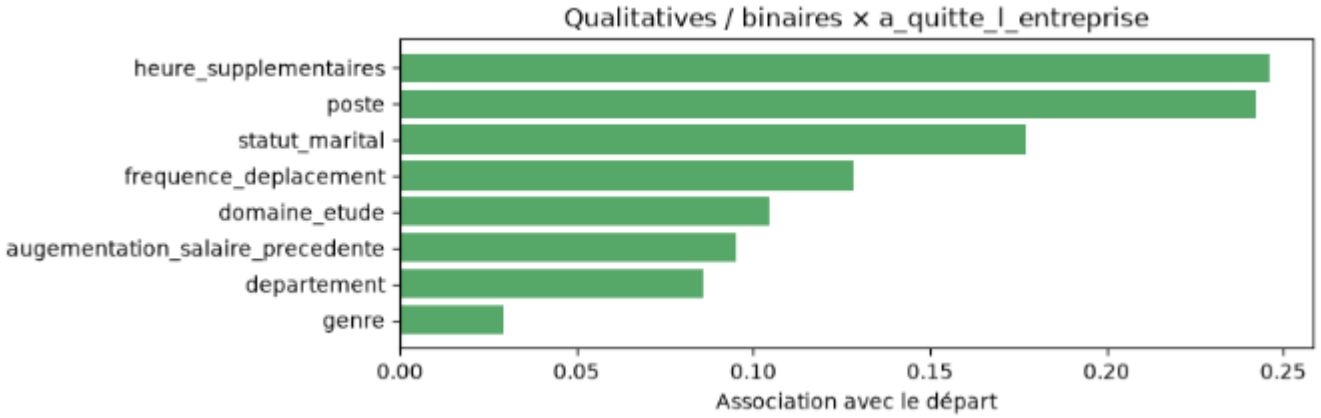
Le dataframes est correctement remplie, sans erreurs de saisies répertoriés (outlier), deux colonnes sont constates et deux colonnes sont redondantes inter-fichiers.

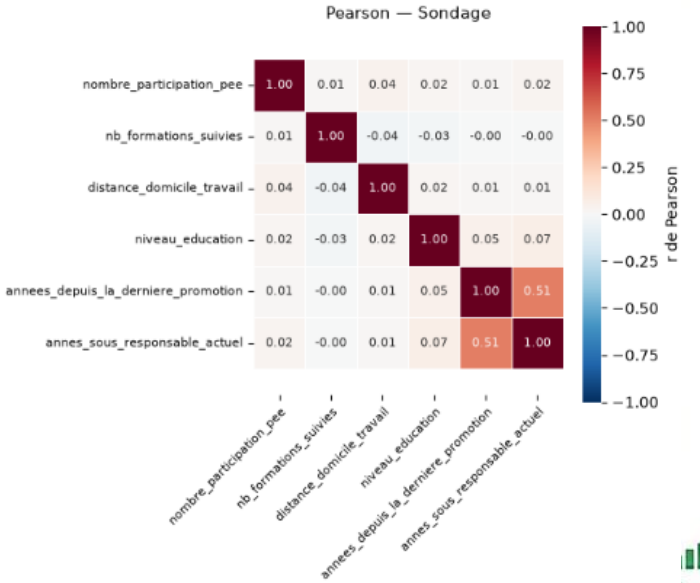
4 L'hypothèse

4.1 Analyse des corrélations avec Y dans le but de créer de nouvelles features

a_quitte_l_entreprise	Effectif	Pourcentage (%)
Non	1233	83.880000
Oui	237	16.120000

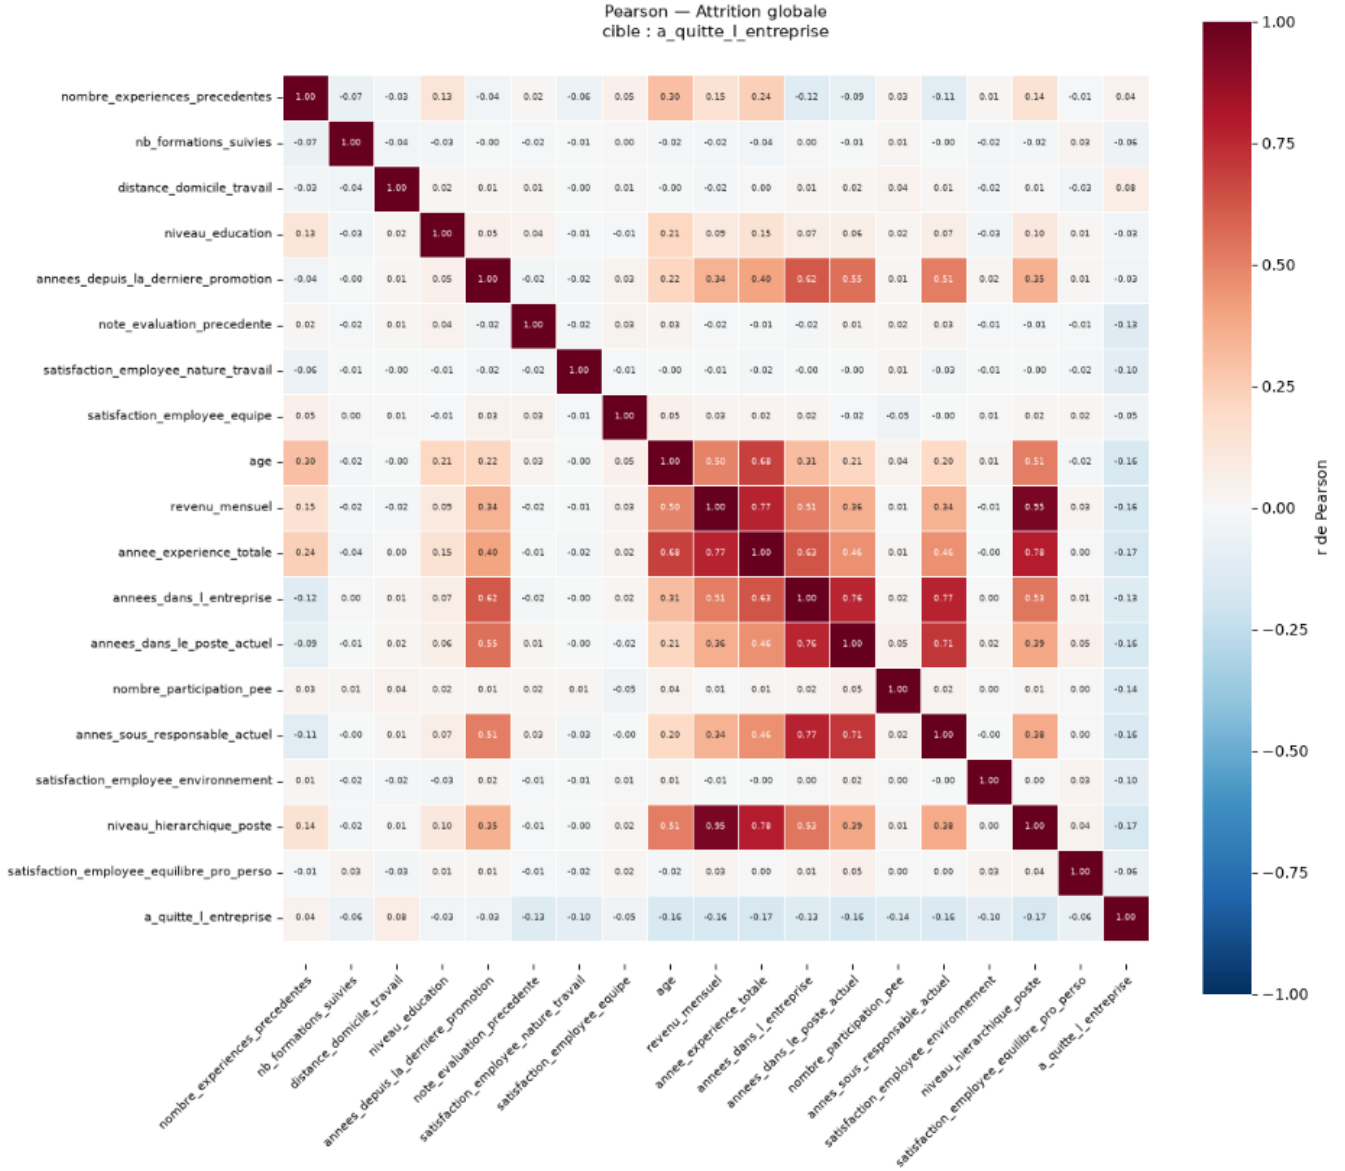






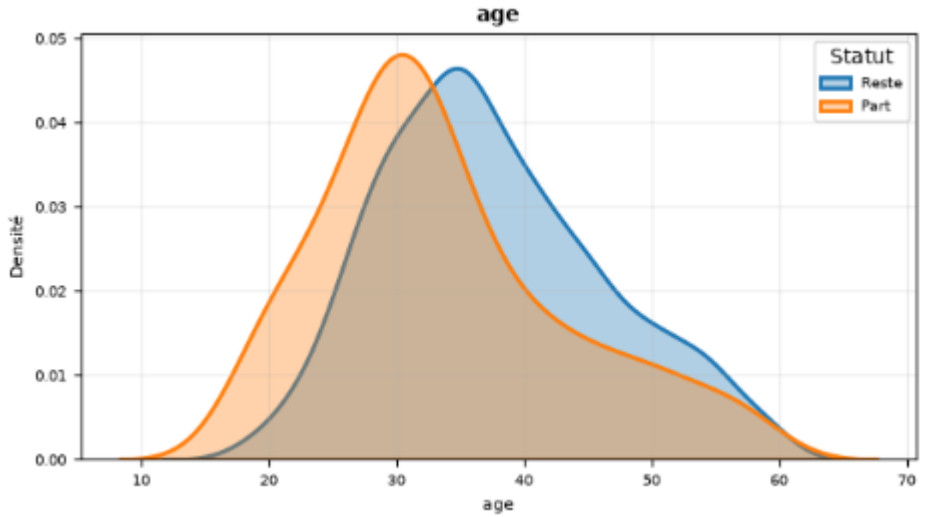
Un profil junior peu ancré, mais ce n'est pas une cause unique.

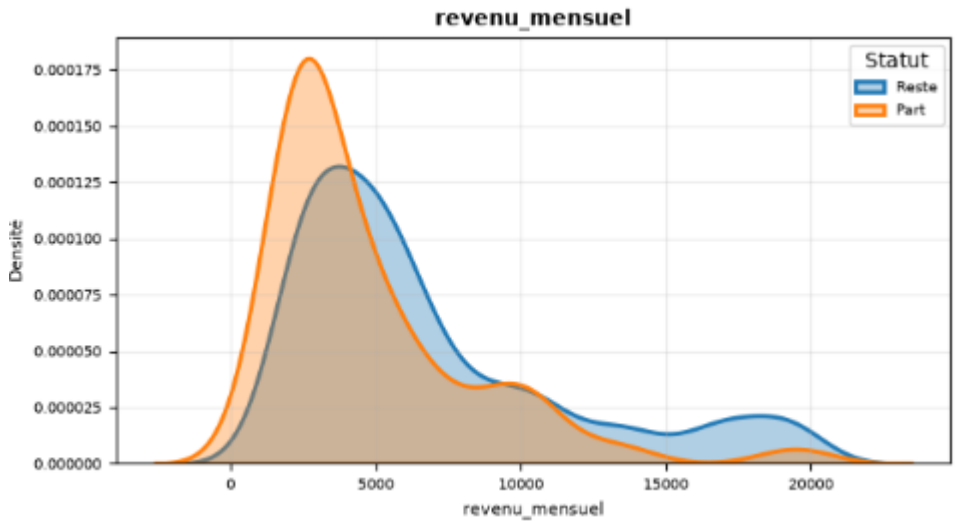
L'attrition ne se répartit pas au hasard : elle se concentre chez les salariés en début de parcours → plus jeunes, niveau de poste bas, salaire plus faible, peu d'ancienneté dans l'entreprise, dans le poste et sous le responsable actuel.
Les matrices Pearson et Spearman le montrent directement : âge, revenu, expérience totale, ancienneté, années dans le poste / sous le responsable et niveau hiérarchique forment un bloc rouge. Elles varient ensemble. On ne peut donc pas dire « c'est le salaire » ou « c'est l'âge » : la matrice dit que c'est le même axe.



4.2 Analyse des formes et mouvements de la distribution des variables vers Y

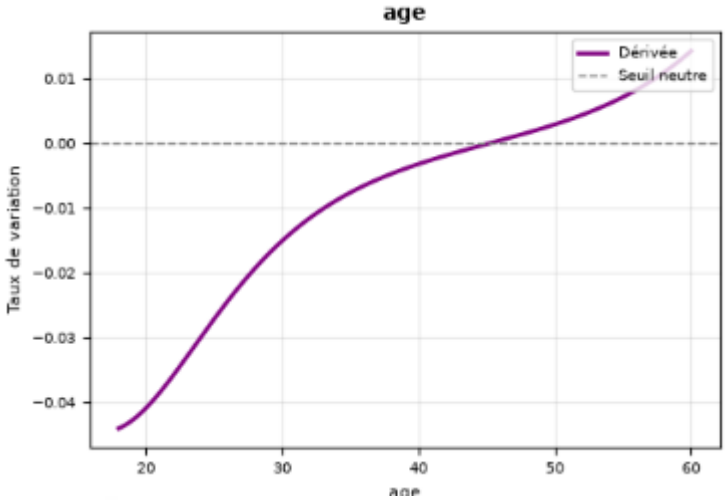
4.2.1 La forme

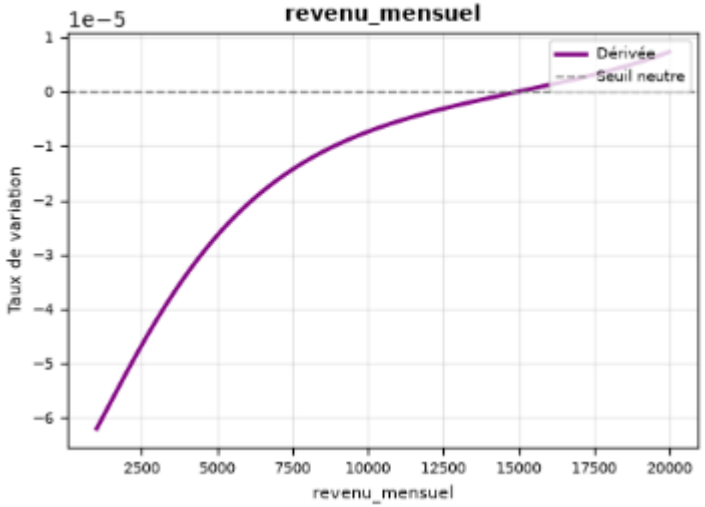




Variables pour lesqueles la courbe Orange dépasse la bleue :
Age
Revenue mensuel
Annees_dans_l_entreprise
Annees_dans_le_poste_actuel
Nombre d_participation_pee
Annees_sous-responsable_actuel
Satistisfaction_employée_environ ement (valeur de 1)
Niveau_hierarchique_poste
Satisfaction_employée_equilibre_ prop_perso (pour valeur de 1)

4.2.2 Le mouvement



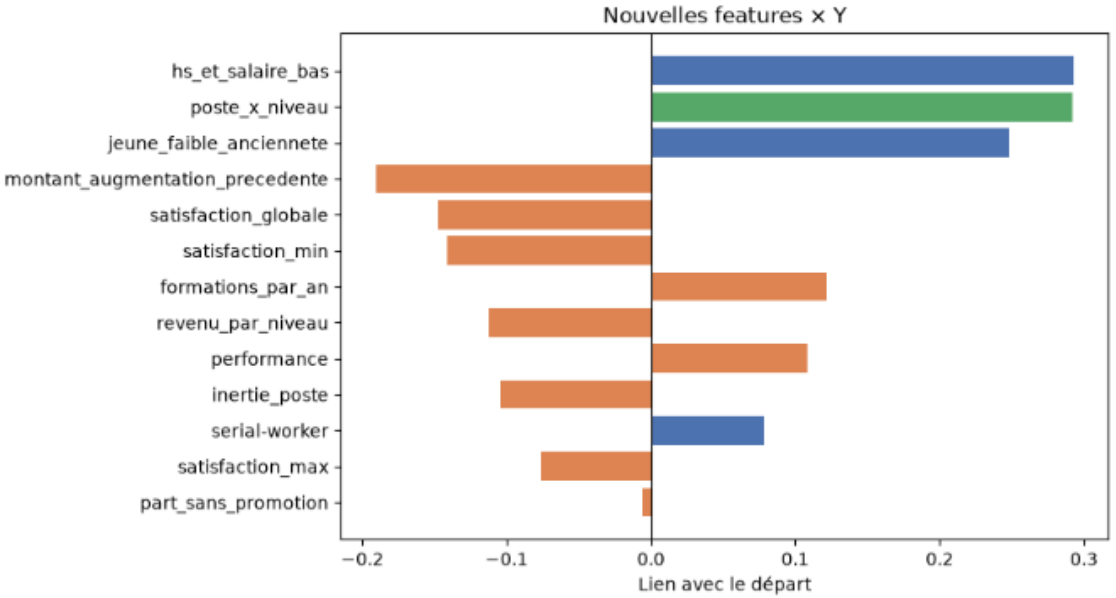


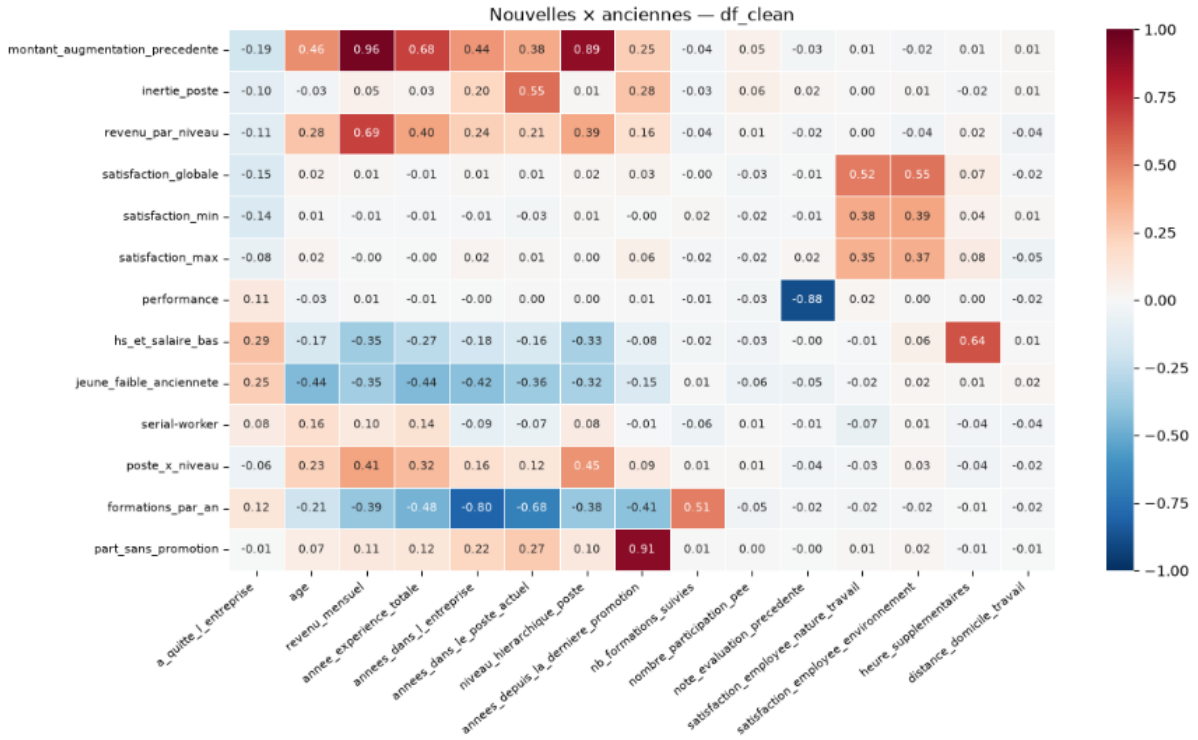
5. Liste de nouvelles features

5.1 Création et classification de nouvelles features

Feature	Origine	Formule et sens	Pourquoi (exploration)	Résultat de la Corrélation avec Y
NÉES DES COURBES DERIVEES				
jeune_faible_ancienneté	âge + ancienneté	1 si âge < 30 et ancienneté < 2 ans.	Risque de départ élevé en début de poste pour les deux variables, la variable combine âge et ancienneté.	Utile
revenu_par_niveau	salaire + niveau	Salaire / niveau hiérarchique.	Salaire et niveau sont tous deux liés ce ratio les combines en une seule variable.	14/26 ème corrélation Secondaire
inertie_poste	2 anciennetés	Années poste / années entreprise.	Test si l'employé est coincé au même poste.	14/26 ème corrélation Secondaire
AUTRES				
hs_et_salaire_bas	HS × salaire	1 si heures sup et salaire < médiane.	Combine deux effets connus : heures sup (effet direct) et salaire bas (effet en courbe).	Utile
montant_augmentation_precedente	changement d'unité	€ de la dernière hausse.	Le % de hausse n'était pas discriminant ; le montant en euros l'est davantage.	9/26 ème corrélation Utile
satisfaction_globale	Likert	Moyenne des 4 satisfactions.	Variables Likert hors bloc carrière, plutôt linéaires vis-à-vis du départ.	9/26 ème corrélation Utile
satisfaction_min	Likert	Minimum des 4 satisfactions.	Capture un effet de seuil (un axe très bas) qu'une moyenne masquerait.	11/26 ème corrélation Utile
satisfaction_max	Likert	Maximum des 4 satisfactions.	*à compléter* — symétrique du minimum : teste si un très bon axe compense les autres.	18/26 ème corrélation Secondaire
performance	notes d'éval	Note actuelle − note précédente.	Isole la tendance (hausse/baisse) plutôt que le niveau brut de la note.	13/26 ème corrélation Secondaire
Serial-worker	queue linéaire	1 si ≥ 5 employeurs précédents.	Variable déjà linéaire vis-à-vis de y ; le flag seuil n'apporte pas grand-chose de plus.	9/10 ème corrélation Faible
poste_x_niveau	poste × niveau	Texte poste & niveau	La heatmap le montre : le taux de départ dépend du couple poste + grade.	Utile
formations_par_an	formations × ancienneté	nb_formations_suivies / (annees_dans_l_entreprise + 1)	Le stock de formations suit l'ancienneté.	13/26 ème corrélation Utile
part_sans_promotion	promo × ancienneté	annees_depuis_la_derniere_promotion / annees_dans_l_entreprise	Proche de 1 = pas promu depuis l'arrivée ; proche de 0 = promo récente.	Non utile

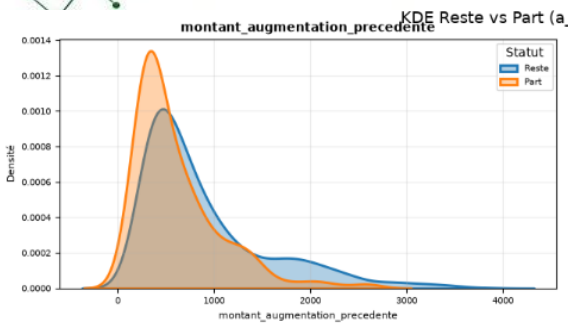
5.2 Analyse des nouvelles features

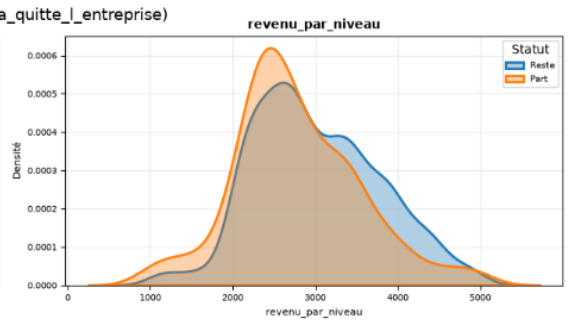


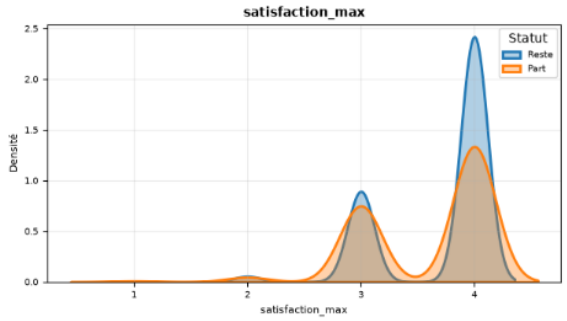


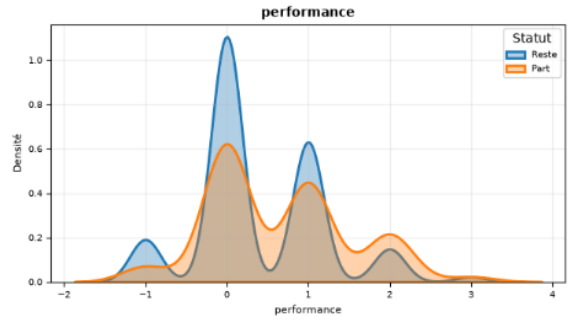
Classifiez automatiquement des informations

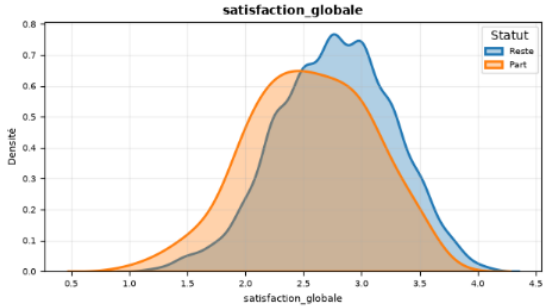
KDE Reste vs Part (a_quitte_l_entreprise)

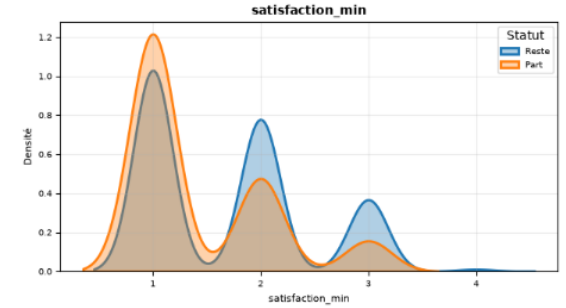


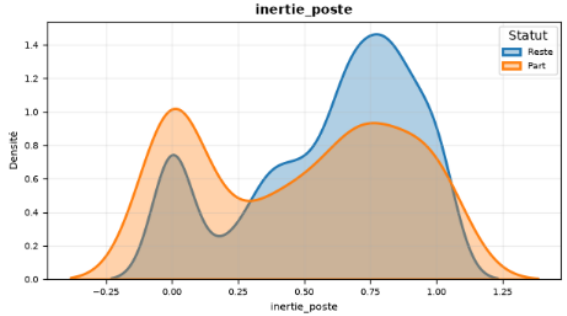


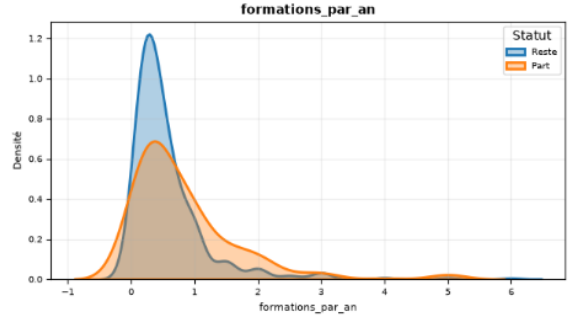


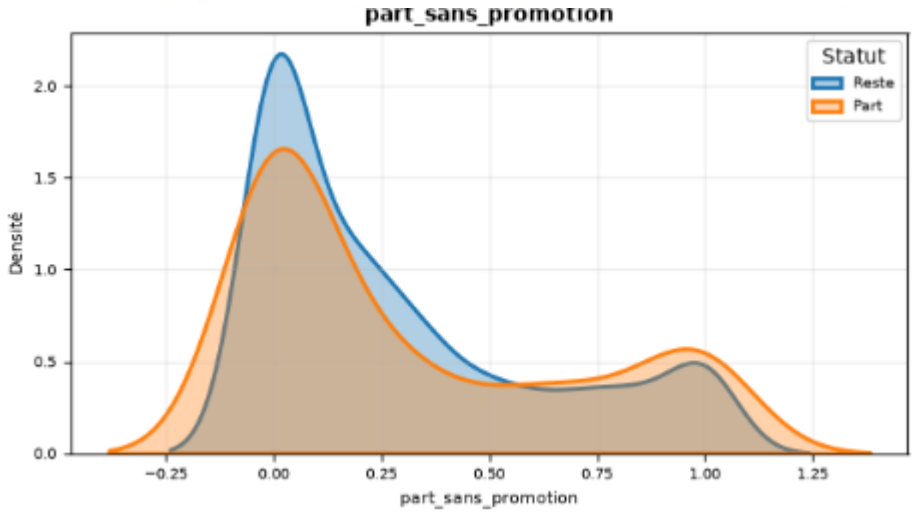






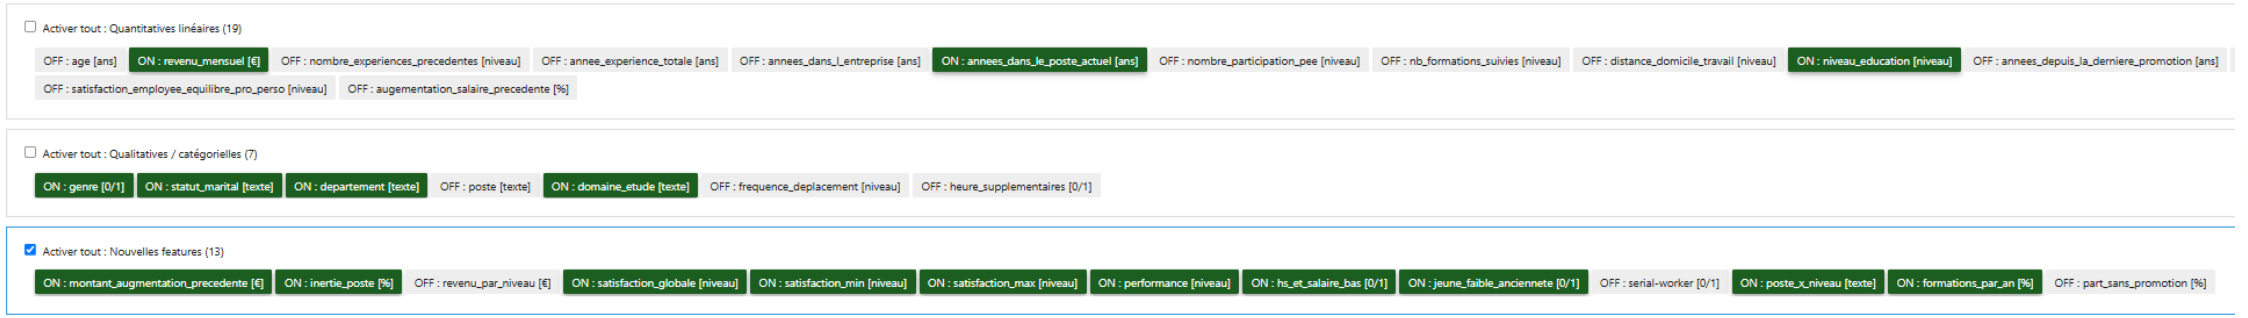






6. Sélection des features pertinentes

5.1 Panneau de sélection des features



*Ce panneau permet de sélectionner et désélectionner rapidement des features afin d'entrainer les modèles.

Les trois axes de sélection d'une features :

1. Supprimer celles qui parlent peu ou pas du départ.
2. Elle ne déduit pas la même chose qu'une autre déjà là (redondance).
3. Elle n'est pas un double d'une synthèse déjà créée.

7. Découpage Train/Test et stratification

7.1 Cross Validation et Train/Test

```
[8]: from sklearn.model_selection import StratifiedKFold

def get_df():
    return df_clean

def get_var_buttons():
    if 'var_buttons' in globals():
        return var_buttons
    print("⚠️ Le panneau de sélection des features n'a pas été lancé !")
    return None

def on_split_termine(resultats):
    global X_train, X_test, y_train, y_test, features_selectionnees, cv
    X_train = resultats["X_train"]
    X_test = resultats["X_test"]
    y_train = resultats["y_train"]
    y_test = resultats["y_test"]
    features_selectionnees = resultats["features_selectionnees"]

    # Récupération dynamique de la graine choisie dans l'interface de split
    seed_dynamique = resultats.get("random_state", 42)

    # Création du CV global dynamique pour l'interface d'hyperparamètres
    cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=seed_dynamique)

display(train_test.bouton_train_test(get_df, get_var_buttons, on_split_termine, target_col="a_quitte_l_entreprise"))
```

▶ Démarrer

Réglages du split

Taille test : 0.20

☑ Stratifier sur la cible (recommandé)

Graine (random_state) : 42

☑ Afficher le détail des effectifs

⤮ →→→→ Lancer le split train / test ←←←←

```
Test : 20% | Train : 80%
Stratify : oui | seed : 42
Variables : 15
Train (1176, 15) | Test (294, 15)
Départs train : 16.2% | test : 16.0%

Effectifs cible
Train : {0: 986, 1: 190}
Test  : {0: 247, 1: 47}

Aperçu CV à 5 plis (sur le train seul, test jamais dedans)
Chaque pli garde ~le même % de départs.
  Pli 1 : apprend 940 (16.2% départs) | note 236 (16.1% départs)
  Pli 2 : apprend 941 (16.2% départs) | note 235 (16.2% départs)
  Pli 3 : apprend 941 (16.2% départs) | note 235 (16.2% départs)
  Pli 4 : apprend 941 (16.2% départs) | note 235 (16.2% départs)
  Pli 5 : apprend 941 (16.2% départs) | note 235 (16.2% départs)
Ces 5 modèles d'aperçu ne sont pas gardés. Le modèle final = tout le train.

Étape 1 OK → cellule préprocesseur.
```

7.2 Stratification du jeu de données

Découpage du jeu de train/test en pourcentage.

La stratification : chaque pli a à peu près le même % de départs que le train.
Le train (~1 028 personnes, 16 % de départs) → est coupé en **5 morceaux**.
Dans chaque morceau, on garde ~16 % de partants on ne se retrouve pas avec un pli à 8 % et un autre à 25 %.

8. Préprocesseur

8.1 5 portes, zéro fuite

PRÉPROCESSEUR

5 portes, zéro fuite

Les colonnes ON de `X_train` passent dans un **ColumnTransformer** (`remainder="drop"` : tout ce qui est OFF disparaît). On **fit sur le train seulement**, puis on `transform` train et test. `Y` n'entre jamais.

Porte	Quoi	Traitement
`num_lin`	quantitatives linéaires	StandardScaler
`num_nonlin`	quantitatives courbes	StandardScaler
`cat`	texte (poste_x_niveau, marital…)	OneHotEncoder
`bool`	déjà 0/1	passthrough
`ratios`	features métier numériques	StandardScaler

Ensuite seulement : le classifieur (L2, etc.). Même préprocesseur pour la CV : à chaque pli on refit sur les 4 plis, on transforme le 5e.

9. Modélisation et interprétation

9.1 Comparer le ROC-AUC : plis d'apprentissage vs plis de validation (CV)

Avec toutes les features

Model	ROC_AUC_cv	ROC_AUC_cv_std	F1_cv	F1_cv_std	ROC_AUC_train	ROC_AUC_train_cv_mean	ROC_AUC_train_cv_std	ROC_AUC_test	PR_AUC_test	Accuracy_test	Precision_test	Recall_test	F1_test	Duration_s	Seuil_utilise	Ecart_Train_CV	Ecart_CV_Test	Diagnostic
Ridge	0.844	0.029	0.463	0.093	0.884	0.890	0.007	0.825	0.531	0.861	0.714	0.213	0.328	0.205	0.500	0.045	0.019	Bien équilibré
LogisticRegression_L1	0.842	0.019	0.518	0.026	0.898	0.904	0.007	0.835	0.542	0.765	0.380	0.745	0.504	2.081	0.500	0.062	0.007	Surapprentissage
LogisticRegression_L2	0.843	0.020	0.518	0.019	0.900	0.906	0.006	0.835	0.540	0.772	0.386	0.723	0.504	0.267	0.500	0.063	0.009	Surapprentissage
ElasticNet_LogReg	0.843	0.020	0.521	0.023	0.899	0.905	0.007	0.835	0.540	0.776	0.391	0.723	0.507	1.875	0.500	0.062	0.009	Surapprentissage
SVR_Linear	0.836	0.016	0.526	0.037	0.903	0.909	0.007	0.828	0.523	0.776	0.391	0.723	0.507	0.218	0.500	0.073	0.009	Surapprentissage
LogisticRegression_None	0.827	0.025	0.509	0.031	0.904	0.911	0.006	0.828	0.498	0.769	0.379	0.702	0.493	2.730	0.500	0.084	-0.002	Surapprentissage
RandomForest	0.822	0.029	0.496	0.073	1.000	1.000	0.000	0.801	0.453	0.833	0.476	0.426	0.449	1.018	0.500	0.178	0.022	Surapprentissage

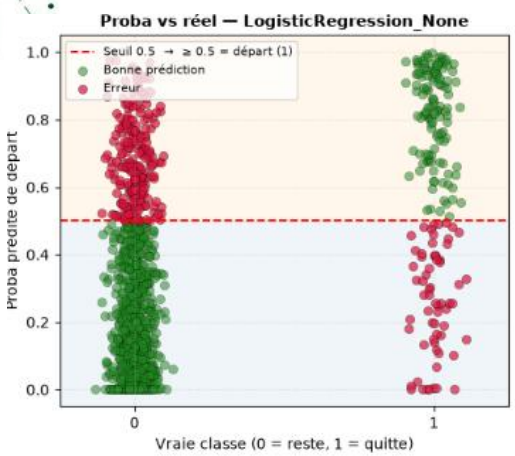
Avec des features minimales

Model	ROC_AUC_cv	ROC_AUC_cv_std	F1_cv	F1_cv_std	ROC_AUC_train	ROC_AUC_train_cv_mean	ROC_AUC_train_cv_std	ROC_AUC_test	PR_AUC_test	Accuracy_test	Precision_test	Recall_test	F1_test	Duration_s	Seuil_utilise	Ecart_Train_CV	Ecart_CV_Test	Diagnostic
LogisticRegression_None	0.826	0.021	0.491	0.021	0.870	0.874	0.009	0.789	0.496	0.735	0.340	0.702	0.458	2.517	0.500	0.048	0.038	Bien équilibré
LogisticRegression_L1	0.832	0.033	0.499	0.016	0.866	0.869	0.009	0.794	0.520	0.728	0.333	0.702	0.452	1.799	0.500	0.037	0.039	Bien équilibré
LogisticRegression_L2	0.831	0.031	0.500	0.027	0.865	0.869	0.009	0.792	0.525	0.745	0.351	0.702	0.468	0.205	0.500	0.038	0.040	Bien équilibré
ElasticNet_LogReg	0.832	0.032	0.505	0.017	0.865	0.869	0.009	0.791	0.520	0.741	0.347	0.702	0.465	0.744	0.500	0.037	0.041	Bien équilibré
SVR_Linear	0.829	0.026	0.498	0.018	0.868	0.873	0.009	0.788	0.501	0.728	0.333	0.702	0.452	0.161	0.500	0.043	0.041	Bien équilibré
LogisticRegression_L2_calibre	0.830	0.032	0.411	0.072	0.865	0.868	0.009	0.791	0.514	0.861	0.688	0.234	0.349	0.481	0.500	0.038	0.039	Bien équilibré
Ridge	0.823	0.042	0.404	0.055	0.852	0.856	0.009	0.782	0.495	0.850	0.600	0.191	0.290	0.164	0.500	0.033	0.042	Bien équilibré

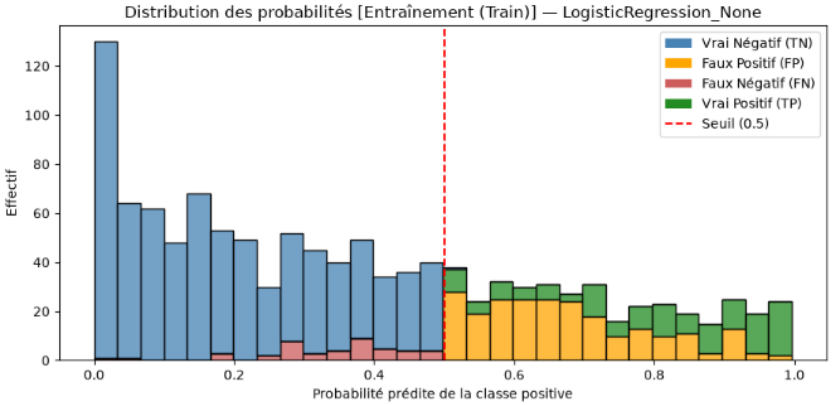
Avec les features choisies

Model	ROC_AUC_cv	ROC_AUC_cv_std	F1_cv	F1_cv_std	ROC_AUC_train	ROC_AUC_train_cv_mean	ROC_AUC_train_cv_std	ROC_AUC_test	PR_AUC_test	Accuracy_test	Precision_test	Recall_test	F1_test	Duration_s	Seuil_utilise	Ecart_Train_CV	Ecart_CV_Test	Diagnostic
AdaBoost	0.804	0.024	0.380	0.049	0.839	0.846	0.006	0.784	0.455	0.830	0.448	0.277	0.342	0.543	0.470	0.042	0.020	Bien équilibré
Ridge	0.802	0.032	0.379	0.055	0.840	0.846	0.005	0.803	0.460	0.844	0.522	0.255	0.343	0.189	0.470	0.043	-0.000	Bien équilibré
SVR_Linear	0.800	0.028	0.458	0.049	0.856	0.863	0.007	0.813	0.474	0.701	0.328	0.830	0.470	0.183	0.470	0.063	-0.013	Surapprentissage
LogisticRegression_None	0.794	0.035	0.454	0.050	0.858	0.865	0.008	0.814	0.472	0.752	0.373	0.809	0.510	0.234	0.470	0.071	-0.020	Surapprentissage
LogisticRegression_L1	0.807	0.028	0.465	0.058	0.853	0.858	0.007	0.810	0.489	0.741	0.362	0.809	0.500	0.190	0.470	0.051	-0.004	Surapprentissage
LogisticRegression_L2	0.807	0.025	0.465	0.058	0.854	0.859	0.007	0.812	0.482	0.755	0.376	0.809	0.514	0.218	0.470	0.051	-0.005	Surapprentissage

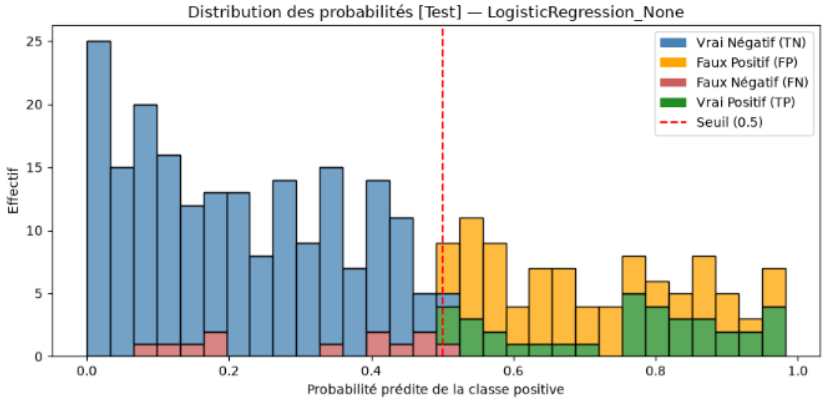
9.2 Comparer les résultats CV/Train/Test



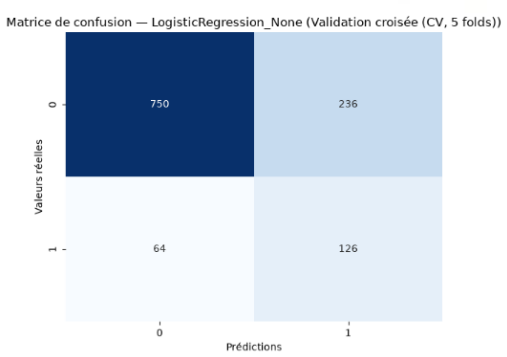
CV

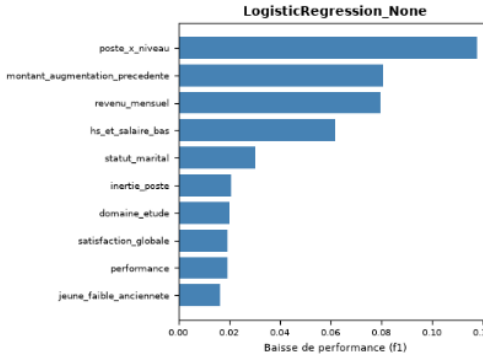


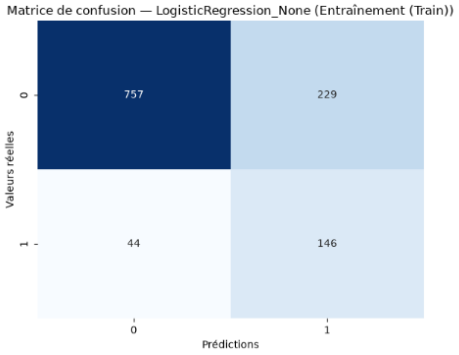
Train

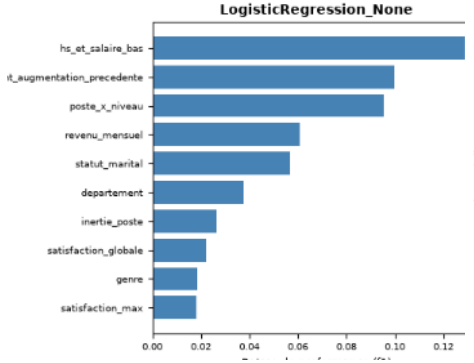


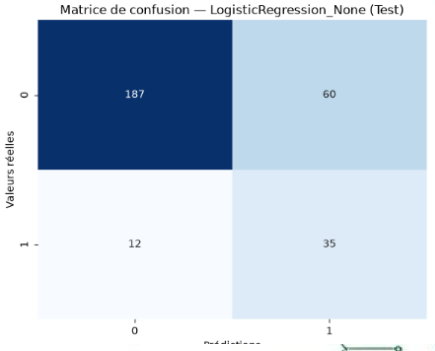
Test











test

*Pour logistique régression on note encore des hésitation entre le choix des features prioritaires entre test /train

10. Fine-tunning

10.1 Choix d'un modèle et optimisations

Je choisi le modèle **LogisticRegression_L2** ayant le meilleur rapport Précision /Recall après la recherche automatique d'hyperparamètres effectuées avec GridShearchCV

	Model	ROC_AUC_cv	ROC_AUC_train	ROC_AUC_test	Recall_train	Recall_test	Accuracy_test	Precision_test	F1_test	Ecart_Train_CV	Ecart_CV_Test	Diagnostic	Meilleurs paramètres	Duration_s
2	LogisticRegression_L2	0.808423	0.841443	0.802567	0.705263	0.680851	0.761905	0.367816	0.477612	0.045849	-0.004503	Cohérent	C=0.1	0.26
4	ElasticNet_LogReg	0.807626	0.853475	0.812129	0.726316	0.680851	0.761905	0.367816	0.477612	0.045849	-0.004503	Cohérent	C=1, l1_ratio=0.5	5.93
6	LogisticRegression_L2_calibre	0.807331	0.853299	0.810923	0.257895	0.170213	0.853741	0.666667	0.271186	0.045968	-0.003591	Cohérent	C=1	0.79
3	Ridge	0.806872	0.837536	0.801361	0.226316	0.106383	0.836735	0.454545	0.172414	0.030664	0.005511	Cohérent	alpha=10	0.24
1	LogisticRegression_L1	0.806660	0.853069	0.810233	0.726316	0.680851	0.751701	0.355556	0.467153	0.046409	-0.003573	Cohérent	C=1	0.27
5	SVR_Linear	0.805091	0.853544	0.811612	0.689474	0.617021	0.782313	0.386667	0.475410	0.048454	-0.006521	Cohérent	C=0.1	0.15
0	LogisticRegression_None	0.794027	0.857884	0.814282	0.731579	0.680851	0.758503	0.363636	0.474074	0.063858	-0.020255	Overfitting possible		0.18

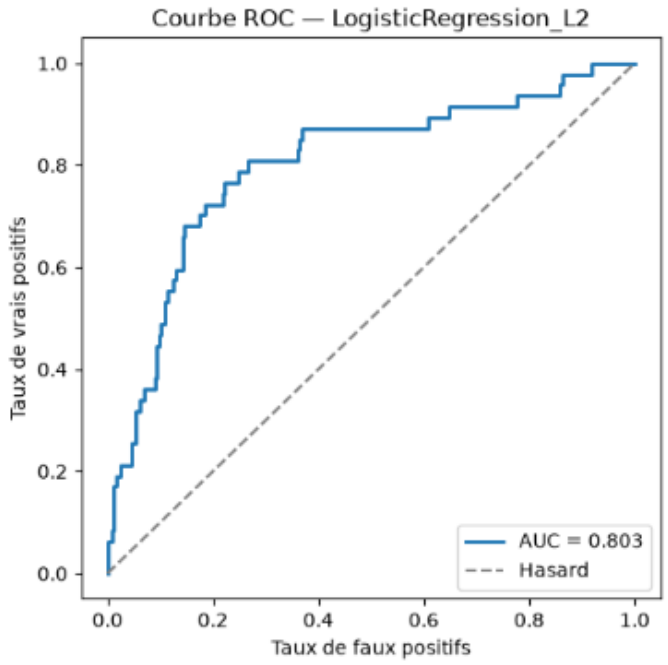
Seuil : 0.52

Importance

	Feature	Importance
43	bool__hs_et_salaire_bas	1.18751
44	bool__jeune_faible_anciennete	0.81116
23	cat__poste_x_niveau_Consultant | N1	0.57101
5	cat__statut_marital_Célibataire	0.53770
45	ratios__montant_augmentation_precedente	0.50678
21	cat__poste_x_niveau_Cadre Commercial | N3	0.45598
9	cat__departement_Consulting	0.43758
38	cat__poste_x_niveau_Senior Manager | N4	0.43255
48	ratios__satisfaction_min	0.41078
8	cat__departement_Commercial	0.39669
29	cat__poste_x_niveau_Manager | N2	0.38838
18	cat__poste_x_niveau_Assistant de Direction | N2	0.35338
6	cat__statut_marital_Divorcé(e)	0.35318
40	cat__poste_x_niveau_Tech Lead | N2	0.30544
37	cat__poste_x_niveau_Senior Manager | N3	0.29501
15	cat__domaine_etude_Ressources Humaines	0.28954
50	ratios__performance	0.27503
11	cat__domaine_etude_Autre	0.27381
17	cat__poste_x_niveau_Assistant de Direction | N1	0.27109
46	ratios__inertie_poste	0.25296

Permutations

	Feature	Importance_moyenne	Ecart_type
0	hs_et_salaire_bas	0.08831	0.00585
1	montant_augmentation_precedente	0.04967	0.02309
2	statut_marital	0.03601	0.00501
3	departement	0.01876	0.00436
4	satisfaction_min	0.01457	0.01014
5	performance	0.01158	0.00718
6	satisfaction_globale	0.01025	0.00353
7	inertie_poste	0.00998	0.00944
8	genre	0.00432	0.00353
9	domaine_etude	0.00351	0.00288
10	jeune_faible_anciennete	0.00333	0.00873
11	revenu_mensuel	0.00324	0.00520
12	formations_par_an	0.00274	0.00122
13	niveau_education	0.00110	0.00077
14	satisfaction_max	0.00096	0.00098
15	annees_dans_le_poste_actuel	0.00062	0.00307
16	poste_x_niveau	-0.00224	0.00289

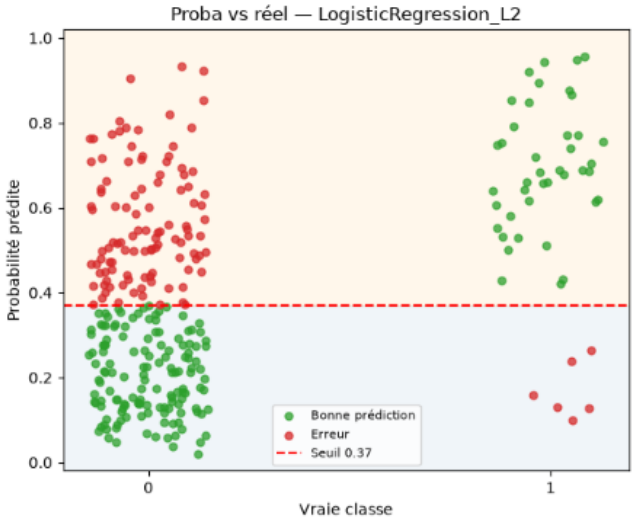


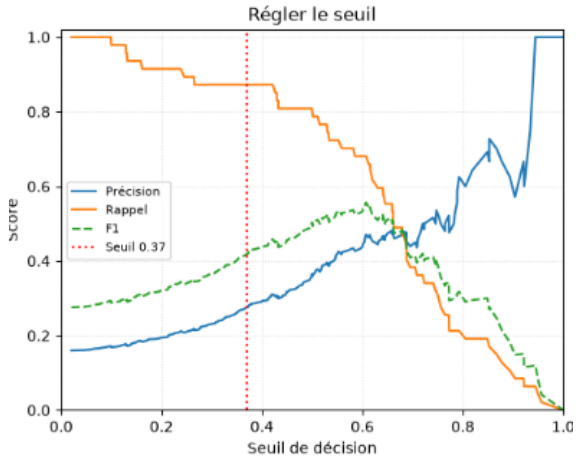
	Residuals	Abs_Residuals
Abs_Residuals	-0.396	1.000
Predicted_Proba	-0.242	0.605
jeune_faible_anciennete	-0.130	0.196
formations_par_an	-0.132	0.175
hs_et_salaire_bas	0.136	0.107
performance	-0.052	0.095
Vraie_Classe	0.782	0.017
niveau_education	0.043	0.014
satisfaction_max	0.044	-0.117
satisfaction_globale	0.131	-0.254
annees_dans_le_poste_actuel	0.152	-0.272
revenu_mensuel	0.117	-0.273
montant_augmentation_precedente	0.107	-0.288
satisfaction_min	0.186	-0.314
inertie_poste	0.168	-0.342

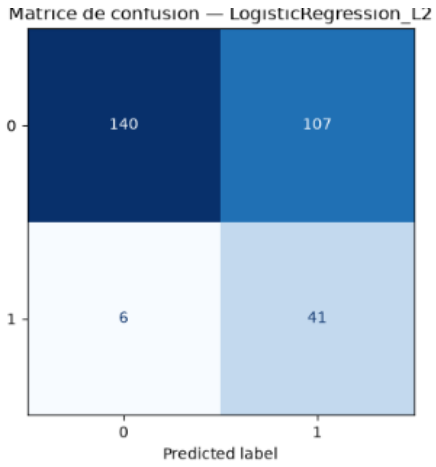
10.2 Optimisation du seuil

Model	ROC AUC cv	ROC AUC train	ROC AUC test	Recall train	Recall test	Accuracy test	Precision test	F1 test	Ecart Train CV	Ecart CV Test	Diagnostic
LogisticRegression_L2	0.808423	0.841443	0.802567	0.884211	0.872340	0.615646	0.277027	0.420513	0.033020	0.005856	Cohérent

Seuil : 0.37





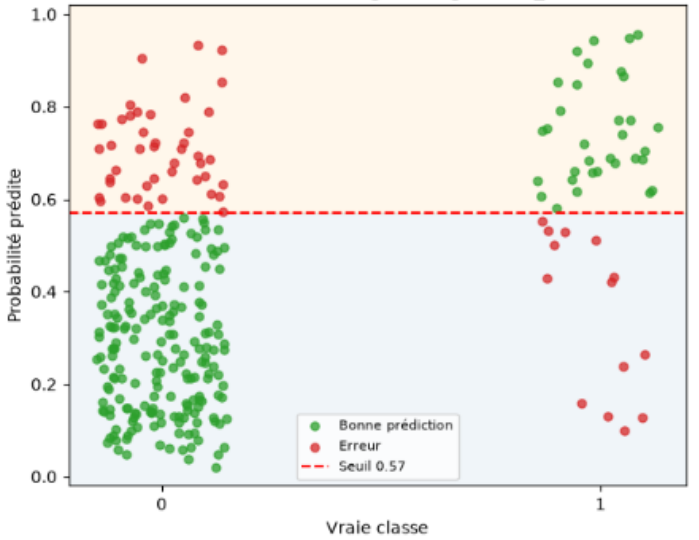


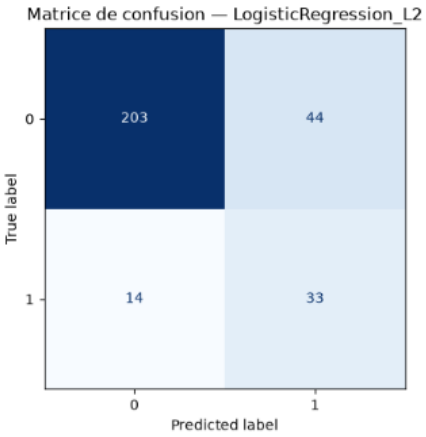
41 départ trouvé
6 raté.
148 alertes dont
107 fausses

*Garder un seuil de 0,57 si rater un départ coûte beaucoup plus cher qu'un rendez-vous HR effectué pour rien.

Model	ROC AUC cv	ROC AUC train	ROC AUC test	Recall train	Recall test	Accuracy test	Precision test	F1 test	Ecart Train CV	Ecart CV Test	Diagnostic
LogisticRegression_L2	0.808423	0.841443	0.802567	0.636842	0.702128	0.802721	0.428571	0.532258	0.033020	0.005856	Cohérent

Seuil : 0.57

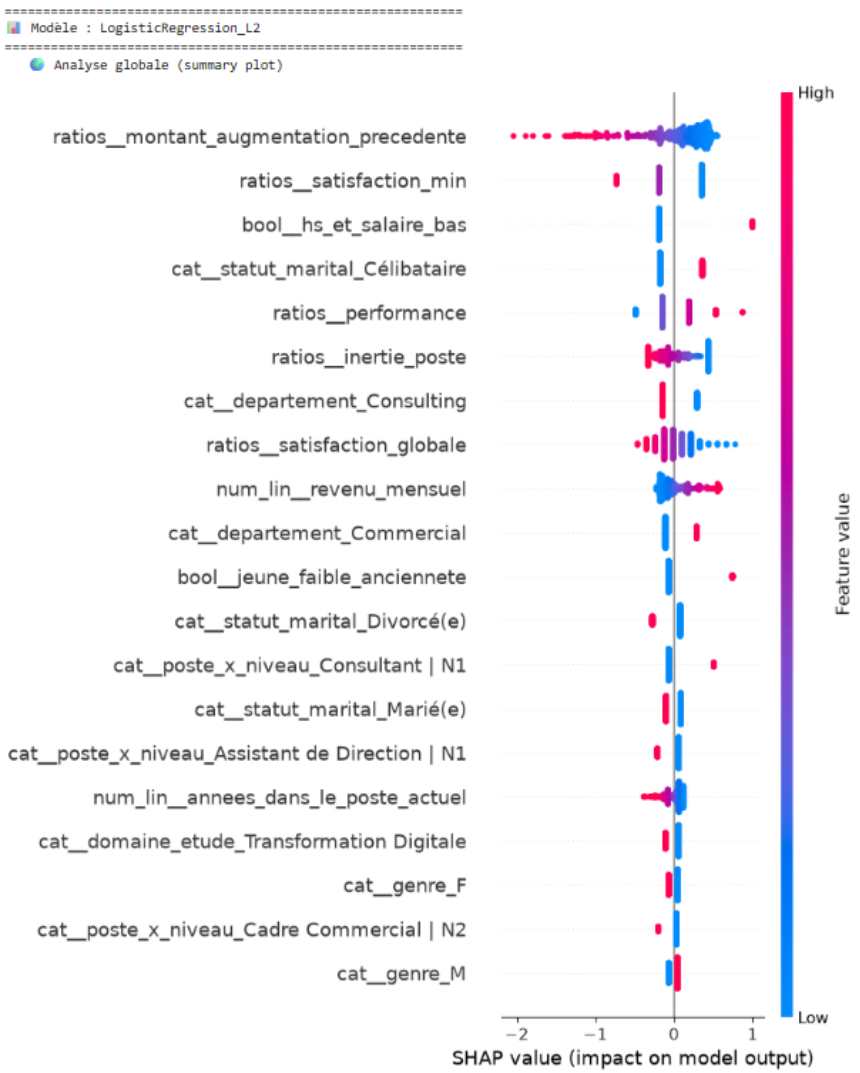




14 départ trouvé
33 raté.
77 alertes dont
44 fausses

11. Analyse Shap

11.1 Global

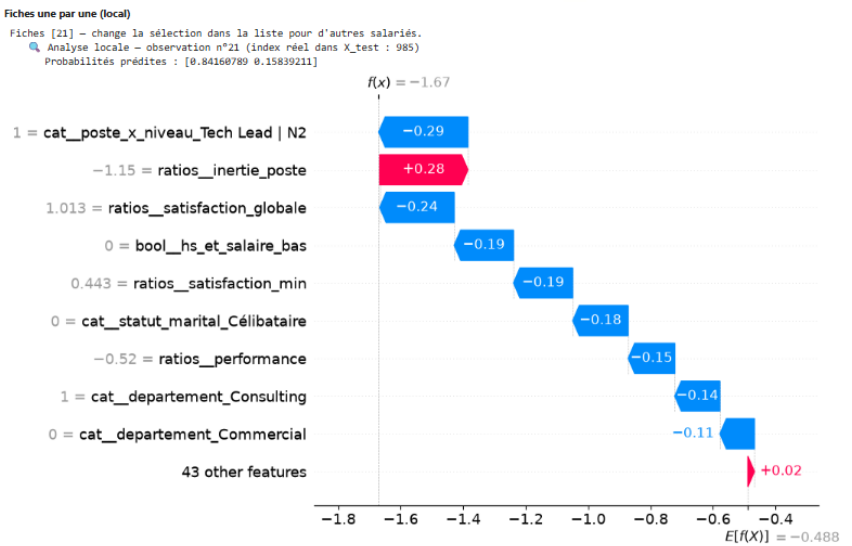


11.2 Local

```
Positions dans X_test (pour SHAP) : [21, 29, 82, 155, 164, 240]
Index pandas : [985, 45, 126, 122, 547, 1111]
   index  position     proba
0    985        21  0.112542
1     45        29  0.136092
2    126        82  0.157787
3    122       155  0.167485
4    547       164  0.103648
5   1111       240  0.339756
```

Exemple : Pourquoi le n°21 à t'il été raté pour la prédiction du départ de l'entreprise?

Ce qu'il est	Effet
Tech Lead **N2**	fort vers **Reste**
sat globale / sat min pas au plancher	Reste
pas HS + bas salaire (hs_et_salaire_bas = 0)	Reste
pas célibataire	Reste
Consulting (pas Commercial)	Reste
perf un peu basse	encore Reste ici



11. Conclusion

L'attrition ne se répartit pas au hasard : elle se concentre sur un **profil junior peu ancré** (âge, salaire, ancienneté, niveau).
Les matrices le montrent comme **un seul axe**, et non plusieurs causes séparées, mais s'ajoute a cela des variables qualitatives et multi causales tel que les heures supplémentaires, les postes occupés ou la satisfaction, etc...

Les features métier sont ainsi gardées si elles **parlent du départ** sans alourdir les modèles avec des indications redondantes.
Elles sont traitées dans un préprocesseur par familles (linéaire / non-linéaire / texte / binaire), puis on les envoies dans des split de CV **stratifiés** avant que les modèles ne donnent des résultats de recherches**.**

On juge alors en deux deux temps :
1-La **pastille** de couleurs (ROC-AUC train vs CV) dit si le modèle est **solide concernant ses plis.**
2-La **courbe précision–rappel** et la **matrice test** disent si le filet des features RH est tenable.

LogisticRegression_None a été choisi dans ce document en guise de modèle simplifié pour l'étude, lorsque les features sont modifiés l'on peut voir que se gonfle le train par rapport au test et si trop peu de features sont sélectionnées on obtient de bons résultats mais cela étale les doutes des modèles et multiplie les fausses alertes impactant ainsi la précision.

Je choisie alors un modèle plus performant sur les deux axe **Précision/Rappel** et je demande à la bibliothèque **GridShearchCV** d'optimiser les paramètres.
J'ajuste ensuite le seuil en rapport a la **demande RH**, car en fonction de → + de précision et moins de fausse alerte Ou + de départs trouvés et - de fausses alertes le seuil sera ajusté en conséquence.

« Un récit **junior + HS / poste etc...** Un modèle **stable hors échantillon**, un seuil **réglé sur le test a la demande du besoin**. »