P6-Initiez-vous au MLOps

Mission: Data Scientist au sein d'une société financière, nommée "Prêt à dépenser", qui propose des crédits à la consommation pour des personnes ayant peu ou pas du tout d'historique de prêt.

Objectif : L'entreprise souhaite **mettre en œuvre un outil de "scoring crédit" pour calculer la probabilité** qu'un client rembourse son crédit, puis classifie la demande en crédit accordé ou refusé. Elle souhaite donc développer un **algorithme de classification** en s'appuyant sur des sources de données variées (données comportementales, données provenant d'autres institutions financières, etc.)

14/10/2026

1.Exploration

1.1 Vues tabulaires des DataFrames

--- describe() : variables numériques ---

	count	mean	std	min	25%	50%	75%	max
SK_ID_CURR	48,744.00	277,796.68	103,169.55	100,001.00	188,557.75	277,549.00	367,555.50	456,250.00
CNT_CHILDREN	48,744.00	0.40	0.71	0.00	0.00	0.00	1.00	20.00
AMT_INCOME_TOTAL	48,744.00	178,431.81	101,522.59	26,941.50	112,500.00	157,500.00	225,000.00	4,410,000.00
AMT_CREDIT	48,744.00	516,740.44	365,397.00	45,000.00	260,640.00	450,000.00	675,000.00	2,245,500.00
AMT_ANNUITY	48,720.00	29,426.24	16,016.37	2,295.00	17,973.00	26,199.00	37,390.50	180,576.00
AMT_GOODS_PRICE	48,744.00	462,618.84	336,710.22	45,000.00	225,000.00	396,000.00	630,000.00	2,245,500.00

--- describe() : variables catégorielles ---

	count	unique	top	freq
NAME_CONTRACT_TYPE	48744	2	Cash loans	48305
CODE_GENDER	48744	2	F	32678
FLAG_OWN_CAR	48744	2	N	32311
FLAG_OWN_REALTY	48744	2	Y	33658
NAME_TYPE_SUITE	47833	7	Unaccompanied	39727

df.head() aperçu des première lignes
df.describe() description des colonnes numériques
-moyenne (données symétriques/asymétriques)
-valeur min/max
-quartiles
-écart type
df.info() nombre de lignes/colonnes, types et valeurs non nulle

```
application_test                  (48744, 121)
application_train                 (307511, 122)
bureau                            (1716428, 17)
bureau_balance                    (27299925, 3)
credit_card_balance               (3840312, 23)
HomeCredit_columns_description    (219, 5)
installments_payments             (13605401, 8)
POS_CASH_balance                  (10001358, 8)
previous_application              (1670214, 37)
sample_submission                 (48744, 2)
```

```
--- info() ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48744 entries, 0 to 48743
Data columns (total 121 columns):
 #    Column                       Non-Null Count  Dtype
---   ------                       --------------  -----
 0    SK_ID_CURR                   48744 non-null  int64
 1    NAME_CONTRACT_TYPE           48744 non-null  object
 2    CODE_GENDER                  48744 non-null  object
 3    FLAG_OWN_CAR                 48744 non-null  object
 4    FLAG_OWN_REALTY              48744 non-null  object
 5    CNT_CHILDREN                 48744 non-null  int64
 6    AMT_INCOME_TOTAL             48744 non-null  float64
```

type de variable		
identifiant	1	0.8
binaire	37	30.6
quantitative discrète	9	7.4
quantitative continue	63	52.1
qualitative	11	9.1

--- Nombre de colonnes par type pandas (dtype) ---

type pandas	nb_colonnes
float64	65
int64	40
object	16

Rechercher : NAME_CONTRACT_TYPE

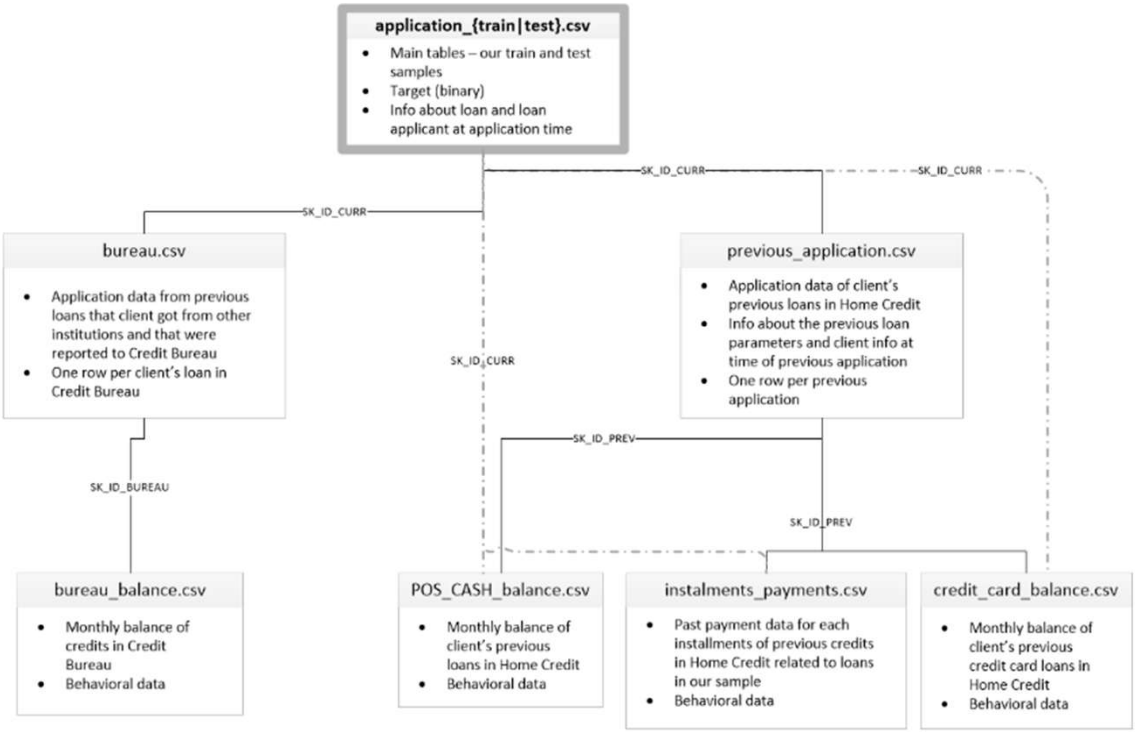
	Correspondance	Table	Row	Description
0	nom exact	application_{train|test}.csv	NAME_CONTRACT_TYPE	Identification if loan is cash or revolving
1	nom exact	previous_application.csv	NAME_CONTRACT_TYPE	Contract product type (Cash loan, consumer loan [POS] ,...) of the previous application

Classifiez automatiquement des informations

Le jeu de données est composé de plusieurs tables liées entre elles par des identifiants.

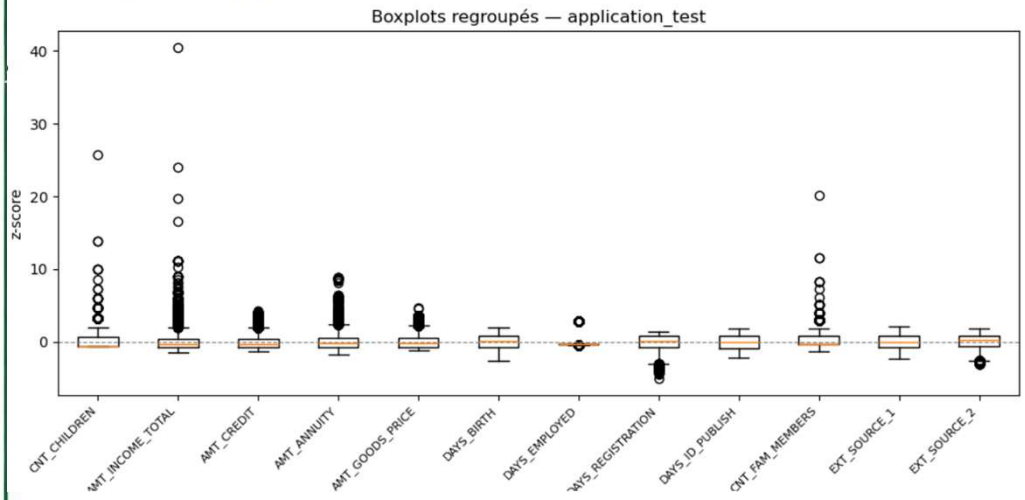
```
application_train / test          (1 ligne par client, clé SK_ID_CURR)
│
├── bureau                        (plusieurs crédits externes par client)
│     └── bureau_balance          (plusieurs mois par crédit, via SK_ID_BUREAU)
│
└── previous_application          (plusieurs demandes passées par client)
      ├── POS_CASH_balance        (via SK_ID_PREV)
      ├── credit_card_balance     (via SK_ID_PREV)
      └── installments_payments   (via SK_ID_PREV)
```

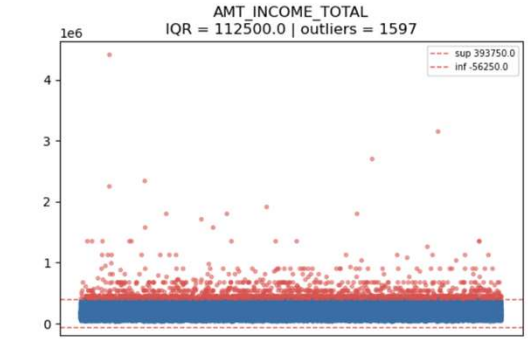
This diagram shows how all of the data is related:

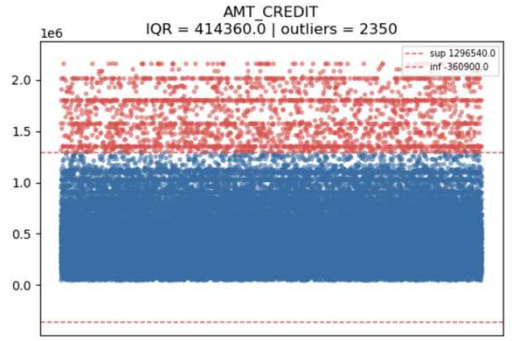


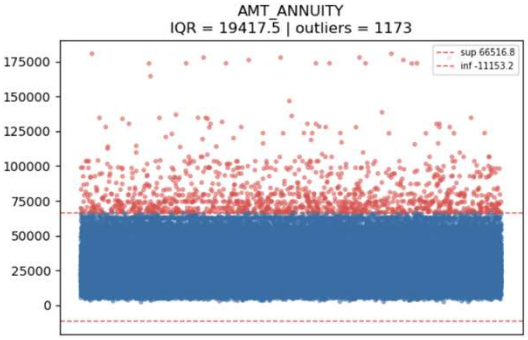
1.2 Vues graphiques des DataFrames

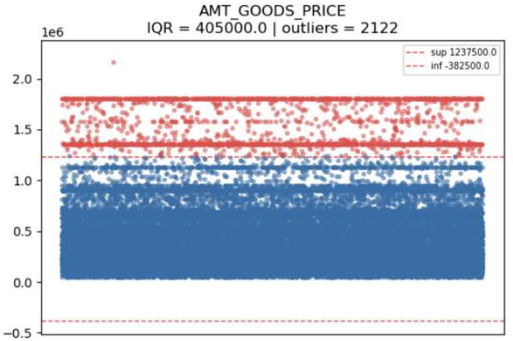
=== Boxplots regroupés : application_test ===



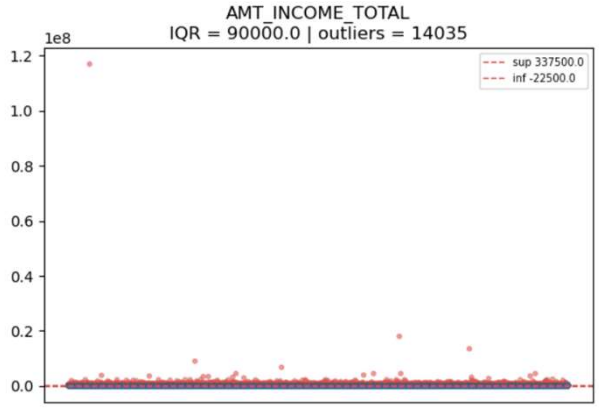




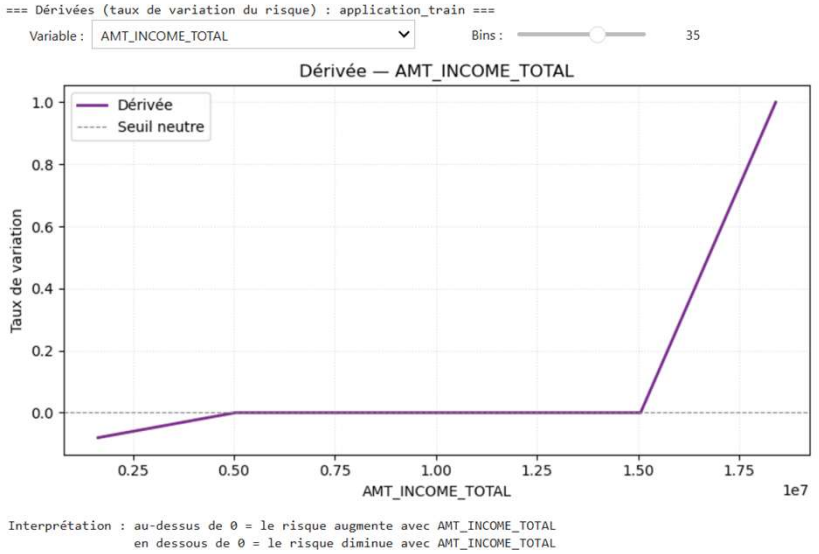


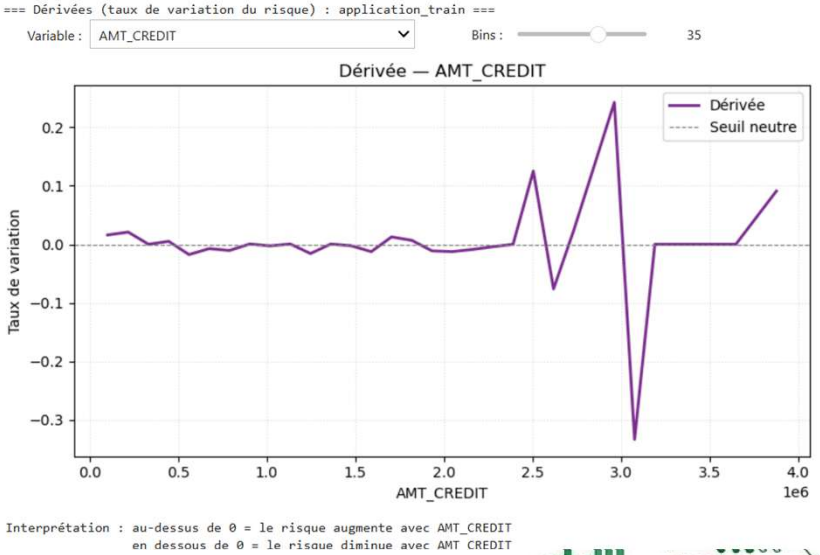


z automatiquement des informations



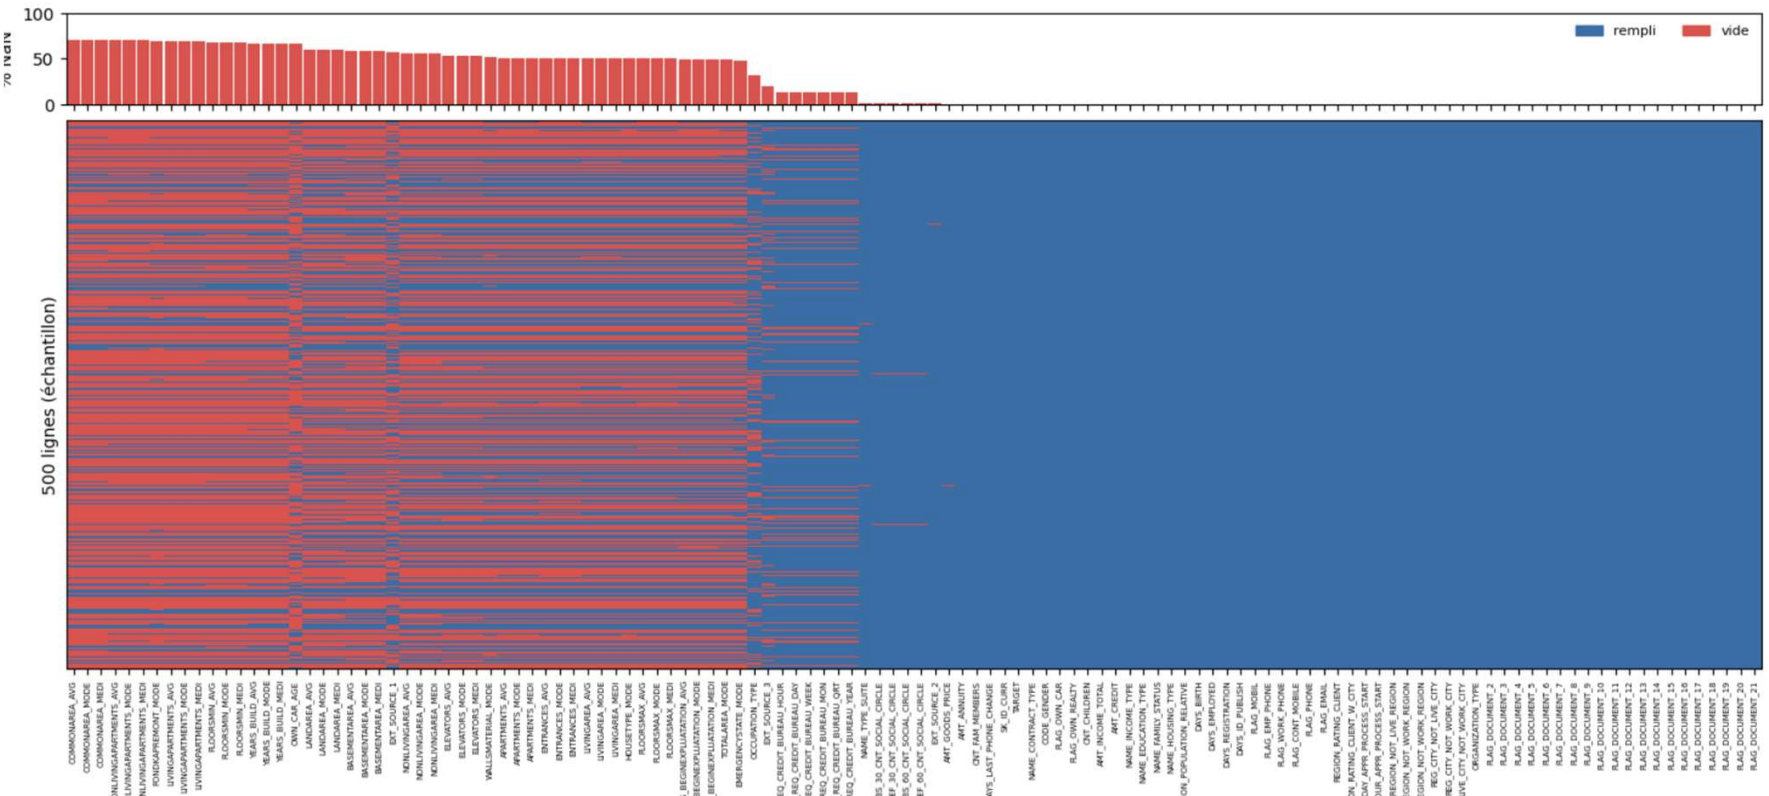
Arbre de décision / LightGBM	Faible (le point va dans une feuille isolée)
Forêt aléatoire	Faible (même principe)



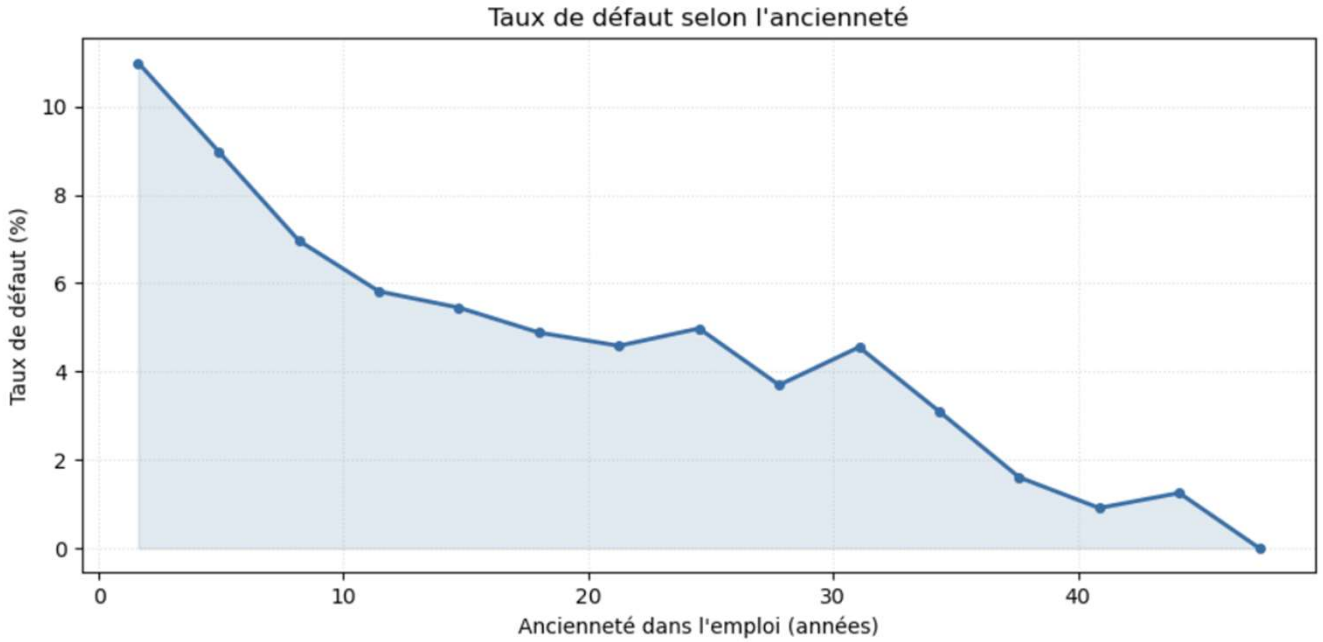


Classifiez automatiquement des informations

application_train : 24.4% de cellules manquantes (307 511 lignes, 122 colonnes)

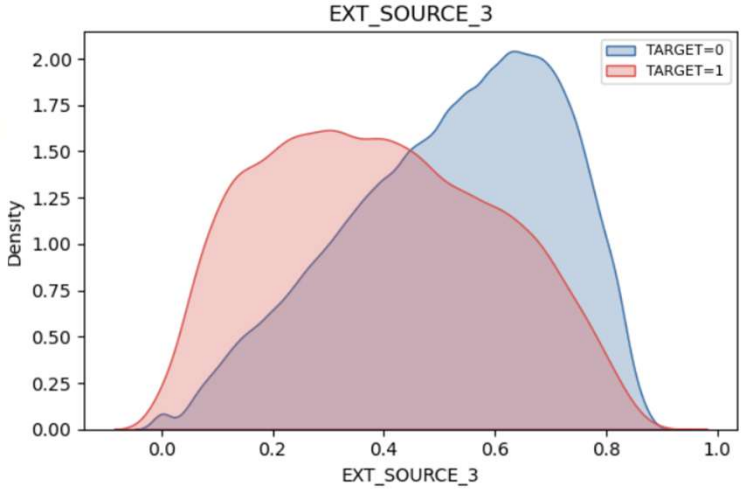


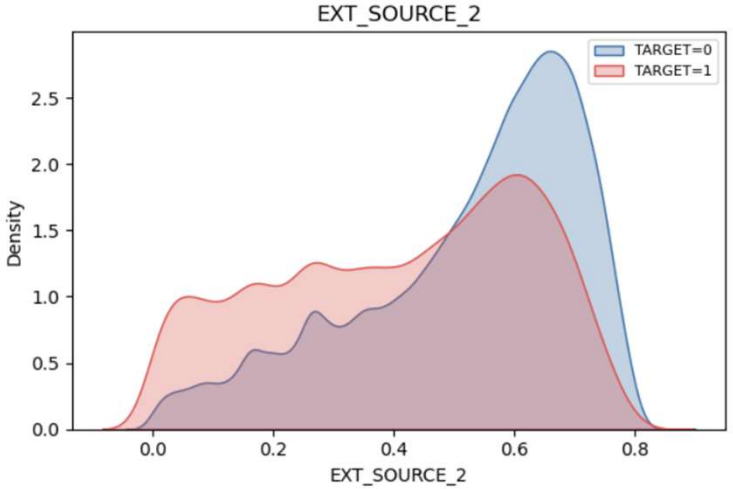
```
--- Ancienneté dans l'emploi ---
```



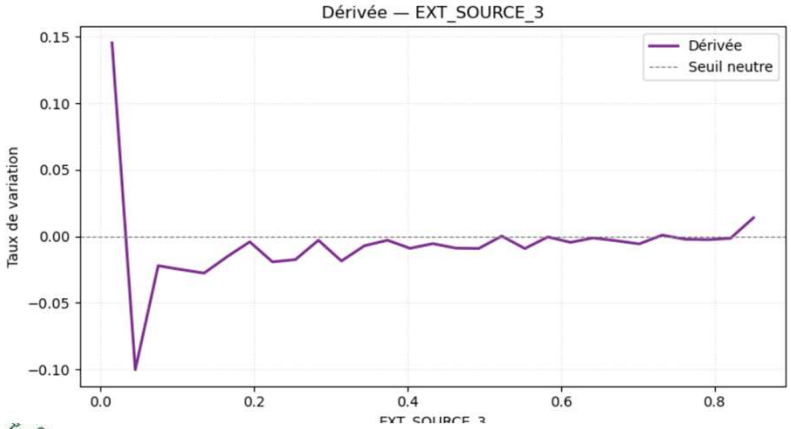
4.2 Analyse des formes et mouvements de la distribution des variables vers Y

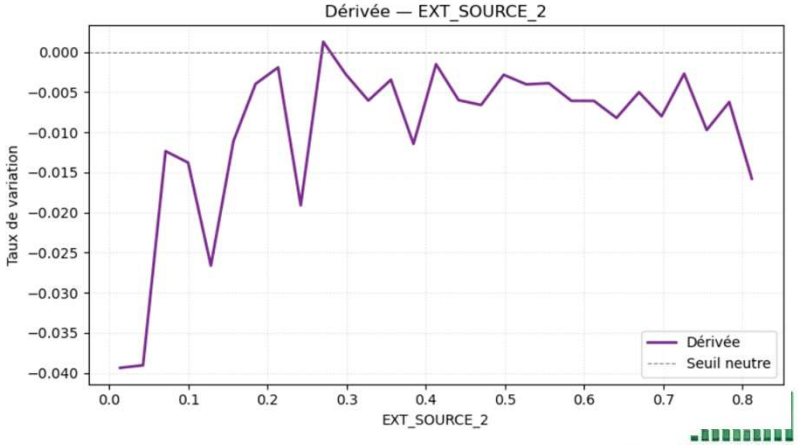
4.2.1 La forme





4.2.2 Le mouvement





3. Nettoyage de la donnée et consolidation d'un nouveau Dataframe

3.1 Récupéré du process du fichier kaggle

```
======================================================================
FUSION HOME CREDIT — ce qui est récupéré des fichiers Kaggle
======================================================================

INDISPENSABLES :
  • application_train  → 1 ligne / client + TARGET (défaut)
  • bureau             → crédits extérieurs
  • previous_application → demandes antérieures
  • installments_payments → historique des échéances

OPTIONNELS (fusionnés si présents) :
  • bureau_balance, POS_CASH_balance, credit_card_balance

LAISSÉS DE CÔTÉ :
  • application_test (pas de TARGET)
  • sample_submission, HomeCredit_columns_description
======================================================================
```

```
=== Clients distincts : application_test ===
SK_ID_CURR.nunique() = 48 744
Nombre de lignes = 48 744
Ratio lignes / clients ≈ 1.00
```

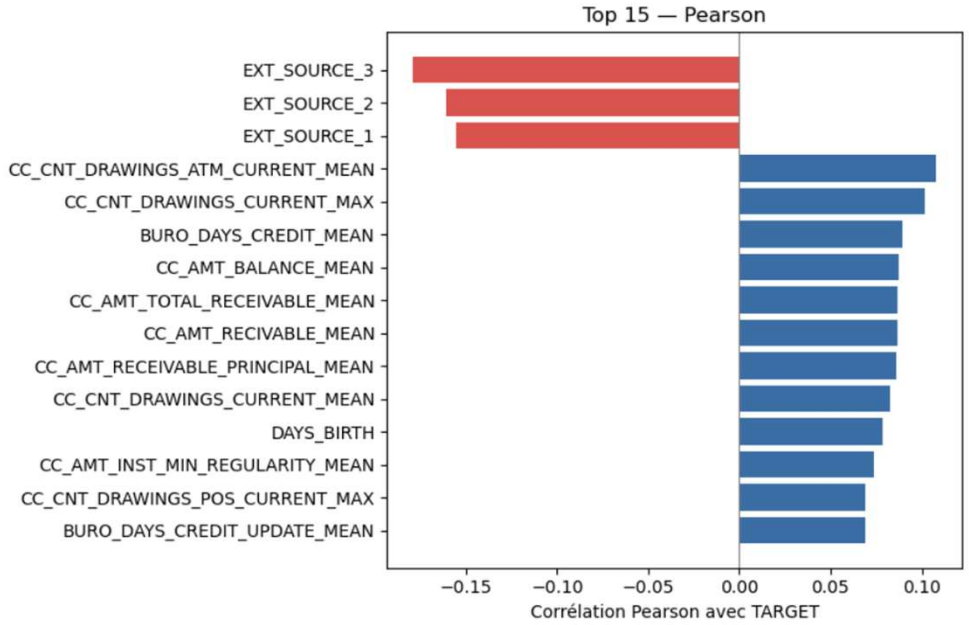
```
=== Clients distincts : application_train ===
SK_ID_CURR.nunique() = 307 511
Nombre de lignes = 307 511
Ratio lignes / clients ≈ 1.00
```

On résume chaque client par leur max mean et count : exemple : mean : Montant moyen des crédits extérieurs

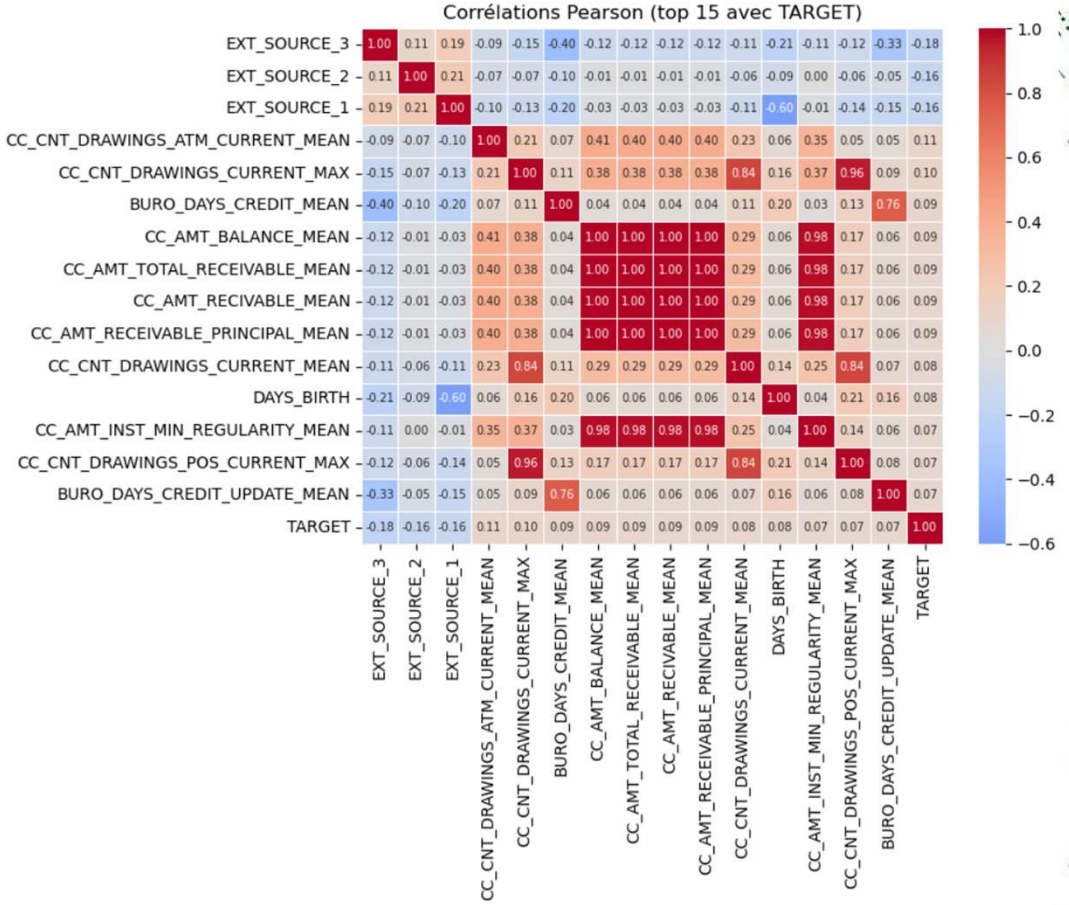
Max: Le plus gros crédit qu'il a eu
Count : Combien de crédits bureau il a.

Si trois crédits dans un bureau :
1-10 000
2-25 000
3-5 000
BURO_AMT_CREDIT_MEAN : 13 333
BURO_AMT_CREDIT_MAX: 25 000
BURO_COUNT: 3

Le script de clean fusion est est présent sur cette page :LightGBM with Simple Features



--- Heatmap avec la cible ---



EXT_SOURCE : Plus la variable augmente plus le risque diminue

4 L'hypothèse

4.1 Analyse des corrélations avec Y dans le but de créer de nouvelles features

Observation	Hypothèse
EXT_SOURCE_* négativement corrélés	Les scores externes capturent une information de risque non présente dans les données internes
Variables CC_* positivement corrélées entre elles	Les variables liées à la carte de crédit sont fortement corrélées entre elles, ce qui indique une redondance.
BURO_DAYS_CREDIT_MEAN positif avec TARGET	Des crédits bureau plus anciens (ou plus nombreux) sont associés à un risque légèrement plus élevé
Corrélations globalement faibles (< 0,2)	Aucune variable seule ne suffit à prédire le défaut → le modèle doit combiner plusieurs signaux

Globalement, les corrélations des indicateurs restent modestes, justifiant l'usage d'un modèle non linéaire capable de combiner plusieurs signaux.

6. Sélection des features pertinentes

5.1 Panneau de sélection des features

```
entrée : 307511 clients, 257 colonnes

FEATURES DÉRIVÉES
  Inspirées des kernels Kaggle de référence :
  • LightGBM with Simple Features (Aguiar)
  • Start Here: A Gentle Introduction (Koehrsen)
  Objectif : créer des ratios et indicateurs qui capturent
  des relations métier non présentes dans les colonnes brutes.

• Demande : DAYS_EMPLOYED_PERC, INCOME_CREDIT_PERC, INCOME_PER_PERSON, AGE_YEARS
  → Ratios recommandés dans les kernels pour normaliser le revenu
    et l'ancienneté par rapport au crédit et à l'âge.
• Bureau : BURO_DEBT_RATIO, SANS_BUREAU
  → Ratio d'endettement externe + indicateur d'absence d'historique.
• Previous : PREV_REFUSED_RATIO, SANS_PREVIOUS
  → Part des demandes antérieures refusées (signal de risque).
• Absences : SANS_INSTAL, SANS_POS, SANS_CARTE
  → 1 si le client n'a pas cet historique (info utile pour le modèle).
• Externe : EXT_SOURCE_MEAN
  → Moyenne des scores externes (souvent le meilleur prédicteur).

======================================================================
preprocessing terminé : X (307511, 249), y (307511,)
doublons : 0
cible : 8.07% de défauts
NaN dans X : 29.4% (gardés, LightGBM les gère)
```

Classifiez automatiquement des informations

--- Interface de sélection ---

- [x] Demande (27) — Voir
- [x] Ratios (5) — Voir
- [x] Bureau (26) — Voir
- [x] Demandes antérieures (39) — Voir
- [x] Échéances (15) — Voir
- [x] POS (optionnel) (13) — Voir
- [x] Cartes (optionnel) (43) — Voir
- [x] Absences (4) — Voir
- [ ] Autres numériques (79) — Voir

Tout cocher | Tout décocher | Construire X et y

[x] Ratios (5) — Voir

```
Ratios — 5 variables
  DAYS_EMPLOYED_PERC
  INCOME_CREDIT_PERC
  INCOME_PER_PERSON
  AGE_YEARS
  BURO_DEBT_RATIO
```

7. Découpage Train/Test et stratification

```
Utilisation de la sélection (fs.interface.resultat)
X (307511, 170)   défauts 8.07%
```

Découpage

Part test — 0.20

Folds — 5

Répétitions — 1

☑ Stratifié sur TARGET

Gestion du déséquilibre

Pondération des classes

- Aucune (stratification seule)
- Pondération des classes
- SMOTE
- Pondération + SMOTE

```
DÉCOUPAGE
  train      : 246008 clients (8.07% de défauts)
  validation : 61503 clients (8.07% de défauts)
  variables  : 170
  validation croisée : StratifiedKFold(5)

GESTION DU DÉSÉQUILIBRE
  → Pondération + SMOTE
     Justification : combinaison des deux approches.

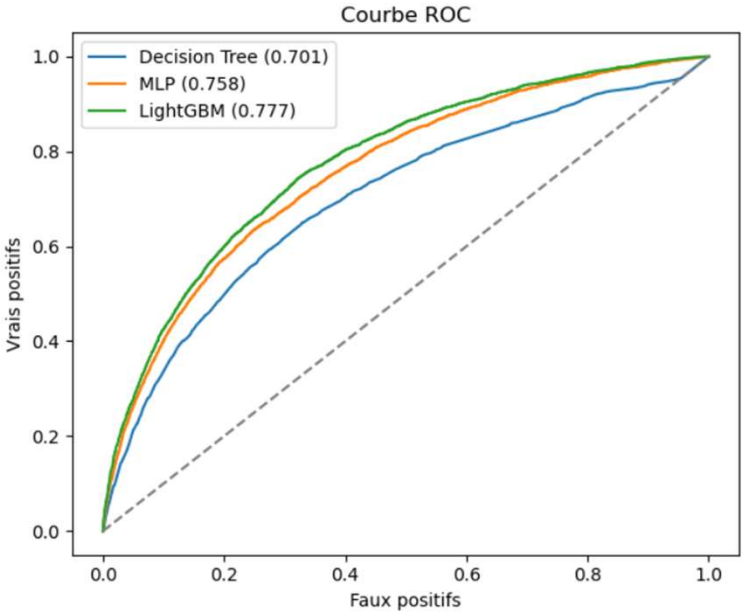
Disponible dans tt.interface.resultat
  → (X_tr, X_va, y_tr, y_va, cv, methode)
```

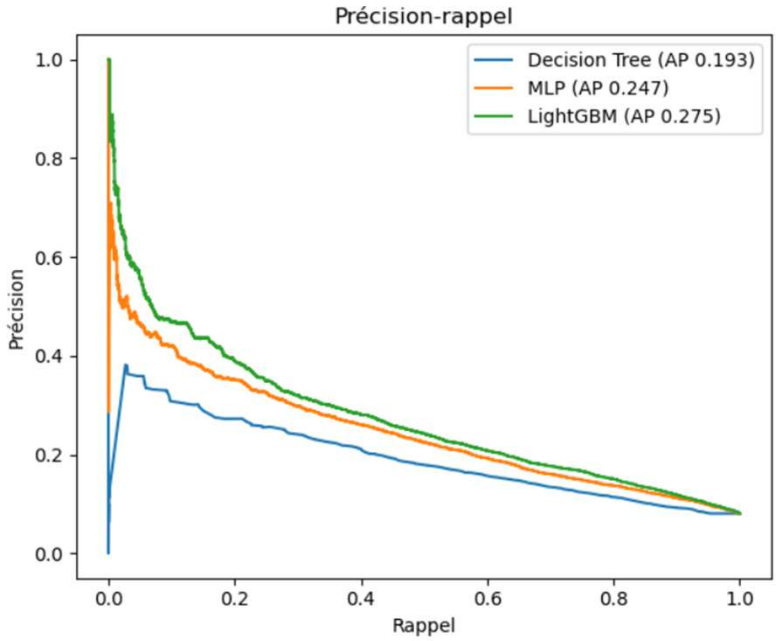
8. Préprocesseur

```
PRÉPROCESSEUR
  LightGBM              : passthrough, NaN conservés (comme le kernel)
  Régression logistique : médiane + standardisation
  Forêt aléatoire       : médiane, pas de standardisation
Pas de one-hot : les catégorielles utiles sont déjà numériques après la fusion.
Disponible dans pp.interface.resultat
```

9. Modélisation et interprétation

	Model	ROC_AUC_cv	ROC_AUC_cv_std	F1_cv	F1_cv_std	ROC_AUC_train	ROC_AUC_train_cv_mean	ROC_AUC_test	PR_AUC_test	Accuracy_test	Precision_test	Recall_test	F1_test	Duration_s	Seuil_utilise	Ecart_Train_CV	Ecart_CV_Test	Diagnostic
2	LightGBM	0.773	0.002	0.288	0.002	0.846	0.860	0.777	0.275	0.730	0.182	0.675	0.287	100.300000	0.500000	0.087	-0.004	Surapprentissage
1	MLP	0.754	0.003	0.030	0.008	0.780	0.777	0.758	0.247	0.919	0.516	0.030	0.057	131.400000	0.500000	0.023	-0.005	Bien équilibré
0	Decision Tree	0.689	0.003	0.238	0.003	0.790	0.797	0.701	0.193	0.675	0.149	0.641	0.242	88.100000	0.500000	0.108	-0.013	Surapprentissage





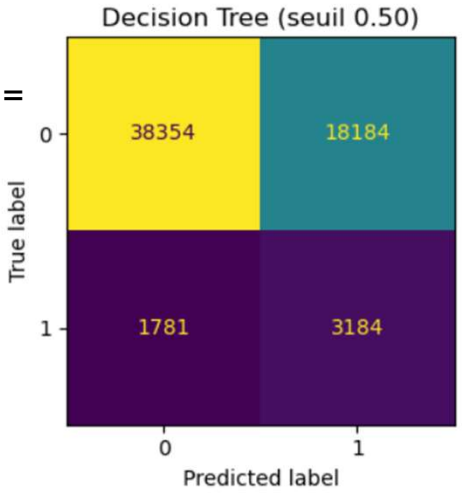
Classifiez automatiquement des informations

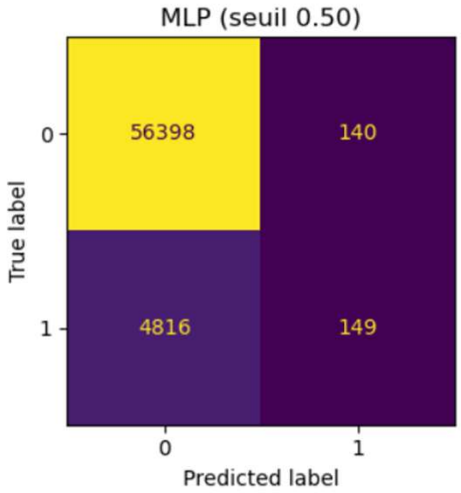
TN =

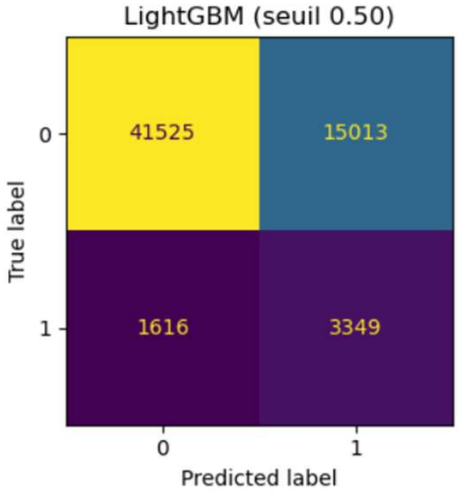
= FN

FN =

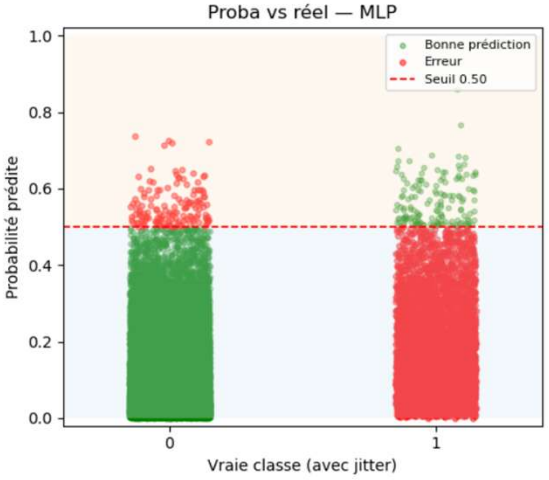
= TP

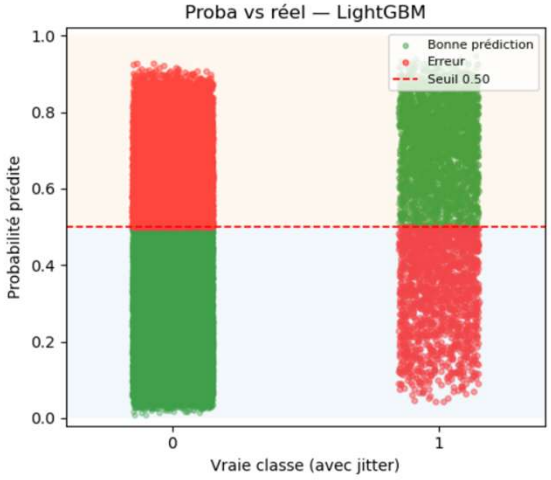




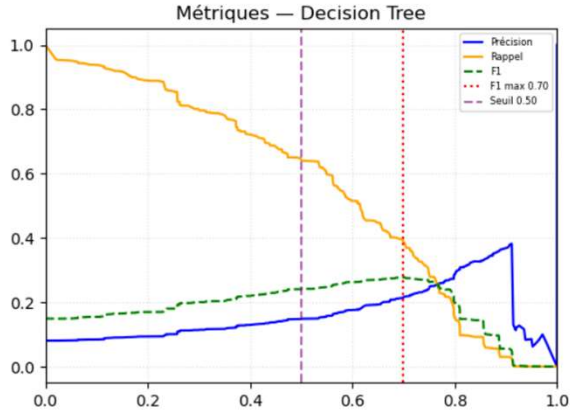


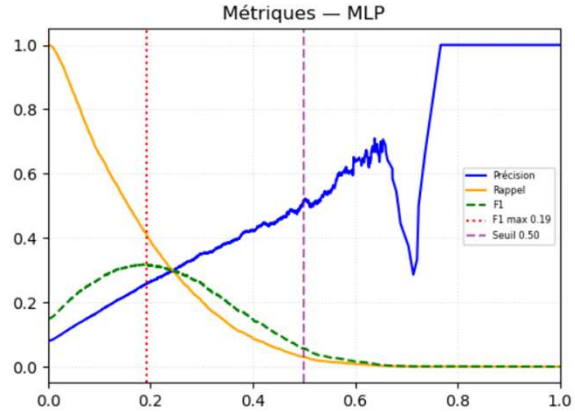


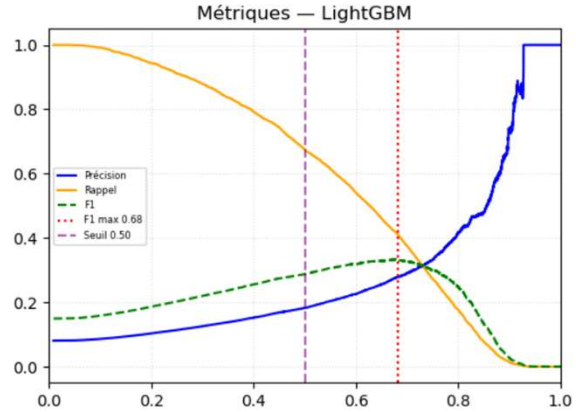


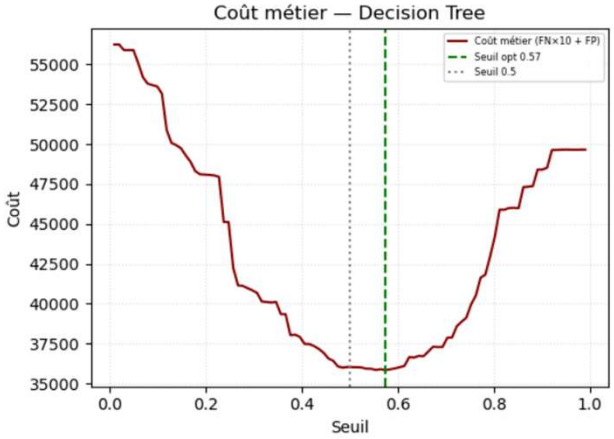


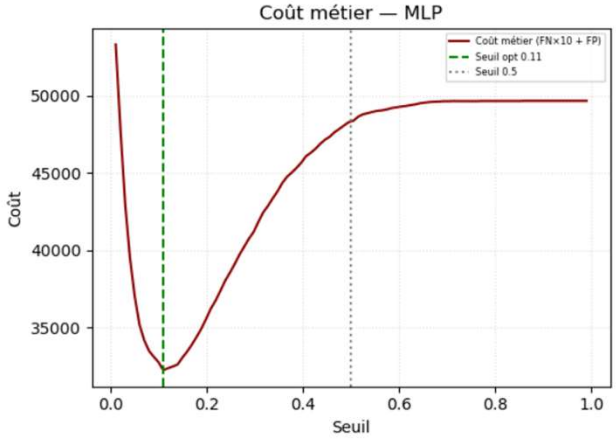
FN (Faux Négatif) = Mauvais client accepté → perte en capital coût 10 Si trop bas → trop de FP (refus inutiles)
FP (Faux Positif) = Bon client refusé → manque à gagner coût 10 Si trop haut → trop de FN (crédits accordés à des mauvais payeurs
Coût métier = (FN X 10) + (FP X 1)
LightGBM a le coût le plus bas car il sépare mieux les deux classes.

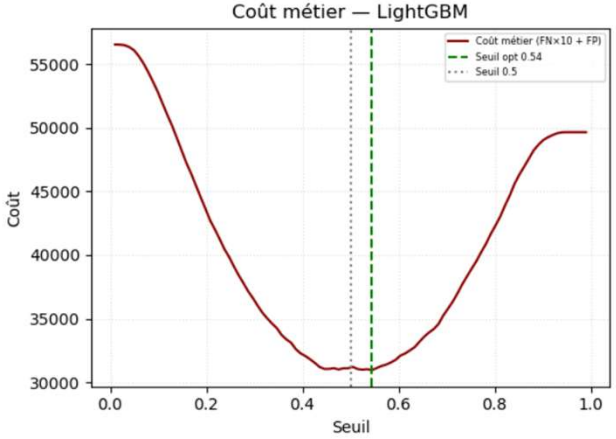






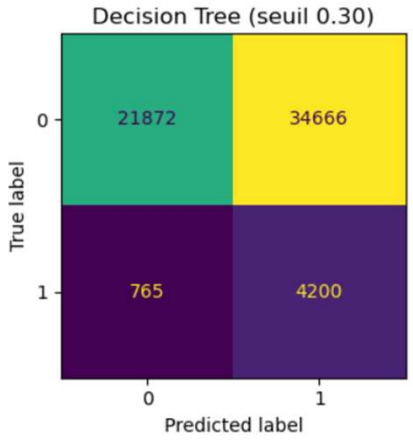


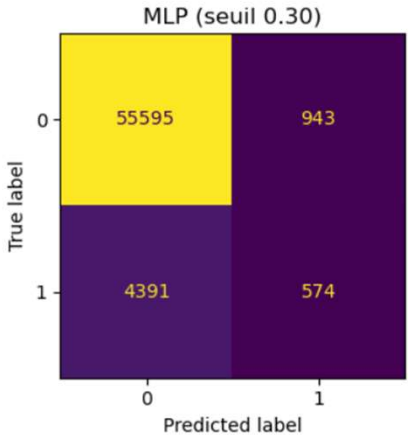


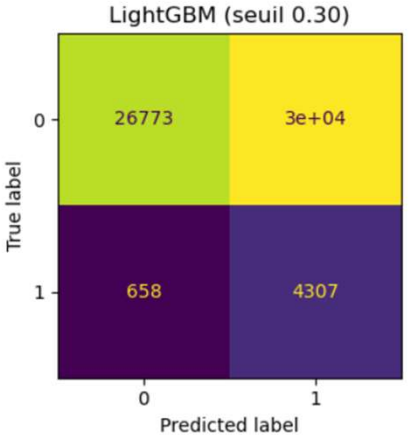


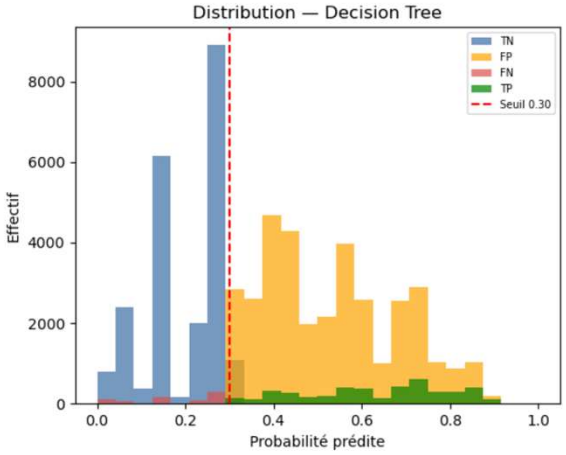
Coût global des erreurs de prédiction FN X10 + FP X1

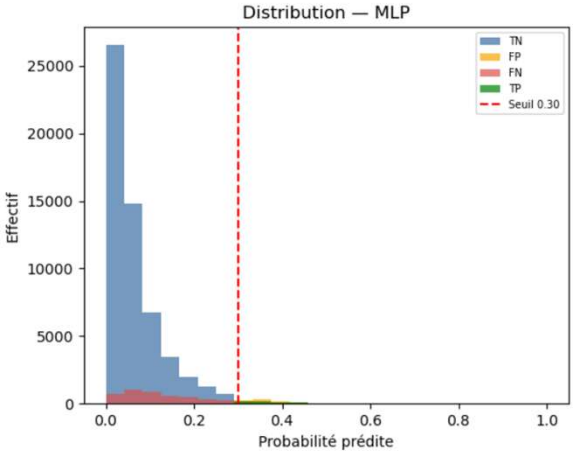
Classifiez automatiquement des informations

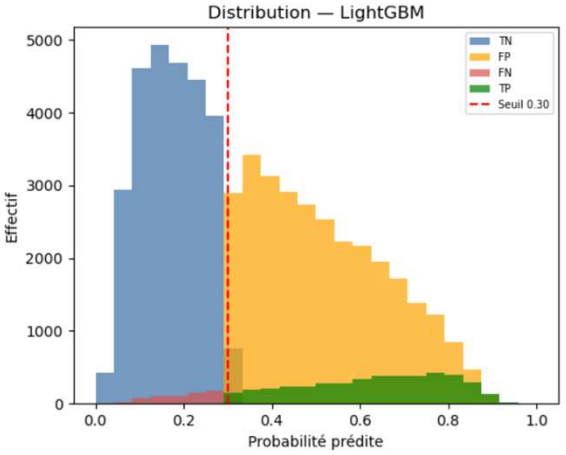






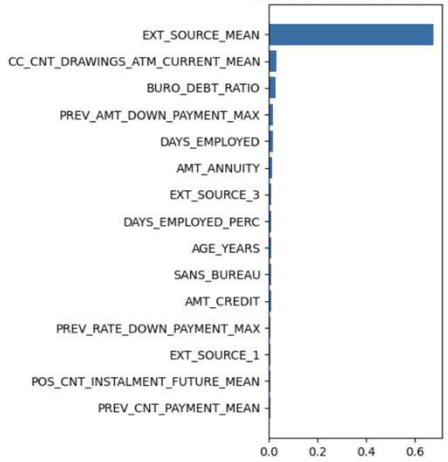




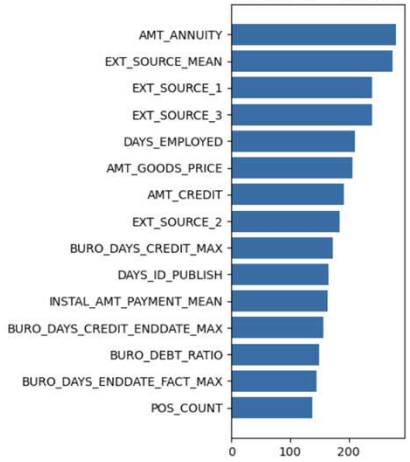


test

Classifiez automatiquement des informations



MLP
(non disponible)



Decision Tree

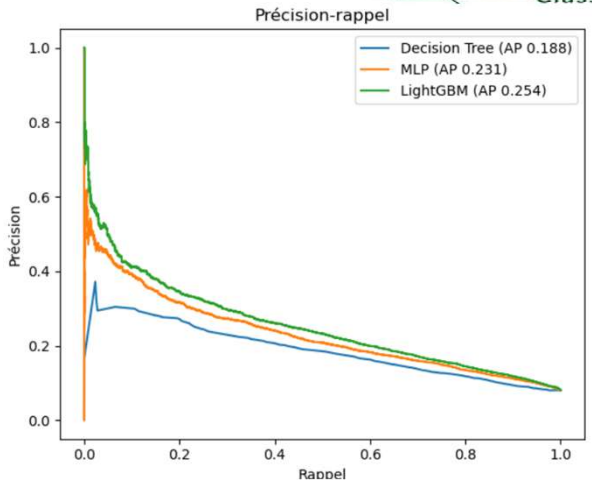
	Feature	Residuals	Abs_Residuals
16	EXT_SOURCE_2	0.233000	-0.424000
17	EXT_SOURCE_3	0.174000	-0.326000
6	DAYS_BIRTH	-0.116000	0.216000
15	EXT_SOURCE_1	0.084000	-0.166000
18	DAYS_LAST_PHONE_CHANGE	-0.074000	0.139000
12	REGION_RATING_CLIENT	-0.057000	0.133000
7	DAYS_EMPLOYED	-0.068000	0.133000
13	REGION_RATING_CLIENT_W_CITY	-0.055000	0.132000
9	DAYS_ID_PUBLISH	-0.052000	0.108000
8	DAYS_REGISTRATION	-0.052000	0.104000
5	REGION_POPULATION_RELATIVE	0.049000	-0.102000
4	AMT_GOODS_PRICE	0.048000	-0.092000

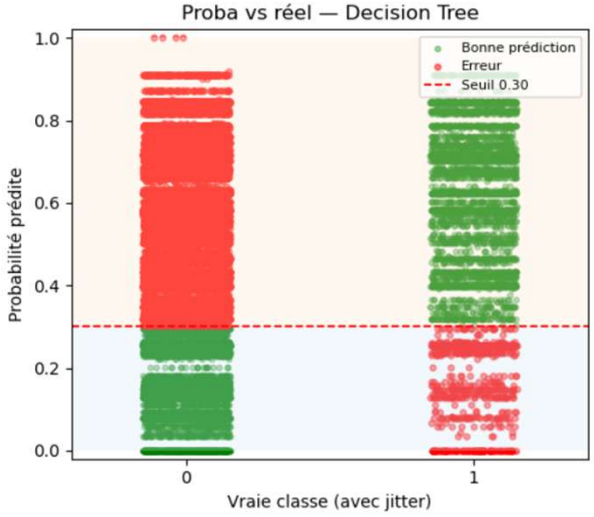
	Feature	Residuals	Abs_Residuals
16	EXT_SOURCE_2	-0.016000	-0.265000
17	EXT_SOURCE_3	-0.005000	-0.203000
6	DAYS_BIRTH	0.020000	0.126000
13	REGION_RATING_CLIENT_W_CITY	0.019000	0.097000
15	EXT_SOURCE_1	-0.017000	-0.096000
18	DAYS_LAST_PHONE_CHANGE	-0.007000	0.095000
12	REGION_RATING_CLIENT	0.018000	0.094000
7	DAYS_EMPLOYED	-0.004000	0.090000
9	DAYS_ID_PUBLISH	0.012000	0.078000
8	DAYS_REGISTRATION	0.009000	0.065000
4	AMT_GOODS_PRICE	-0.005000	-0.059000
5	REGION_POPULATION_RELATIVE	-0.015000	-0.057000

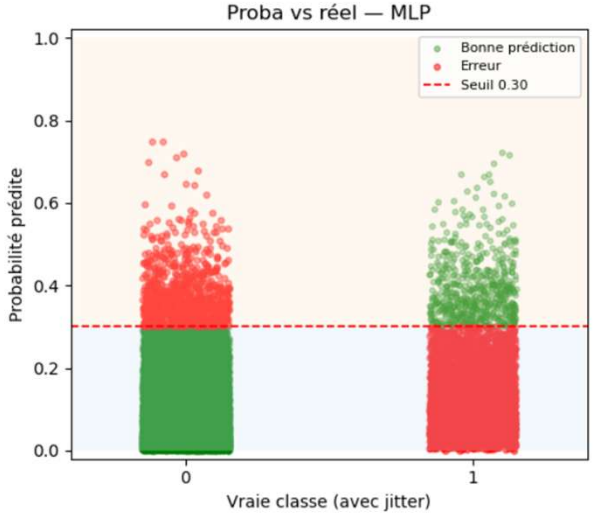
LightGBM

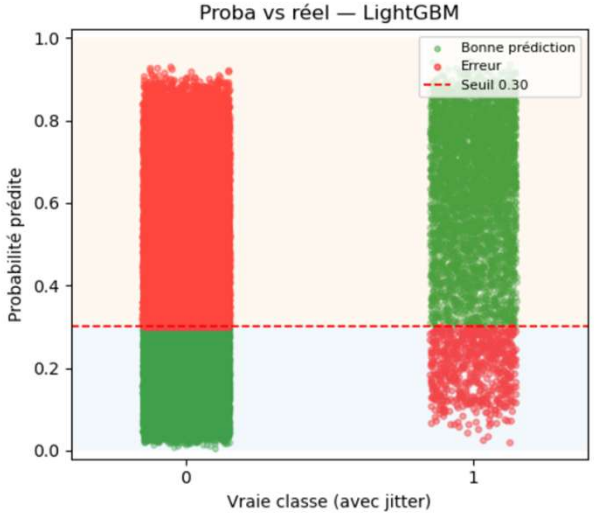
	Feature	Residuals	Abs_Residuals
16	EXT_SOURCE_2	0.254000	-0.444000
17	EXT_SOURCE_3	0.222000	-0.374000
6	DAYS_BIRTH	-0.134000	0.233000
15	EXT_SOURCE_1	0.132000	-0.220000
13	REGION_RATING_CLIENT_W_CITY	-0.093000	0.173000
12	REGION_RATING_CLIENT	-0.093000	0.171000
7	DAYS_EMPLOYED	-0.093000	0.162000
18	DAYS_LAST_PHONE_CHANGE	-0.097000	0.160000
9	DAYS_ID_PUBLISH	-0.083000	0.144000
5	REGION_POPULATION_RELATIVE	0.073000	-0.128000
8	DAYS_REGISTRATION	-0.075000	0.126000
4	AMT_GOODS_PRICE	0.071000	-0.117000

Classifiez automatiquement des informations









	fold	auc_train	auc_test	f1_test
0	1	0.760	0.756	0.268
1	2	0.761	0.754	0.265
2	3	0.759	0.762	0.270
3	4	0.760	0.756	0.266
4	5	0.760	0.756	0.267

« Une AUC de 0,77 signifie que le modèle classe correctement 77 % des paires (défaut, non-défaut). Au seuil optimal de 0,53, le coût métier est de 30 935, soit environ 1 775 défauts non détectés (× 10) et 13 185 bons clients refusés (× 1). »

10. Fine-tunning

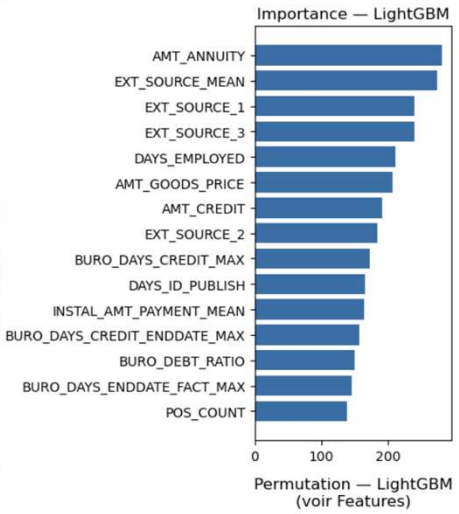
```
--- Analyse du meilleur modèle ---
LightGBM tuné  AUC 0.7692 | coût opt 31,326
```

Tableau | ROC | Précision-rappel | Matrice | Proba vs réel | Courbe de seuil

	Model	ROC_AUC_cv	ROC_AUC_train	ROC_AUC_test	PR_AUC_test	Accuracy	Precision	Recall	F1	Seuil_utilise	Seuil_opt	Coût_opt	FN_opt	FP_opt
0	LightGBM tuné	0.771	0.859	0.769	0.255	0.92	0.55	0.023	0.044	0.53	0.09	31326	1682	14506

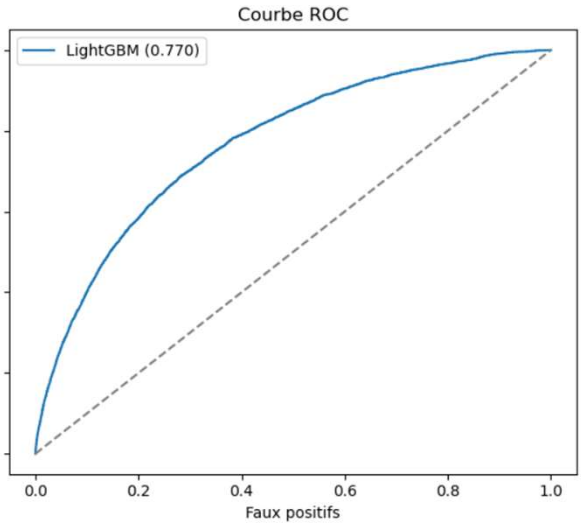
```
meilleure combinaison : {'learning_rate': 0.05, 'min_child_samples': 50, 'n_estimators': 300, 'num_leaves': 31}
run MLflow : lightgbm-tuning
```

Importance



Permutations

	Feature	Importance	Ecart_type
102	INSTAL_DAYS_INSTALMENT_MAX	0.0123	0.0012
104	INSTAL_DAYS_ENTRY_PAYMENT_MAX	0.0063	0.0009
100	INSTAL_NUM_INSTALMENT_NUMBER_MAX	0.0037	0.0005
112	POS_MONTHS_BALANCE_MEAN	0.0030	0.0014
40	BURO_AMT_CREDIT_MAX_OVERDUE_MAX	0.0030	0.0016
120	POS_SK_DPD_DEF_MEAN	0.0027	0.0009
48	BURO_AMT_CREDIT_SUM_LIMIT_MAX	0.0027	0.0012
28	INCOME_PER_PERSON	0.0023	0.0009
18	DAYS_LAST_PHONE_CHANGE	0.0023	0.0005
39	BURO_AMT_CREDIT_MAX_OVERDUE_MEAN	0.0023	0.0045
47	BURO_AMT_CREDIT_SUM_LIMIT_MEAN	0.0023	0.0017
26	EXT_SOURCE_MEAN	0.0023	0.0048
137	CC_AMT_DRAWINGS_POS_CURRENT_MEAN	0.0020	0.0016
5	REGION_POPULATION_RELATIVE	0.0020	0.0008
103	INSTAL_DAYS_ENTRY_PAYMENT_MEAN	0.0020	0.0022



	Residuals	Abs_Residuals
Abs_Residuals	-0.396	1.000
Predicted_Proba	-0.242	0.605
jeune_faible_ancienneté	-0.130	0.196
formations_par_an	-0.132	0.175
hs_et_salaire_bas	0.136	0.107
performance	-0.052	0.095
Vraie_Classe	0.782	0.017
niveau_education	0.043	0.014
satisfaction_max	0.044	-0.117
satisfaction_globale	0.131	-0.254
annees_dans_le_poste_actuel	0.152	-0.272
revenu_mensuel	0.117	-0.273
ontant_augmentation_precedente	0.107	-0.288
satisfaction_min	0.186	-0.314
inertie_poste	0.168	-0.342

--- Top 5 combinaisons ---

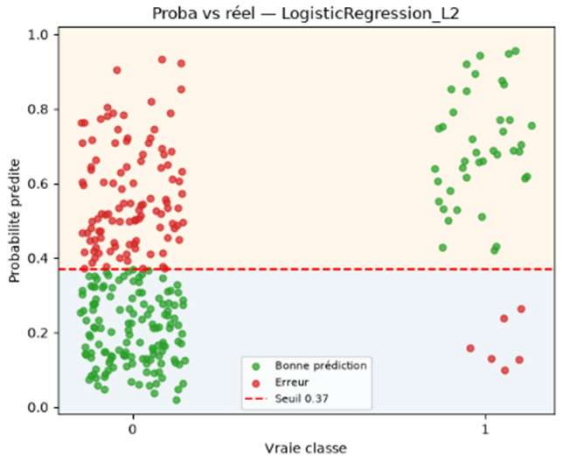
	rank_test_score	mean_test_score	params
4	1	0.770978	{'learning_rate': 0.05, 'min_child_samples': 5...
6	2	0.770456	{'learning_rate': 0.05, 'min_child_samples': 5...
5	3	0.769939	{'learning_rate': 0.05, 'min_child_samples': 5...
0	4	0.769450	{'learning_rate': 0.05, 'min_child_samples': 2...
2	5	0.769274	{'learning_rate': 0.05, 'min_child_samples': 2...

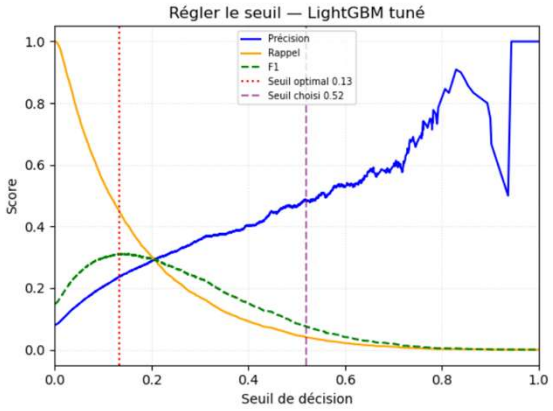
Classifiez automatiquement des informations

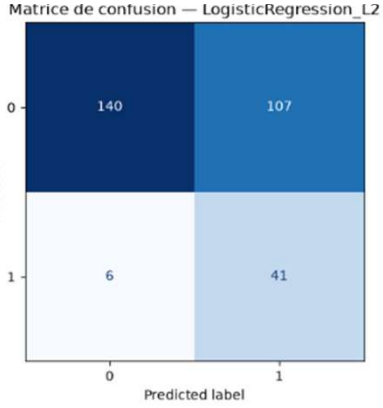
10.2 Optimisation du seuil

Model	ROC AUC cv	ROC AUC train	ROC AUC test	Recall train	Recall test	Accuracy test	Precision test	F1 test	Ecart Train CV	Ecart CV Test	Diagnostic
LogisticRegression_L2	0.808423	0.841443	0.802567	0.884211	0.872340	0.615646	0.277027	0.420513	0.033020	0.005856	Cohérent

Seuil : 0.37



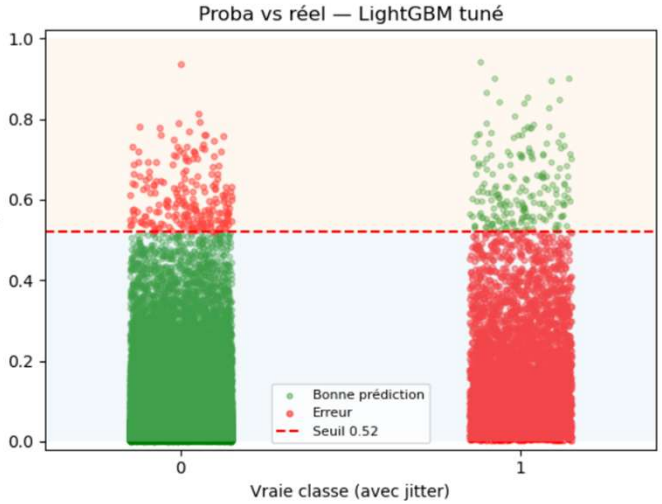


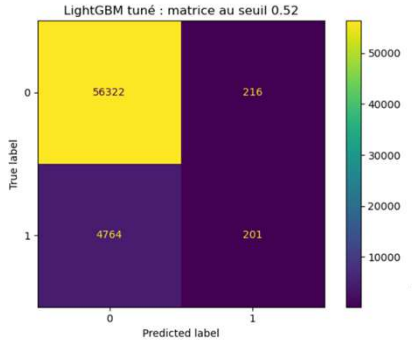


41 départ trouvé
6 raté.
148 alertes dont
107 fausses

Model	ROC AUC cv	ROC AUC train	ROC AUC test	Recall train	Recall test	Accuracy test	Precision test	F1 test	Ecart Train CV	Ecart CV Test	Diagnostic
LogisticRegression_L2	0.808423	0.841443	0.802567	0.636842	0.702128	0.802721	0.428571	0.532258	0.033020	0.005856	Cohérent

Seuil : 0.57



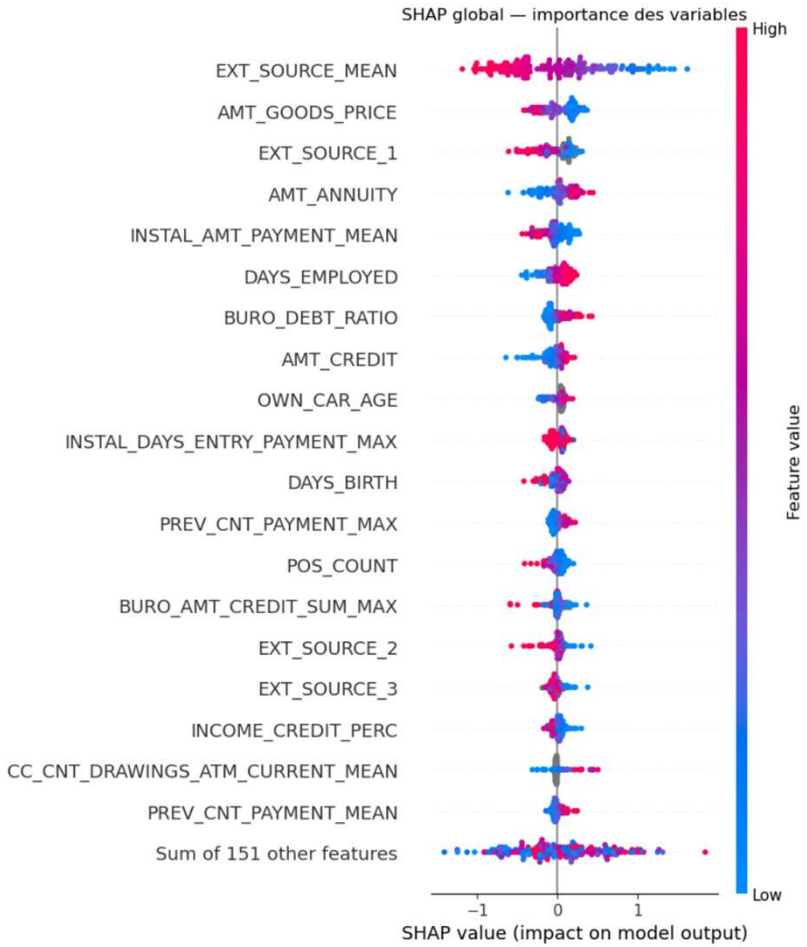


14 départ trouvé
33 raté.
77 alertes dont
44 fausses

*Garder un seuil de 0,57 si rater un départ coûte beaucoup plus cher qu'un rendez-vous HR effectué pour rien.

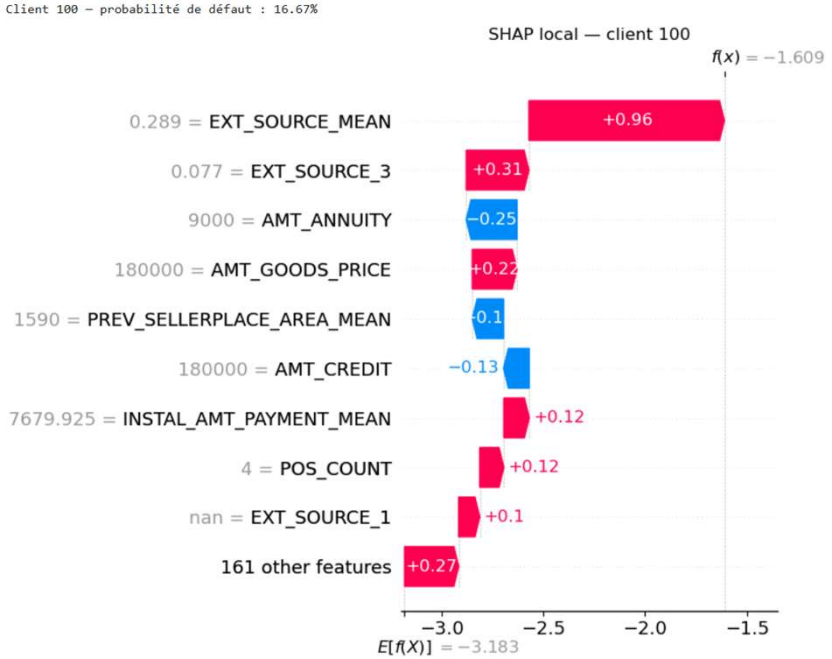
Analyse Shap

Global



Local

Exemple : Pourquoi le n°100 est t'il accepté par la prédiction ? Probabilité de défaut : 16,6%



MLfLOW

LightGBM | 1 hour ago | - | 3.8min | note_bo... | home-credit-LightGBM v7

Metrics (14)

Search metrics

Metric	Value	Models
roc_auc_cv	0.770016713302296	model
roc_auc_cv_std	0.001108322980175044	model
f1_cv	0.2914586311804881	model
auc_train	0.8637063572119985	model
auc_test	0.770214715716514	model
pr_auc_test	0.2537084815147058	model
accuracy_test	0.7342406061492935	model
precision_test	0.18307897961457056	model
recall_test	0.6620342396777442	model
f1_test	0.2868362494000611	model
cout_metier_0.5	31447	model
cout_metier_optimal	31447	model
seuil_optimal	0.5	model
duration_s	190.5454330444336	model

Parameters (4)

Search parameters

Parameter	Value
modele	LightGBM
methode_desequilibre	pondération
n_features	170
activation_mlp	n/a

Model metrics (14)

